© 陈强,《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

## 第2章 概率统计回顾

- 2.1 概率与条件概率
  - 1. 概率

"概率"为在大量重复实验下,事件发生频率趋向的某个稳定值。

记事件"下雨"为A,其发生的"概率"(probability)为P(A)。

【例】天气预报明天 70%概率下雨的含义?

1

## 2. 条件概率

【例】 已知明天会出太阳,下雨的概率有多大?

记事件"出太阳"为B,则在出太阳条件下降雨的"条件概率" (conditional probability)为

$$P(A|B) \equiv \frac{P(A \cap B)}{P(B)}$$

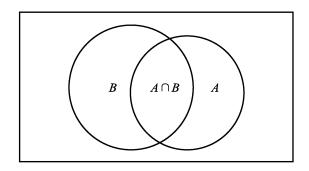


图 2.1 条件概率示意图

【例】股市崩盘的可能性为无条件概率;在已知经济已陷入严重衰退的情况下,股市崩盘的可能性为条件概率。

### 3. 独立事件

如果条件概率等于无条件概率,即P(A|B) = P(A),即 B 是否发生不影响 A 的发生,则称 A ,B 为相互独立的随机事件。

此时, 
$$P(A|B) \equiv \frac{P(A \cap B)}{P(B)} = P(A)$$
,故

$$P(A \cap B) = P(A)P(B)$$

#### 4. 全概率公式

如果事件组 $\{B_1, B_2, \dots, B_n\}$  $(n \ge 2)$ 两两互不相容, $P(B_i) > 0$  $(\forall i = 1, \dots, n)$ ,且 $B_1 \cup B_2 \cup \dots \cup B_n$ 为必然事件,则对任何事件A都有,

$$P(A) = \sum_{i=1}^{n} P(B_i) P(A|B_i)$$

全概率公式把世界分成了n个可能情形,再把每种情况下的条件概率"加权平均"而汇总成无条件概率(权重为每种情形发生的概率)。

该公式有助于理解迭代期望定律。

## 2.2 分布与条件分布

### 1. 离散型概率分布

假设随机变量 X 的可能取值为 $\{x_1, x_2, \dots, x_k, \dots\}$ ,其对应概率为 $\{p_1, p_2, \dots, p_k, \dots\}$ ,即  $p_k \equiv P(X = x_k)$ ,则称 X 为离散型随机变量,其分布律可以表示为

$$X$$
  $x_1$   $x_2$   $\cdots$   $x_k$   $\cdots$   $p$   $p_1$   $p_2$   $\cdots$   $p_k$   $\cdots$ 

其中, 
$$p_k \ge 0$$
,  $\sum_k p_k = 1$ 。

### 2. 连续型概率分布

连续型随机变量可以取任意实数,其"概率密度函数"(probability density function,简记 pdf) f(x) 满足,

(i) 
$$f(x) \ge 0$$
,  $\forall x$ ;

(ii) 
$$\int_{-\infty}^{+\infty} f(x) \, \mathrm{d}x = 1;$$

(iii) 
$$X$$
 落入区间  $[a,b]$  的概率为  $P(a \le X \le b) = \int_a^b f(x) dx$ 。

定义"累积分布函数"(cumulative distribution function, 简记 cdf):

$$F(x) \equiv P(-\infty < X \le x) = \int_{-\infty}^{x} f(t) dt$$

### 3. 多维随机向量的概率分布

为研究变量间关系,常考虑"随机向量"(random vector)。

- 二维连续型随机向量(X,Y)的"联合密度函数"f(x,y)满足,
- (i)  $f(x, y) \ge 0$ ,  $\forall x, y$ ;

(ii) 
$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1;$$

(iii) (X,Y) 落 入 平 面 某 区 域 D 的 概 率 为  $P\{(X,Y)\in D\}=\iint_D f(x,y)dxdy$ 。

n 维连续型随机向量  $(X_1, X_2, \dots, X_n)$  可由联合密度函数  $f(x_1, x_2, \dots, x_n)$  来描述。

从二维联合密度 f(x,y), 可计算 X 的(一维)边缘密度函数:

$$f_x(x) = \int_{-\infty}^{+\infty} f(x, y) \, \mathrm{d}y$$

类似地,可计算 Y的(一维)边缘密度函数:

$$f_{y}(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

定义二维随机向量(X,Y)的累积分布函数为:

$$F(x, y) \equiv P(-\infty < X \le x; -\infty < Y \le y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f(t, s) dt ds$$

### 4. 条件分布

考虑在 X = x 条件下 Y 的条件分布(conditional distribution),记为 Y|X = x。如果 X 为连续型随机变量,事件  $\{X = x\}$  发生的概率为 0,该如何计算 Y|X = x 的 "条件概率密度"?

考虑 $X \in [x-\varepsilon, x+\varepsilon]$ , 然后让 $\varepsilon \to 0^+$ , 可证明条件密度函数为:

$$f(y \mid x) = \frac{f(x, y)}{f_x(x)}$$

此公式与条件概率公式类似。

## 2.3 随机变量的数字特征

定义 对于分布律为  $p_k = P(X = x_k)$  的离散型随机变量 X,其期望 (expectation)

$$E(X) \equiv \mu \equiv \sum_{k=1}^{\infty} x_k p_k$$

定义 对于概率密度函数为f(x)的连续型随机变量X,其期望

$$E(X) \equiv \mu \equiv \int_{-\infty}^{+\infty} x f(x) dx$$

期望算子(expectation operator)满足"线性性"(linearity),即E(X+Y)=E(X)+E(Y),E(kX)=kE(X),k为任意常数。

## 定义 随机变量 X 的方差(variance)

$$Var(X) \equiv \sigma^2 \equiv E[X - E(X)]^2$$

称方差的平方根为**标准差**(standard deviation),记为 $\sigma$ 。

命题 
$$\operatorname{Var}(X) = \operatorname{E}[X^2] - \left[\operatorname{E}(X)\right]^2$$

证明: 
$$Var(X) = E[X - E(X)]^2 = E\{X^2 - 2E(X)X + [E(X)]^2\}$$
  
=  $E[X^2] - 2[E(X)]^2 + [E(X)]^2 = E[X^2] - [E(X)]^2$ 

## 定义 随机变量 X 与 Y 的协方差(covariance)

$$Cov(X, Y) \equiv \sigma_{XY} \equiv E \lceil (X - E(X))(Y - E(Y)) \rceil$$

如果Cov(X,Y)>0,二者正相关;反之,负相关。

如果Cov(X,Y)=0,则线性不相关,但不一定相互独立。

计算协方差的简便公式:

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$$

$$= E[XY - X E(Y) - E(X)Y + E(X)E(Y)]$$

$$= E(XY) - E(X)E(Y)$$

协方差的运算也满足线性性:

$$Cov(X, Y + Z) = Cov(X, Y) + Cov(X, Z)$$

将协方差标准化:

定义 随机变量 X 与 Y 的相关系数(correlation)

$$\rho = \operatorname{Corr}(X, Y) = \frac{\operatorname{Cov}(X, Y)}{\sqrt{\operatorname{Var}(X) \operatorname{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

可以证明,  $-1 \le \rho \le 1$ 。

对于随机变量 X,可定义一系列的数字特征,即各阶"矩" (moment)的概念。

定义 一阶原点矩为E(X)(即期望),二阶原点矩为 $E(X^2)$ ,三阶原点矩为 $E(X^3)$ ,四阶原点矩为 $E(X^4)$ ,等等。

定义 二阶中心矩为 $E[X-E(X)]^2$ (即方差),三阶中心矩为 $E[X-E(X)]^3$ ,四阶中心矩为 $E[X-E(X)]^4$ ,等等。

- 一阶原点矩(期望)表示随机变量的平均值。
- 二阶中心矩(方差)表示随机变量的波动程度。

三阶中心矩表示随机变量密度函数的不对称性(偏度)。

四阶中心矩表示随机变量密度函数的最高处(山峰)有多"尖"及尾部有多"厚"(峰度)。

将三、四阶中心矩标准化:

定义 随机变量 X 的偏度(skewness)为  $E[(X - \mu)/\sigma]^3$ 。

如果随机变量为对称分布(比如,正态分布),则其偏度为 0 (奇函数在关于原点对称的区间上积分为 0)。

定义 随机变量 X 的峰度(kurtosis)为  $E[(X - \mu)/\sigma]^4$ 。

正态分布的峰度为3。

定义 随机变量 X 的超额峰度 (excess kurtosis)为  $E[(X-\mu)/\sigma]^4-3$ 。

如果随机变量 X 的峰度大于 3 (比如 t 分布),则其密度函数的两侧尾部更"厚" (fat tails)。

可使用正态分布的偏度与峰度性质来检验某分布是否为正态。

更一般地,对于任意函数  $g(\cdot)$ ,称随机变量函数的期望  $E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x)dx$  为矩(moment)。

定义 条件期望(conditional expectation)即条件分布Y|x的期望:

$$E(Y \mid X = x) \equiv E(Y \mid x) = \int_{-\infty}^{+\infty} y f(y \mid x) dy$$

由于 y 已被积分掉,故 E(Y|x) 只是 x 的函数。

定义 条件方差(conditional variance)就是条件分布Y|x的方差

$$Var(Y | X = x) \equiv Var(Y | x) = \int_{-\infty}^{+\infty} [y - E(Y | x)]^2 f(y | x) dy$$

由于 y 已被积分掉,故 Var(Y|x) 只是 x 的函数。

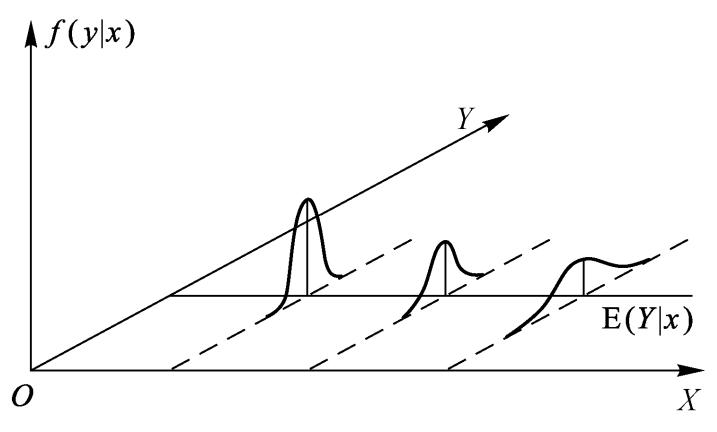


图 2.2 条件期望与条件方差示意图

为引入随机向量的数字特征,回顾矩阵的相关概念。

定义 对于 $n \times n$  对称矩阵 A (symmetric),如果对于任意 n 维非零列向量c,都有二次型 $c'Ac \ge 0$ ,则称A 为半正定矩阵。

定义 对于 $n \times n$  对称矩阵A,如果对于任意n 维非零列向量c,都有二次型c'Ac > 0,则称A 为正定矩阵。

从几何上看,对于正定矩阵,可通过坐标变换变为一个主对角线上元素全部为正数的对角矩阵(特征值全部为正)。

故正定矩阵的行列式一定不等于0,故其逆矩阵一定存在。

在一维情形下,正定矩阵就相当于正数。

类似地,可定义半负定与负定矩阵。

命题 对于任意矩阵 D, D'D 为半正定矩阵。

证明:由于D'D = (D'D)',故D'D为对称矩阵。

不失一般性,假设D'D为n级矩阵。对于任意n维非零列向量c,二次型

$$c'(D'D)c = (c'D')(Dc) = \underbrace{(Dc)'Dc}_{\text{平方和}} \ge 0$$

故D'D 为半正定矩阵。

定义 设 $X = (X_1 X_2 \cdots X_n)'$ 为 n 维随机向量,则其"协方差矩阵" (covariance matrix)为  $n \times n$  的对称半正定矩阵:

$$Cov(X) = Var(X) = E \begin{bmatrix} (X - E(X))(X - E(X))' \\ \vdots \\ (X_n - E(X_n)) \end{bmatrix} (X_1 - E(X_1) & \cdots & X_n - E(X_n) \end{bmatrix}$$

$$= E \begin{bmatrix} [X_1 - E(X_1)]^2 & \cdots & [X_1 - E(X_1)][X_n - E(X_n)] \\ \vdots & \ddots & \vdots \\ [X_1 - E(X_1)][X_n - E(X_n)] & \cdots & [X_n - E(X_n)]^2 \end{bmatrix}$$

$$= \begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & \ddots & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{pmatrix}$$

主对角线元素  $\sigma_{ii} \equiv \text{Var}(X_i)$ , 非主对角线元素  $\sigma_{ij} \equiv \text{Cov}(X_i, X_j)$ 。

假设A为 $m \times n$ 常数矩阵(不含随机变量),可证明:

(i) 
$$E(AX) = AE(X)$$
;

(ii) 
$$\operatorname{Var}(X) = \operatorname{E}(XX') - \operatorname{E}(X) \left[ \operatorname{E}(X) \right]'$$
;

(iii) 
$$Var(AX) = A Var(X)A'$$

命题 n 维随机向量 X 的协方差矩阵 Var(X) 为半正定矩阵。

证明:根据协方差矩阵的定义,Var(X)为 $n \times n$ 对称矩阵。

对于n维非零列向量c,随机变量c'X的方差必然大于或等于0。因此,

$$Var(c'X) = c' Var(X)c \ge 0$$

根据定义,Var(X)为半正定矩阵。

考虑两个随机向量之间的协方差矩阵。

定义 设 $X = (X_1 X_2 \cdots X_n)'$ 为n维随机向量, $Y = (Y_1 Y_2 \cdots Y_m)'$ 为m维随机向量,则这两个随机向量之间的协方差矩阵为

$$Cov(X,Y) \equiv E\left[\left(X - E(X)\right)\left(Y - E(Y)\right)'\right] = E(XY') - E(X)E(Y')$$

### 2.4 迭代期望定律

**定理** 对于条件期望的运算,有以下重要的"迭代期望定律"(Law of iterated expectation),

$$E(Y) = E_X [E(Y \mid x)]$$

以连续型变量为例来证明。

证明: LHS = E(Y) = 
$$\int_{-\infty}^{+\infty} y f_y(y) dy$$

RHS = E<sub>X</sub>  $\left[ \int_{-\infty}^{+\infty} y \frac{f(x,y)}{f_x(x)} dy \right] = \int_{-\infty}^{+\infty} \left[ \int_{-\infty}^{+\infty} y \frac{f(x,y)}{f_x(x)} dy \right] f_x(x) dx$ 

=  $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x,y) dx dy = \int_{-\infty}^{+\infty} y \left[ \int_{-\infty}^{+\infty} f(x,y) dx \right] dy = LHS$ 

无条件期望等于条件期望之加权平均,权重为条件概率密度。

在离散随机变量的情形下:

$$E(Y) = \sum_{x_i} P(X = x_i) E(Y \mid x_i)$$

推而广之,对于任意函数 g(·)都有:

$$E[g(Y)] = E_X E[g(Y) | x]$$

有时省去期望算子 $E_X$ 的下标,需注意对什么变量求期望。

### 2.5 随机变量无关的三个层次概念

**定义** 对于连续型随机变量 X 与 Y, 如果其联合密度等于边缘密度的乘积,即  $f(x,y) = f_x(x)f_y(y)$ ,则称 X 与 Y 相互独立。

X与 Y相互独立,是随机变量"无关"的最强概念。

线性不相关的概念更弱,仅要求Cov(X,Y)=0。"相互独立"意味着"线性不相关",但反之不然。

二者之间还有一个中间层次的无关概念,即"均值独立" (mean-independence)。

定义 假设条件期望 E(Y|x) 存在。如果 E(Y|x) 不依赖于 X,则称 "Y均值独立于 X" (Y is mean-independent of X)。

均值独立不是对称的关系,"Y均值独立于 X"不意味着"X均值独立于 Y"。

命题 "Y均值独立于 X" 当且仅当 E(Y|x) = E(Y)。

证明: (1) 假设 "Y 均值独立于 X",则 E(Y|x) 不依赖于 X,故  $E_X[E(Y|x)] = E(Y|x)$  。 根 据 迭 代 期 望 定 律 ,  $E(Y) = E_X[E(Y|x)] = E(Y|x)$ 。

(2) 假设E(Y|x) = E(Y),则显然E(Y|x)不依赖于X。

**命题** 如果 X 与 Y 相互独立,则 Y 均值独立于 X,且 X 均值独立于 Y。

**定理(均值独立意味着不相关)** 如果 Y 均值独立于 X,或 X 均值独立于 Y,则 Cov(X,Y)=0。

### 证明:

$$Cov(X,Y) = E[(X - E(X))(Y - E(Y))]$$
 (协方差的定义)  
 $= E_X E_Y[(X - E(X))(Y - E(Y))|_X]$  (迭代期望定律)  
 $= E_X[(X - E(X))E_Y(Y - E(Y)|_X)]$  (X - E(X) 视为常数)  
 $= E_X[(X - E(X))(E(Y|_X) - E(Y))]$  (期望算子的线性性)  
 $= E_X[(X - E(X)) \cdot 0] = 0$  (均值独立的定义)

总之,"相互独立"⇒"均值独立"⇒"线性不相关"。

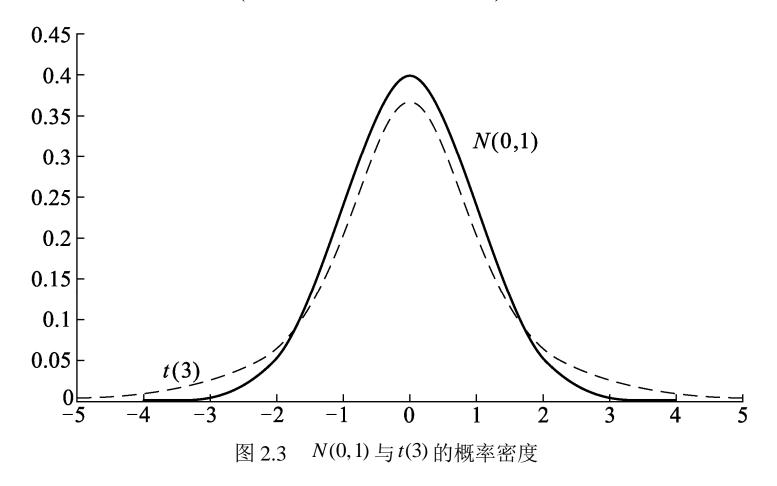
- 2.6 常用连续型统计分布
  - 1. **正态分布**: 如果随机变量 X 的概率密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{\frac{-(x-\mu)^2}{2\sigma^2}\right\}$$

则称 X 服从正态分布,记为  $X \sim N(\mu, \sigma^2)$ ,  $\mu$  为期望,  $\sigma^2$  为方差。

定义 $Z = \frac{X - \mu}{\sigma}$ ,则Z服从标准正态分布,记为 $Z \sim N(0,1)$ 。

标准正态的概率密度记为 $\phi(x)$ ; 累积分布函数记为 $\Phi(x)$ 。正态分布也称"高斯分布"(Gaussian distribution)。



如果 n 维随机向量  $X = (X_1 X_2 \cdots X_n)'$  的联合密度函数为

$$f(x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2} |\mathbf{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu})' \mathbf{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu})\right\}$$

则称 X 服从期望为  $\mu$  、协方差矩阵为  $\Sigma$  的 n 维正态分布,记为  $X \sim N(\mu, \Sigma)$ 。

多维正态的每个分量都是正态,分量之线性组合仍是正态。

但每个分量均为一维正态不足以保证联合分布为多维正态。

**命题** 对于 n 个随机变量  $X_1, X_2, ..., X_n$  ,如果任意线性组合  $k_1X_1 + ... + k_nX_n$  (其中  $k_1, ..., k_n$  不全为 0)都服从一维正态分布,则  $(X_1 X_2 ... X_n)$  服从 n 维正态分布。

**命题** 如果 $(X_1 X_2 \cdots X_n)$ 服从n维正态分布,设 $Y_1, \dots, Y_m$ 分别是 $(X_1 X_2 \cdots X_n)$ 的线性函数,则 $(Y_1 \cdots Y_m)$ 也服从多维正态分布。

证明:考虑 $Y_1, \dots, Y_m$ 的任意线性组合 $k_1Y_1 + \dots + k_mY_m$ ,其中 $k_1, \dots, k_m$ 不全为0。由于 $Y_1, \dots, Y_m$ 分别是 $(X_1 X_2 \dots X_n)$ 的线性函数,故 $k_1Y_1 + \dots + k_mY_m$ 也是 $(X_1 X_2 \dots X_n)$ 的线性函数。由于多维正态的线性组合仍为正态,故 $k_1Y_1 + \dots + k_mY_m$  服从一维正态分布。根据 $k_1, \dots, k_m$ 的任意性可知, $(Y_1 \dots Y_m)$  服从多维正态分布。

如果 $(X_1 X_2 \cdots X_n)$ 服从 n 维正态分布,则 " $X_1, X_2, \cdots, X_n$ 相互 独立"与 " $X_1, X_2, \cdots, X_n$ 两两不相关"是等价的。利用此性质,有时很容易证明正态变量的独立性。

# 2. $\chi^2$ 分布(卡方分布,Chi-square):

如果 $Z \sim N(0,1)$ ,则 $Z^2 \sim \chi^2(1)$ ,即自由度为 1 的 $\chi^2$  分布。如果  $\{Z_1, \dots, Z_k\}$  为独立同分布的标准正态,则其平方和

$$\sum_{i=1}^k Z_i^2 \sim \chi^2(k)$$

参数 k 为 "自由度" (degree of freedom),即由 k 个相互独立(自由)的随机变量构成。

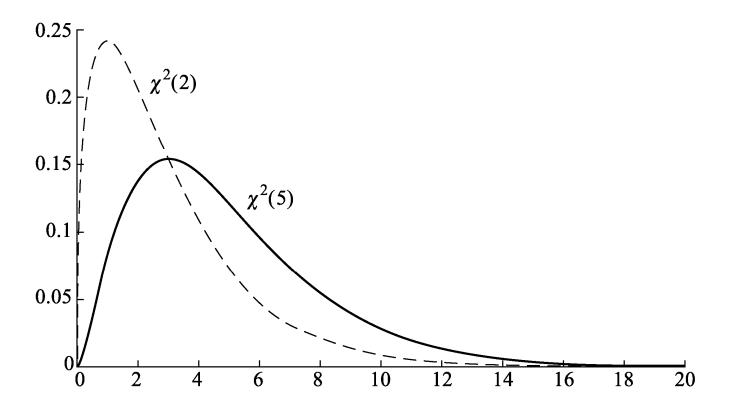


图 2.4  $\chi^2$  分布的概率密度

### 3. t 分布

假设 $Z \sim N(0,1)$ ,  $Y \sim \chi^2(k)$ , 且Z = Y相互独立,则

$$\frac{Z}{\sqrt{Y/k}} \sim t(k)$$

其中, k为自由度。

*t* 分布以原点对称,与标准正态相比,中间"山峰"更低(但更尖),两侧有"厚尾"(fat tails)。

当自由度 $k \to \infty$ 时,t分布收敛于标准正态分布。

### 4. F 分布

假设 $Y_1 \sim \chi^2(k_1)$ ,  $Y_2 \sim \chi^2(k_2)$ , 且 $Y_1, Y_2$ 相互独立,则

$$\frac{Y_1/k_1}{Y_2/k_2} \sim F(k_1, k_2)$$

其中, $k_1, k_2$ 为自由度。

F分布取值为正,概率密度形状与 $\chi^2$ 分布相似。

如果 $X \sim t(k)$ ,可证明 $X^2 \sim F(1,k)$ (参见习题)。

### 2.7 统计推断的思想

计量经济学的主要方法是数理统计的"统计推断"(statistical inference)。

称我们感兴趣的研究对象全体为"总体"(population), 其中的每个研究对象称为"个体"(individual)。

由于总体包含的个体可能很多,普查成本较高,故常从总体抽取部分个体,称为"样本"(sample)。样本中包含个体的数目称为"样本容量"(sample size)。

通常希望样本为"随机样本"(random sample),即总体中的每个个体都有相同的概率被抽中,且被抽中的概率相互独立,称为"独立同分布"(independently identically distributed,简记 iid)。

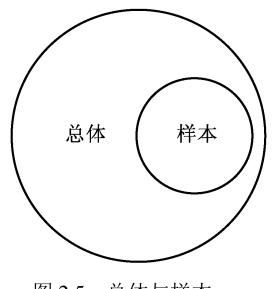


图 2.5 总体与样本

由于样本来自总体,必然带有总体的信息。而统计推断就是根据样本数据对总体性质进行推断的科学。统计推断的主要形式有参数估计(点估计、区间估计)、假设检验及预测等。