© 陈强、《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

第3章 小样本OLS

3.1 古典线性回归模型的假定

"最小二乘法" (Ordinary Least Square, OLS)是单一方程线性回归模型的基本估计方法。"古典线性回归模型" (Classical Linear Regression Model)的假定如下。

假定 3.1 线性假定(linearity)。总体(population)模型为

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \dots, n)$$

1

n 为样本容量,解释变量 x_{ik} 的第一个下标表示第i个观测值,第二个下标则表示第k个解释变量 $(k = 1, \dots, K)$ 。

如有常数项,令第一个解释变量为单位向量,即 $x_{i1} \equiv 1$, $\forall i$ 。

 $\beta_1, \beta_2, \dots, \beta_K$ 为待估参数,称为"回归系数" (regression coefficients)。

线性假设的含义是 x_{ik} 对 y_i 的边际效应为常数,比如 $\frac{\partial E(y_i)}{\partial x_{i1}} = \beta_1$ 。

如果边际效应可变,可加入平方项 (x_{ik}^2) 或交叉互动项 $(x_{ik}x_{im})$ 。

比如,
$$y_i = \beta_1 x_{i1} + \dots + \beta_K x_{iK} + \gamma x_{ik} x_{im} + \varepsilon_i$$

则
$$x_{ik}$$
对 y_i 的平均边际效应为 $\frac{\partial E(y_i)}{\partial x_{ik}} = \beta_k + \gamma x_m$ 。

只要把高次项也作为解释变量来看待,则依然满足线性假定。

总体模型也称"数据生成过程"(Data Generating Process, DGP)。

记第
$$i$$
 个观测数据为 $\mathbf{x}_i \equiv (x_{i1} \ x_{i2} \cdots x_{iK})'$, $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \cdots \beta_K)'$,则

$$y_i = x_i' \beta + \varepsilon_i \quad (i = 1, \dots, n)$$

把所有个体的方程叠放可得

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1' \\ \boldsymbol{x}_2' \\ \vdots \\ \boldsymbol{x}_n' \end{pmatrix} \boldsymbol{\beta} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

定义 $\mathbf{y} \equiv (y_1 \ y_2 \cdots y_n)'$,数据矩阵 $\mathbf{X} \equiv (\mathbf{x}_1 \ \mathbf{x}_2 \cdots \mathbf{x}_n)'$, $\mathbf{\varepsilon} \equiv (\varepsilon_1 \ \varepsilon_2 \cdots \varepsilon_n)'$,则

$$y = X\beta + \varepsilon$$

假定 3.2 严格外生性(strict exogeneity)

$$E(\varepsilon_i \mid \boldsymbol{X}) = E(\varepsilon_i \mid \boldsymbol{x}_1, \dots, \boldsymbol{x}_n) = 0 \quad (i = 1, \dots, n)$$

 ε_i 均值独立于所有解释变量的观测数据,而不仅仅是同一观测数据 x_i 中的解释变量。

 ε_i 与所有解释变量都不相关,即 $Cov(\varepsilon_i, x_{jk}) = 0$, $\forall j, k$ 。此假定很强,在第 5 章可放松。

均值独立仅要求 $E(\varepsilon_i | X) = c$,c 为某常数,不一定为 0。

当回归方程有常数项时,如果 $\mathbf{E}(\varepsilon_i \mid \mathbf{X}) = c \neq 0$,总可以把 c 归入常数项要求。

命题 $E(\varepsilon_i) = 0$,即扰动项的无条件期望为 0。

证明:根据迭代期望定律,
$$E(\varepsilon_i) = E_X \underbrace{E(\varepsilon_i \mid X)}_{=0} = E_X(0) = 0$$
。

定义 如果随机变量 X, Y 满足E(XY)=0, 则称 X, Y 正交 (orthogonal)。

命题 解释变量与扰动项正交。

证明:
$$0 = \text{Cov}(x_{jk}, \varepsilon_i) = \text{E}(x_{jk}\varepsilon_i) - \text{E}(x_{jk}) \underbrace{\text{E}(\varepsilon_i)}_{=0} = \text{E}(x_{jk}\varepsilon_i)$$
。

假定 3.3 不存在"严格多重共线性"(strict multicolinearity),即数据矩阵X满列秩,rank(X) = K,其中"rank"表示矩阵的秩。

如果不满足此条件,则 β "不可识别" (unidentified),因为X 中某个或多个变量为多余。

根据 OLS 估计, $\boldsymbol{b} = (\boldsymbol{X}\boldsymbol{X})^{-1}\boldsymbol{X}\boldsymbol{y}$ 。

如X满列秩,XX正定,故 $(XX)^{-1}$ 存在;反之, $(XX)^{-1}$ 不存在。

实际数据不易出现严格多重共线性。

如果出现,Stata 也会自动识别。

假定 3.4 球型扰动项(spherical disturbance),即扰动项满足"同方差"、"无自相关"的性质,

$$\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \operatorname{E}(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}' \mid \boldsymbol{X}) = \sigma^{2}\boldsymbol{I}_{n} = \begin{pmatrix} \sigma^{2} & 0 \\ & \ddots & \\ 0 & \sigma^{2} \end{pmatrix}$$

 I_n 为n阶单位矩阵。

协方差矩阵 $Var(\boldsymbol{\varepsilon}|\boldsymbol{X})$ 的主对角线元素都等于 σ^2 ,即满足"条件同方差" (conditional homoskedasticity);反之,则存在"条件异方差" (conditional heteroskedasticity)。

协方差矩阵 $Var(\varepsilon|X)$ 的非主对角线元素都为0,不同个体的扰动项之间无"自相关"(autocorrelation);反之,则存在自相关。

3.2 OLS 的代数推导

对于 $\boldsymbol{\beta}$ 的任意假想值 $\tilde{\boldsymbol{\beta}}$,记个体i的拟合误差(即残差, residual)为 $e_i = y_i - \boldsymbol{x}_i' \, \tilde{\boldsymbol{\beta}}$ 。

将所有个体的残差叠放,可得残差向量 $\mathbf{e} \equiv (e_1 e_2 \cdots e_n)' = \mathbf{y} - \mathbf{X}\tilde{\boldsymbol{\beta}}$ 。

最小二乘法寻找能使残差平方和(Sum of Squared Residuals, SSR) $\sum_{i=1}^{n} e_i^2$ 最小的 $\tilde{\boldsymbol{\beta}}$ 。

几何上,一元回归就是寻找最佳拟合的回归直线;

二元回归就是寻找最佳拟合的回归平面;

多元回归,则寻找最佳拟合的回归超平面(superplane)。

最小化问题:

$$\min_{\tilde{\boldsymbol{\beta}}} \operatorname{SSR}(\tilde{\boldsymbol{\beta}}) = \sum_{i=1}^{n} e_{i}^{2} = \boldsymbol{e}' \boldsymbol{e}$$
 (平方和写成向量内积)
$$= (\boldsymbol{y} - \boldsymbol{X}\tilde{\boldsymbol{\beta}})'(\boldsymbol{y} - \boldsymbol{X}\tilde{\boldsymbol{\beta}}) \quad (残差向量的表达式)$$

$$= (\boldsymbol{y}' - \tilde{\boldsymbol{\beta}}' \boldsymbol{X}')(\boldsymbol{y} - \boldsymbol{X}\tilde{\boldsymbol{\beta}}) \quad (矩阵转置性质)$$

$$= \boldsymbol{y}' \boldsymbol{y} - \boldsymbol{y}' \boldsymbol{X}\tilde{\boldsymbol{\beta}} - \tilde{\boldsymbol{\beta}}' \boldsymbol{X}' \boldsymbol{y} + \tilde{\boldsymbol{\beta}}' \boldsymbol{X}' \boldsymbol{X}\tilde{\boldsymbol{\beta}} \quad (乘积展开)$$

$$= \boldsymbol{y}' \boldsymbol{y} - 2 \boldsymbol{y}' \boldsymbol{X}\tilde{\boldsymbol{\beta}} + \tilde{\boldsymbol{\beta}}' \boldsymbol{X}' \boldsymbol{X}\tilde{\boldsymbol{\beta}} \quad (合并同类项)$$

 $(y'X\tilde{\boldsymbol{\beta}})' = \tilde{\boldsymbol{\beta}}'X'y$ (对称矩阵),为1×1常数,故相等,可合为2 $y'X\tilde{\boldsymbol{\beta}}$ 。

目标函数 $SSR(\tilde{\boldsymbol{\beta}})$ 是 $\tilde{\boldsymbol{\beta}}$ 的二次函数(二次型)。

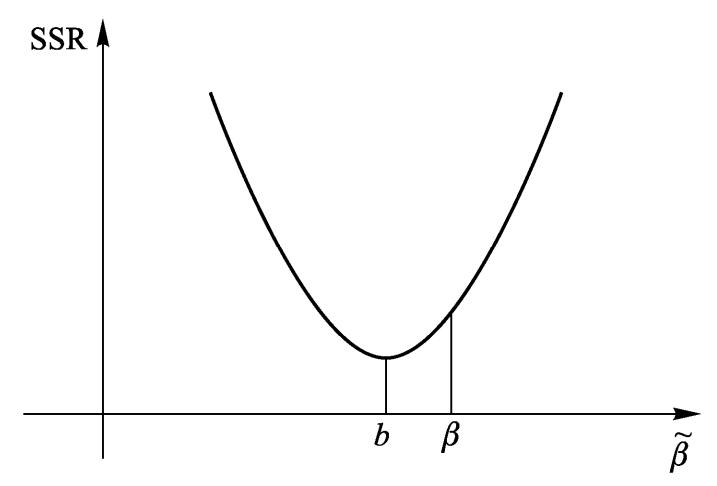


图 3.1 参数的假想值 $\tilde{\beta}$ 、真实值 β 与 OLS 估计值b

向量微分的规则:

记
$$\boldsymbol{a} = (a_1 \ a_2 \cdots a_K)', \quad \text{则}\boldsymbol{a}'\tilde{\boldsymbol{\beta}} = \sum_{i=1}^K a_i \tilde{\beta}_i \ .$$

$$\frac{\partial (\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}} \equiv \left(\frac{\partial (\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_{1}} \frac{\partial (\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_{2}} \cdots \frac{\partial (\boldsymbol{a}'\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_{K}}\right)' = (a_{1} \ a_{2} \cdots a_{K})' = \boldsymbol{a}$$

类似于对一次函数求导。假设A为K阶对称矩阵,可证:

$$\frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\boldsymbol{\beta}}} \equiv \left(\frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_{1}} \frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_{2}} \cdots \frac{\partial(\tilde{\boldsymbol{\beta}}'\boldsymbol{A}\tilde{\boldsymbol{\beta}})}{\partial\tilde{\beta}_{K}}\right)' = 2\boldsymbol{A}\tilde{\boldsymbol{\beta}}$$

类似于对二次函数求导。

使用向量微分规则,可得最小化的一阶条件:

$$\frac{\partial (SSR)}{\partial \tilde{\beta}} = -2X'y + 2X'X\tilde{\beta} = 0$$

最小二乘估计量b满足:

$$(XX)_{K\times K}b_{K\times 1}=X'_{K\times n}y_{n\times 1}$$
 (正规方程组, K 个方程, K 个未知数)

$$X'y - (X'X)b = 0 (移项)$$

$$X'(y-Xb)=0$$
 (向左提取共同的矩阵因子 X')

因此,X'e = 0,其中残差向量 $e \equiv y - Xb$ 。

残差向量e与解释变量X正交,是 OLS 的一大特征。

求解可得 OLS 估计量:

$$\boldsymbol{b} \equiv (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y}$$

二阶条件要求黑赛矩阵(Hessian)

$$\frac{\partial^{2}(SSR)}{\partial\tilde{\boldsymbol{\beta}}\partial\tilde{\boldsymbol{\beta}}'} \equiv \frac{\partial\left(\frac{\partial SSR}{\partial\tilde{\boldsymbol{\beta}}}\right)}{\partial\tilde{\boldsymbol{\beta}}'} \equiv \begin{pmatrix} \frac{\partial^{2}SSR}{\partial^{2}\tilde{\boldsymbol{\beta}}_{1}} & \cdots & \frac{\partial^{2}SSR}{\partial\tilde{\boldsymbol{\beta}}_{1}\partial\tilde{\boldsymbol{\beta}}_{K}} \\ \cdots & \cdots & \cdots \\ \frac{\partial^{2}SSR}{\partial\tilde{\boldsymbol{\beta}}_{1}\partial\tilde{\boldsymbol{\beta}}_{K}} \end{pmatrix} = 2XX \quad 为正定矩阵$$

因为X满列秩,故XX正定。

被解释变量的"拟合值"(fitted values)或"预测值"(predicted values):

$$\hat{\boldsymbol{y}} \equiv (\hat{y}_1 \ \hat{y}_2 \cdots \hat{y}_n)' \equiv \boldsymbol{Xb}$$

可把被解释变量y分解为两个正交的部分,即 $y = \hat{y} + e$,而 $\hat{y} = e$ 正交,因为

$$\hat{\mathbf{y}}'\mathbf{e} = (\mathbf{X}\mathbf{b})'\mathbf{e} = \mathbf{b}'\mathbf{X}'\mathbf{e} = \mathbf{b}' \cdot \mathbf{0} = \mathbf{0}$$

对于扰动项方差 $\sigma^2 = Var(\varepsilon_i)$ 的估计:

$$s^2 \equiv \frac{1}{n-K} \sum_{i=1}^n e_i^2$$

其中,(n-K)为自由度。为什么除以(n-K)而不除以n?

随机变量 $\{e_1, e_2, \dots, e_n\}$ 必须满足 K 个正规方程 X'e = 0,故只有其中(n-K)个 e_i 是相互独立(自由)的。

经过校正后,才是无偏估计, $E(s^2) = \sigma^2$ 。

如果样本容量 n 很大 $(n \to \infty)$,则 $\frac{n-K}{n} \to 1$,是否进行"小样本校正"并没有多少差别。

称 $s = \sqrt{s^2}$ 为 " 回归方程的标准误差" (standard error of the regression),简称"回归方程的标准误"。

称某统计量的标准差为该统计量的"标准误"(standard error)。

3.3 OLS 的几何解释

 \hat{y} 是y向超平面X的投影(projection),因为e与X正交。

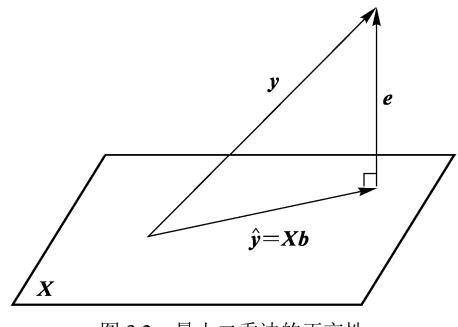


图 3.2 最小二乘法的正交性

由于 $\hat{y} \equiv Xb = X\underbrace{(X'X)^{-1}X'y}_{\equiv b} \equiv Py$,故 $P \equiv X(X'X)^{-1}X'$ 称为"投影矩阵" (projection matrix)。

用P左乘任何向量,就得到该向量在超平面X上的投影。

由于 $e = y - \hat{y} = y - Py = (I_n - P)y \equiv My$,故 $M \equiv I_n - P$ 称为"消灭矩阵" (annihilator matrix)。

用消灭矩阵M左乘任何向量,就得到该向量对超平面X投影后的残差向量。

矩阵P与M的性质(参见习题):

(i)
$$PX = X$$
; (自己的投影还是自己)

(ii)
$$Pe = 0$$
; (垂直于 X 的向量 e 投影于 X 则退化为一个点)

(iii)
$$MX = 0$$
; (自己对自己投影,其残差为 0)

(iv)**P**与**M**都是对称阵;

$$(v)P^2 = P;$$
 (再次投影的效果等于一次投影)

$$(vi)M^2 = M$$
。 (再次消灭的效果等于一次消灭)

把残差写成ε的函数:

$$e = My = M(X\beta + \varepsilon) = \underbrace{MX}_{=0}\beta + M\varepsilon = M\varepsilon$$

把残差平方和写为ε的函数:

$$SSR = e'e = (M\varepsilon)'M\varepsilon = \varepsilon'M'M\varepsilon = \varepsilon'M^2\varepsilon = \varepsilon'M\varepsilon$$

3.4 拟合优度

如果回归方程有常数项,则 $\sum_{i=1}^{n}(y_i-\overline{y})^2$ 可分解为:

$$\sum_{i=1}^{n} (y_i - \overline{y})^2 = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2 + \sum_{i=1}^{n} e_i^2$$

其中, $\overline{y} = \frac{1}{n} \sum_{i=1}^{n} y_i$ 为样本均值。

被解释变量 y_i 的离差平方和可分为两部分,即可由模型解释的部分 $\sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2$,与无法由模型解释的残差部分 $\sum_{i=1}^{n} e_i^2$ 。

平方和分解公式能成立正是由于 OLS 的正交性(参见习题)。

定义 "拟合优度" (goodness of fit) R²为

$$0 \le R^2 \equiv \frac{\sum_{i=1}^n (\hat{y}_i - \overline{y})^2}{\sum_{i=1}^n (y_i - \overline{y})^2} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \overline{y})^2} \le 1$$

拟合优度 R^2 也称"可决系数" (coefficient of determination)。

可以证明(参见习题),在有常数项的情况下,拟合优度等于被解释变量 y_i 与拟合值 \hat{y}_i 之间相关系数的平方,即 $R^2 = [Corr(y_i, \hat{y}_i)]^2$ 。

 R^2 越高,拟合程度越好。

缺点:如果增加解释变量, R^2 只增不减,因为至少可让新增解释变量的系数为0而保持 R^2 不变。

通过调整自由度,对解释变量过多(模型不够简洁)进行惩罚。

定义 校正拟合优度 (adjusted R^2) \bar{R}^2 为

$$\overline{R}^{2} = 1 - \frac{\sum_{i=1}^{n} e_{i}^{2} / (n - K)}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2} / (n - 1)}$$

缺点: \bar{R}^2 可能为负。

无论 R^2 还是 \bar{R}^2 ,只反映拟合程度好坏,除此无太多意义。

评估回归方程是否显著,应使用F检验(R^2 与F统计量有联系)。

如果回归模型无常数项,则平方和分解公式不成立。仍可将 $\sum_{i=1}^{n} y_i^2$ 分解为:

$$\sum_{i=1}^{n} y_i^2 = \mathbf{y}'\mathbf{y} = (\hat{\mathbf{y}} + \mathbf{e})'(\hat{\mathbf{y}} + \mathbf{e}) = \hat{\mathbf{y}}'\hat{\mathbf{y}} + 2\underbrace{\hat{\mathbf{y}}'\mathbf{e}}_{=0} + \mathbf{e}'\mathbf{e} = \sum_{i=1}^{n} \hat{y}_i^2 + \sum_{i=1}^{n} e_i^2$$

定义"非中心 R^2 " (Uncentered R^2):

$$R_{uc}^2 \equiv \frac{\hat{\mathbf{y}}'\hat{\mathbf{y}}}{\mathbf{y}'\mathbf{y}} = 1 - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{y}'\mathbf{y}}$$

如果无常数项,则 Stata 汇报 R_{uc}^2 。

3.5 OLS 的小样本性质

- (1) 线性性: OLS 估计量 $\mathbf{b} = (\mathbf{X}\mathbf{X})^{-1}\mathbf{X}\mathbf{y}$ 为 \mathbf{y} 的线性组合。
- (2) 无偏性: $E(b|X) = \beta$, 即b不会系统地高估或低估 β 。

证明: 抽样误差(sampling error)为

$$\boldsymbol{b} - \boldsymbol{\beta} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y} - \boldsymbol{\beta} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'(\boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) - \boldsymbol{\beta} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{\varepsilon} \equiv \boldsymbol{A}\boldsymbol{\varepsilon}$$

其中,记
$$A \equiv (X'X)^{-1}X'$$
。所以
$$E(b-\beta|X) = E(A\varepsilon|X) = A\underbrace{E(\varepsilon|X)}_{=0} = 0 \quad (严格外生性)$$

移项可得, $E(b|X) = \beta$ 。在此证明中,严格外生性不可或缺。

推论 无条件期望 $E(b) = \beta$ 。

证明: $E(\boldsymbol{b}) = E_X E(\boldsymbol{b} \mid \boldsymbol{X}) = E_X(\boldsymbol{\beta}) = \boldsymbol{\beta}$ (常数的期望仍为常数)。

(3) 估计量**b**的方差为 $Var(\mathbf{b} \mid \mathbf{X}) = \sigma^2(\mathbf{X}\mathbf{X})^{-1}$ 。

证明:
$$Var(\boldsymbol{b} \mid \boldsymbol{X}) = Var(\boldsymbol{b} - \boldsymbol{\beta} \mid \boldsymbol{X})$$
 ($\boldsymbol{\beta}$ 是常数)
$$= Var(\boldsymbol{A}\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \boldsymbol{A} \, Var(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) \boldsymbol{A}' = \boldsymbol{A}\sigma^2 \boldsymbol{I}_n \boldsymbol{A}'$$

$$= \sigma^2 \boldsymbol{A} \boldsymbol{A}' = \sigma^2 (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1} = \sigma^2 (\boldsymbol{X}'\boldsymbol{X})^{-1}$$

球型扰动项假定是证明的关键。

如存在条件异方差,则方差表达式不同,应使用"稳健标准误" (robust standard error),参见第5章。

(4) "高斯-马尔可夫定理"(Gauss-Markov Theorem): 最小二乘 法是最佳线性无偏估计(Best Linear Unbiased Estimator,简记 BLUE),即在所有线性无偏估计中,最小二乘法的方差最小。

证明: OLS 估计量b为线性无偏估计。

假设 $\hat{\boldsymbol{\beta}}$ 为任一线性无偏估计,需证明 $Var(\hat{\boldsymbol{\beta}}|X) \ge Var(\boldsymbol{b}|X)$,即 $Var(\hat{\boldsymbol{\beta}}|X) - Var(\boldsymbol{b}|X)$ 为半正定矩阵。

 $Var(\hat{\boldsymbol{\beta}}|\boldsymbol{X}) - Var(\boldsymbol{b}|\boldsymbol{X})$ 半正定,则 $Var(\boldsymbol{b}|\boldsymbol{X})$ 的主对角线元素(即方差)一定小于或等于 $Var(\hat{\boldsymbol{\beta}}|\boldsymbol{X})$ 的主对角线上对应元素(参见习题)。

由于 $\hat{\boldsymbol{\beta}}$ 为线性估计,故存在常数矩阵 $C_{K\times n}$,使得 $\hat{\boldsymbol{\beta}}=Cy$ 。

已知 $\boldsymbol{b} = A\boldsymbol{y}$,其中 $\boldsymbol{A} \equiv (\boldsymbol{X}\boldsymbol{X})^{-1}\boldsymbol{X}'$ 。定义 $\boldsymbol{D} \equiv \boldsymbol{C} - \boldsymbol{A}$,则

$$\hat{\beta} = Cy = (D + A)y = D(X\beta + \varepsilon) + b = DX\beta + D\varepsilon + b$$

利用β的无偏性可得,

$$\boldsymbol{\beta} = \mathrm{E}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = \mathrm{E}(\boldsymbol{D}\boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{D}\boldsymbol{\varepsilon} + \boldsymbol{b} \mid \boldsymbol{X}) = \boldsymbol{D}\boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{D}\underbrace{\mathrm{E}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})}_{=0} + \underbrace{\mathrm{E}(\boldsymbol{b} \mid \boldsymbol{X})}_{=\beta} = \boldsymbol{D}\boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\beta}$$

对于任意 β ,都有 $DX\beta=0$,故DX=0。 $\hat{\beta}$ 的表达式简化为

$$\hat{\boldsymbol{\beta}} = \underbrace{DX}_{=0} \boldsymbol{\beta} + D\boldsymbol{\varepsilon} + \boldsymbol{b} = D\boldsymbol{\varepsilon} + \boldsymbol{b}$$

 $\hat{\beta}$ 的抽样误差为

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = \boldsymbol{D}\boldsymbol{\varepsilon} + \boldsymbol{b} - \boldsymbol{\beta} = \boldsymbol{D}\boldsymbol{\varepsilon} + \boldsymbol{A}\boldsymbol{\varepsilon} = (\boldsymbol{D} + \boldsymbol{A})\boldsymbol{\varepsilon}$$

$$\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = \operatorname{Var}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \mid \boldsymbol{X}) = \operatorname{Var}[(\boldsymbol{D} + \boldsymbol{A})\boldsymbol{\varepsilon} \mid \boldsymbol{X}] = (\boldsymbol{D} + \boldsymbol{A})\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})(\boldsymbol{D} + \boldsymbol{A})'$$

$$= \sigma^{2}(\boldsymbol{D} + \boldsymbol{A})(\boldsymbol{D}' + \boldsymbol{A}') = \sigma^{2}(\boldsymbol{D}\boldsymbol{D}' + \underbrace{\boldsymbol{A}\boldsymbol{D}'}_{=\boldsymbol{0}} + \underbrace{\boldsymbol{D}\boldsymbol{A}'}_{=\boldsymbol{0}} + \boldsymbol{A}\boldsymbol{A}')$$

$$= \sigma^{2}[\boldsymbol{D}\boldsymbol{D}' + (\boldsymbol{X}'\boldsymbol{X})^{-1}] \quad (\boldsymbol{D}\boldsymbol{A}' = \underbrace{\boldsymbol{D}\boldsymbol{X}}_{=\boldsymbol{0}}(\boldsymbol{X}'\boldsymbol{X})^{-1} = \boldsymbol{0})$$

$$\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) - \operatorname{Var}(\boldsymbol{b} \mid \boldsymbol{X}) = \sigma^{2} \left[\boldsymbol{D} \boldsymbol{D}' + (\boldsymbol{X}' \boldsymbol{X})^{-1} \right] - \sigma^{2} (\boldsymbol{X}' \boldsymbol{X})^{-1} = \sigma^{2} \boldsymbol{D} \boldsymbol{D}'$$

由于**DD**′为半正定矩阵,故高斯-马尔可夫定理成立。

如果没有球型扰动项的假定,则最小二乘法不是 BLUE,还存在其他更优的线性无偏估计,参见第7章。

(5)方差的无偏估计: $E(s^2 \mid X) = \sigma^2$ 。

证明:因为

$$E(s^{2} \mid X) = E\left(\frac{e'e}{n-K} \mid X\right) = E\left(\frac{\varepsilon'M\varepsilon}{n-K} \mid X\right) = \frac{1}{n-K}E(\varepsilon'M\varepsilon \mid X)$$

故只要证明 $E(\boldsymbol{\varepsilon}'\boldsymbol{M}\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = (n-K)\sigma^2$,即可。

定义 任意方阵A的迹(trace)就是其主对角线元素之和,记为 trace(A)。

迹运算的性质:

$$trace(A + B) = trace(A) + trace(B)$$

trace(kA) = k trace(A), k 为常数

trace(AB) = trace(BA) 只要AB 与 BA 都存在

如果A为 1×1 矩阵(常数),则trace(A) = A。

$$E(\boldsymbol{\varepsilon}'\boldsymbol{M}\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = E[\operatorname{trace}(\boldsymbol{\varepsilon}'\boldsymbol{M}\boldsymbol{\varepsilon} \mid \boldsymbol{X})]$$

(ε'Με为1×1)

$$= E[\operatorname{trace}(\boldsymbol{M}\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}' \mid \boldsymbol{X})]$$

 $(\varepsilon' 与 M \varepsilon$ 换次序)

$$= \operatorname{trace} \big[\operatorname{E} (\boldsymbol{M} \boldsymbol{\varepsilon} \boldsymbol{\varepsilon}' \mid \boldsymbol{X}) \big]$$

 $= \operatorname{trace} \left[\operatorname{E}(M \varepsilon \varepsilon' \mid X) \right]$ (期望算子与迹算子换次序)

$$= \operatorname{trace} \left[\boldsymbol{M} \boldsymbol{\sigma}^2 \boldsymbol{I}_n \right]$$

(球型扰动项)

 $=\sigma^2\operatorname{trace}(\boldsymbol{M})$

(迹运算的线性性)

$$\operatorname{trace}(\boldsymbol{M}) = \operatorname{trace}\left[\boldsymbol{I}_{n} - \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\right]$$
 (消灭矩阵 \boldsymbol{M} 的定义)
$$= \operatorname{trace}(\boldsymbol{I}_{n}) - \operatorname{trace}\left[\boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\right] \text{ (迹运算的线性性)}$$

$$= n - \operatorname{trace}\left[(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{X}\right] \qquad (\boldsymbol{X} = \boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}' = \boldsymbol{X}')$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}' = \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}' = \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}' = \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}' = \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}' = \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}'$$

$$= n - \operatorname{trace}(\boldsymbol{I}_{K}) \qquad (\boldsymbol{X}'\boldsymbol{X} = \boldsymbol{X}') + \boldsymbol{X}'$$

对协方差阵 $Var(\boldsymbol{b} \mid \boldsymbol{X})$ 的无偏估计为 $s^2(\boldsymbol{X}'\boldsymbol{X})^{-1}$,在 Stata 中记为 "VCE" (Variance-Covariance Matrix Estimated)。

3.6 对单个系数的 t 检验

假定 3.5 在给定X的情况下, $\boldsymbol{\varepsilon}|X$ 的条件分布为正态,即 $\boldsymbol{\varepsilon}|X\sim N(\mathbf{0},\sigma^2\boldsymbol{I}_n)$ 。

考虑对单个系数进行检验,"原假设" (null hypothesis,零假设) 为 $H_0: \beta_k = \bar{\beta}_k$,其中 $\bar{\beta}_k$ 为给定常数。

通常 $\bar{\beta}_k = 0$,检验变量 x_{ik} 的系数是否显著地不等于 0。

假设检验是概率意义上的反证法,即首先假设原假设成立,然后看在原假设成立的前提下,是否导致不太可能发生的"小概率事件"在一次抽样的样本中出现。

如果小概率事件竟在一次抽样中被观测到,则说明原假设不可信,应该拒绝原假设,接受"替代假设"(alternative hypothesis,备择假设") $H_1: \beta_k \neq \overline{\beta}_k$ 。

如果未知参数 β_k 的估计值 b_k 离 $\bar{\beta}_k$ 较远,则倾向于拒绝原假设。 这类检验称为"沃尔德检验"(Wald test)。

在衡量距离远近时,绝对距离依赖变量单位,需以标准差为基准来考虑相对距离。

由于 $\varepsilon | X \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$,而 $\mathbf{b} - \boldsymbol{\beta} = \mathbf{A}\boldsymbol{\varepsilon}$ 为 $\boldsymbol{\varepsilon}$ 的线性函数,故 $(\mathbf{b} - \boldsymbol{\beta}) | X$ 服从正态分布。

进一步,
$$E(\boldsymbol{b} - \boldsymbol{\beta} \mid \boldsymbol{X}) = \boldsymbol{0}$$
, $Var(\boldsymbol{b} \mid \boldsymbol{X}) = \sigma^2 (\boldsymbol{X} \boldsymbol{X})^{-1}$, 故

$$(\boldsymbol{b} - \boldsymbol{\beta}) | \boldsymbol{X} \sim N(\boldsymbol{0}, \sigma^2 (\boldsymbol{X}'\boldsymbol{X})^{-1}) \circ$$

在原假设" $H_0: \beta_k = \overline{\beta_k}$ "成立的情况下,其第 k 个分量 $(b_k - \overline{\beta_k}) | X \sim N(0, \sigma^2(XX)_{kk}^{-1})$,其中 $(XX)_{kk}^{-1}$ 为矩阵 $(XX)^{-1}$ 的(k, k)元素,而 $\sigma^2(XX)_{kk}^{-1}$ 为 b_k 的方差。

如果
$$\sigma^2$$
已知,则统计量 $z_k \equiv \frac{b_k - \overline{\beta}_k}{\sqrt{\sigma^2 (\boldsymbol{X'\!X})_{kk}^{-1}}} \sim N(0,1)$ 。

通常 σ^2 未知,称为"厌恶参数"(nuisance parameter): 虽然对 σ^2 不感兴趣,但 σ^2 却出现在表达式中。

合格的"检验统计量"(test statistic)须满足两个条件:能够根据样本数据计算;概率分布已知。

以估计值 s^2 来替代 σ^2 ,可得t统计量。

定理(t 统计量的分布) 在假定 3.1-3.5 均满足,且原假设 " H_0 : $\beta_k = \bar{\beta}_k$ " 也成立的情况下,t 统计量

$$t_k \equiv \frac{b_k - \overline{\beta}_k}{\text{SE}(b_k)} \equiv \frac{b_k - \overline{\beta}_k}{\sqrt{s^2 (\boldsymbol{X}'\!\boldsymbol{X})_{kk}^{-1}}} \sim t(n - K)$$

其中, $SE(b_k)$ 是 b_k 的"估计标准误差" (estimated standard error),简称"标准误"。

证明:将统计量 t_k 变形:

$$t_{k} \equiv \frac{b_{k} - \overline{\beta}_{k}}{\sqrt{s^{2} (\boldsymbol{X}' \boldsymbol{X})_{kk}^{-1}}} = \frac{b_{k} - \overline{\beta}_{k}}{\sqrt{\sigma^{2} (\boldsymbol{X}' \boldsymbol{X})_{kk}^{-1}}} \cdot \sqrt{\frac{\sigma^{2}}{s^{2}}} = \frac{z_{k}}{\sqrt{s^{2} / \sigma^{2}}} = \frac{z_{k}}{\sqrt{\frac{\boldsymbol{e'e}}{(n - K)\sigma^{2}}}} \equiv \frac{z_{k}}{\sqrt{q/(n - K)}}$$

其中,
$$z_k \equiv \frac{b_k - \overline{\beta}_k}{\sqrt{\sigma^2 (X'X)_{kk}^{-1}}}, \quad q \equiv \frac{e'e}{\sigma^2}$$
。

已知 $z_k \sim N(0,1)$,下面将证明,

(1)
$$q \mid X \sim \chi^2(n-K);$$

(2)
$$z_k | X 与 q | X$$
相互独立,

则根据
$$t$$
 分布的定义, $\frac{z_k}{\sqrt{q/(n-K)}} \sim t(n-K)$ 。

(1)
$$q = \frac{e'e}{\sigma^2} = \frac{\varepsilon' M \varepsilon}{\sigma^2} = \frac{\varepsilon'}{\sigma} M \frac{\varepsilon}{\sigma}$$
 (二次型)。

由于 $\boldsymbol{\varepsilon} | \boldsymbol{X} \sim N(\boldsymbol{0}, \sigma^2 \boldsymbol{I}_n)$,故 $\frac{\boldsymbol{\varepsilon}}{\sigma} | \boldsymbol{X} \sim N(\boldsymbol{0}, \boldsymbol{I}_n)$ 。已知消灭矩阵 \boldsymbol{M} 为"幂等矩阵" (idempotent matrix,即 $\boldsymbol{M}^2 = \boldsymbol{M}$)。

根据线性代数知识,对于幂等矩阵M,rank(M)=trace(M)=n-K。

根据数理统计知识, $q | X \sim \chi^2(n-K)$ 。由于M不满秩,q | X的自由度降为(n-K)。

(2) $z_k \equiv \frac{b_k - \overline{\beta}_k}{\sqrt{\sigma^2 (X'X)_{kk}^{-1}}}$ 是**b**的函数,q是**e**的函数,故只要证明**b**与**e**相互独立即可。

由于 $b = \beta + A\varepsilon$ 与 $e = M\varepsilon$ 都是正态扰动项 ε 的线性函数,故(b,e)的联合分布也是正态,故只要证明Cov(b,e) = 0即可。

$$Cov(b, e \mid X) = Cov(\beta + A\varepsilon, M\varepsilon \mid X) \qquad (代入b 与 e 表达式)$$

$$= Cov(A\varepsilon, M\varepsilon \mid X) \qquad (去掉常数\beta)$$

$$= E(A\varepsilon\varepsilon'M) - E(A\varepsilon)E(M\varepsilon)' \qquad (协方差矩阵公式)$$

$$= AE(\varepsilon\varepsilon')M = \sigma^2AM = \sigma^2(X'X)^{-1}X'M = \sigma^2(X'X)^{-1}(MX)' = 0$$

$$= O$$

$$(OLS 的正交性)$$

t检验的步骤

第一步: 计算 t_k 。如果 $|t_k|$ 很大,则 H_0 较不可信。如果 H_0 为真,则 $|t_k|$ 很大的概率将很小(为小概率事件),不应在抽样中观测到。

第二步: 计算"显著性水平"(significance level)为 α 的"临界值"(critical value) $t_{\alpha/2}(n-K)$

$$P\{t(n-K) > t_{\alpha/2}(n-K)\} = P\{t(n-K) < -t_{\alpha/2}(n-K)\} = \alpha/2$$

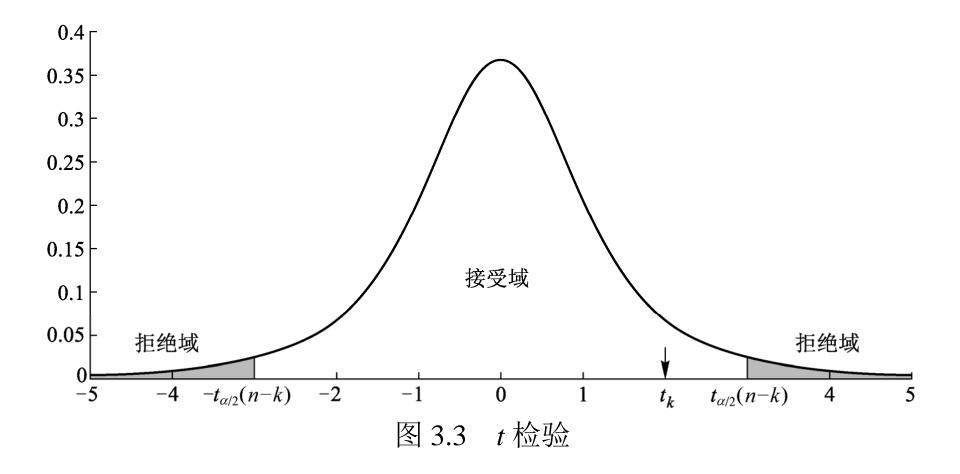
其中,t(n-K)服从 t(n-K)分布。t(n-K)大于 $t_{\alpha/2}(n-K)$,或小于 $-t_{\alpha/2}(n-K)$ 的概率都是 $\alpha/2$ 。通常 $\alpha=5\%$,则 $\alpha/2=2.5\%$ 。有时 $\alpha=1\%$ 或 10%。

第三步: 如果 t_k 落入"拒绝域" (rejection region),则拒绝 H_0 ; t_k 落入"接受域" (acceptance region),则接受 H_0 。

拒绝域分布在t分布两边,称为"双边检验"(two-tailed)。

计算 p 值

定义 给定检验统计量的样本观测值,称原假设可被拒绝的最小显著性水平为此假设检验问题的 p 值(probability value, 即 p-value)。



在 t 检验中, p 值为 $P(t>|t_k|) \times 2$, 其中 t_k 为检验统计量的样本观测值。

p值越小则越倾向于拒绝原假设。

【例】p 值 = 0.03,则可在 5%的显著性水平上拒绝原假设。而且,"p 值= 0.03"还可在 3%的显著性水平上拒绝原假设。

使用 p 值进行假设检验一般比临界值更有信息量。

当 Stata 直接给出 p 值时,就不需要知道临界值了。

计算置信区间

假设"置信度"(confidence level)为 $(1-\alpha)$ (比如 $\alpha = 5\%$,则 $1-\alpha = 95\%$),要找到"置信区间"(confidence interval),使得该区间覆盖真实参数 β_k 的概率为 $(1-\alpha)$ 。

由于
$$\frac{b_k - \beta_k}{\text{SE}(b_k)} \sim t(n - K)$$
,故
$$P\left\{-t_{\alpha/2} < \frac{b_k - \beta_k}{\text{SE}(b_k)} < t_{\alpha/2}\right\} = 1 - \alpha \qquad (t_{\alpha/2} \, \text{的定义})$$

$$P\{b_k - t_{\alpha/2}SE(b_k) < \beta_k < b_k + t_{\alpha/2}SE(b_k)\} = 1 - \alpha \qquad (不等式变形)$$

即置信区间为
$$\left[b_k - t_{\alpha/2} \operatorname{SE}(b_k), b_k + t_{\alpha/2} \operatorname{SE}(b_k)\right]$$
。

置信区间是随机区间,随着样本不同而不同。

如果置信度为 95%,抽样 100 次,得到 100 个置信区间,大约 95 个置信区间能覆盖到真实参数 β_k 。

第Ⅰ类错误与第Ⅱ类错误

定义 "第 I 类错误" (Type I error)指的是,虽然原假设为真,但却根据观测数据做出了拒绝原假设的错误判断,即"弃真"。第 I 类错误的发生概率为 $P(\text{reject } H_0 | H_0)$ 。

定义"第॥类错误"(Type II error)指的是,虽然原假设为假(替代假设为真),但却根据观测数据做出了接受原假设的错误判断,即"存伪"。第II类错误的发生概率为 $P(accept H_0|H_1)$ 。

除非增加样本容量,减少第 I 类错误的发生概率,必然导致第 II 类错误的发生概率增加,反之亦然。

在进行检验时,一般先指定可接受的发生第 I 类错误的最大概率,即"显著性水平",比如 5%;而不指定第 II 类错误的发生概率(通常更难计算)。

定义 称 "1 减去第 II 类错误的发生概率"为统计检验的"功效"或"势"(power),即 "1–P(accept $H_0|H_1$)"。换言之,功效为在原假设为错误的情况下,拒绝原假设的概率。

进行检验时,通常知道第I类错误的发生概率,不知道第II类错误的发生概率。

拒绝原假设,比较理直气壮,因为知道犯错概率(显著性水平)。 接受原假设,比较没有把握,通常不知犯错概率(可能较高)。

3.7 对线性假设的 F检验

检验回归方程的显著性,即检验原假设 " H_0 : $\beta_2 = \cdots = \beta_K = 0$ " (β_1 为常数项)。

更一般地,检验m个线性假设是否同时成立:

$$H_0: \underset{m \times K}{\mathbf{R}} \underset{K \times 1}{\mathbf{\beta}} = \underset{m \times 1}{\mathbf{r}}$$

其中,r为 m 维列向量,R为 $m \times K$ 矩阵,rank(R) = m,即R满行秩,没有多余或自相矛盾的方程。

例 对于模型 $y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$,检验" $H_0: \beta_2 = \beta_3$ 且 $\beta_4 = 0$ "。

$$\mathbf{R} = \begin{pmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad \mathbf{r} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad 因为$$

$$\begin{pmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} \beta_2 - \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Wald 检验原理: b是 β 的估计量,如果 H_0 成立,则(Rb-r)应比较接近0。

定理(F 统计量的分布) 在假定 3.1-3.5 均满足,且原假设 " H_0 : $R\beta = r$ " 也成立的情况下,则 F 统计量

$$F \equiv \frac{(\mathbf{R}\mathbf{b} - \mathbf{r})' \left[\mathbf{R} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \right]^{-1} (\mathbf{R}\mathbf{b} - \mathbf{r}) / m}{s^2} \sim F(m, n - K)$$

证明: 由于 $s^2 = e'e/(n-K)$, 可将 F 写成

$$F \equiv \frac{(\mathbf{R}\mathbf{b} - \mathbf{r})' \left[\sigma^2 \mathbf{R} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \right]^{-1} (\mathbf{R}\mathbf{b} - \mathbf{r}) / m}{(\mathbf{e}'\mathbf{e}/\sigma^2) / (n - K)} \equiv \frac{w/m}{q/(n - K)}$$

其中, $w \equiv (\mathbf{R}\mathbf{b} - \mathbf{r})' \left[\sigma^2 \mathbf{R} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \right]^{-1} (\mathbf{R}\mathbf{b} - \mathbf{r})$ 。

下面将证明:

- (1) $w | X \sim \chi^2(m);$
- (2) $q | X \sim \chi^2(n-K)$; (已在 t 检验定理中证明)
- (3) $w|X \ni q|X$ 相互独立,

则根据 F 分布的定义, $\frac{w/m}{q/(n-K)} \sim F(m,n-K)$ 。

(1) 定义 $v = \mathbf{Rb} - \mathbf{r}$ 。在 H_0 成立的情况下,

$$v \equiv Rb - r = Rb - R\beta = R(b - \beta)$$

由于b为正态,故v|X为m维正态,且E(v|X)=0,方差为

$$\operatorname{Var}(\boldsymbol{v} \mid \boldsymbol{X}) = \operatorname{Var}[\boldsymbol{R}(\boldsymbol{b} - \boldsymbol{\beta}) \mid \boldsymbol{X}] = \boldsymbol{R} \operatorname{Var}(\boldsymbol{b}) \boldsymbol{R}' = \sigma^2 \boldsymbol{R} (\boldsymbol{X}' \boldsymbol{X})^{-1} \boldsymbol{R}'$$

根据数理统计知识,

$$w = (\mathbf{R}\mathbf{b} - \mathbf{r})' [\sigma^{2}\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1} (\mathbf{R}\mathbf{b} - \mathbf{r}) = v' [\operatorname{Var}(\mathbf{v} \mid \mathbf{X})]^{-1} v \sim \chi^{2}(m)$$

由于R满行秩,故[$R(X'X)^{-1}R'$]⁻¹存在。

(3) w 是 b 的 函数, q 是 e 的 函数, 由于 b 与 e 相互独立, 故 w|X 与 q|X 相互独立。

F检验的步骤

第一步: 计算F 统计量。如果F 统计量很大,则 H_0 较不可信。

第二步: 计算显著性水平为 α 的临界值 $F_{\alpha}(m, n-K)$,

$$P\{F(m, n-K) > F_{\alpha}(m, n-K)\} = \alpha$$

其中, F(m, n-K) 服从 F(m, n-K) 分布。

第三步:如果F统计量落入右边拒绝域,则拒绝 H_0 ;F统计量

落入接受域,则接受 H_0 。拒绝域只在右侧,为"单边右侧检验"。

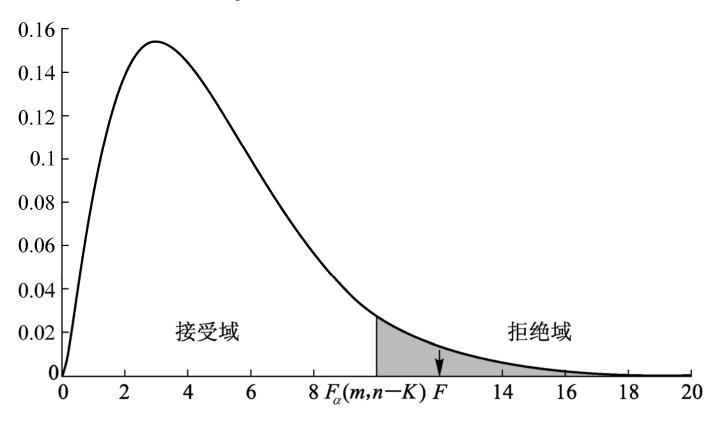


图 3.4 F 检验

3.8 F 统计量的似然比原理表达式

使用约束条件下的最小二乘法,即 "约束最小二乘法" (Restricted OLS, Constrained OLS),可得F统计量的简便表达式。

考虑以下约束极值问题:

$$\min_{\tilde{\boldsymbol{\beta}}} SSR(\tilde{\boldsymbol{\beta}})$$
s.t. $R\tilde{\boldsymbol{\beta}} = r$

如果 " H_0 : $R\beta = r$ " 正确,则加上此约束不应使残差平方和 $SSR(\tilde{\beta})$ 的最小值增大很多。

求解此约束极值问题,可证明:

$$F = \frac{(e^{*\prime}e^* - e'e)/m}{e'e/(n-K)}$$

其中,e为无约束残差, e^* 为有约束残差,m为约束条件个数。

这种通过比较"条件极值"与"无条件极值"而进行的检验, 统称为"似然比检验"(Likelihood ratio test)。

命题 对于线性回归方程 " $y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i$ ",检验原假设 " $H_0: \beta_2 = \dots = \beta_K = 0$ " (即该方程的显著性)的 F 统计量等于 $\frac{R^2/(K-1)}{(1-R^2)/(n-K)}$ 。

证明:由于共有(K-1)个约束,根据似然比原理的F统计量为

$$F = \frac{(e^{*'}e^{*} - e'e)/(K - 1)}{e'e/(n - K)} = \frac{\frac{(e^{*'}e^{*} - e'e)}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2}}/(K - 1)}{\frac{e'e}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2}}/(n - K)}$$

其中,e为无约束残差,而 e^* 为约束残差。记约束回归的拟合优

度为
$$R_*^2$$
,由于 $\frac{e'e}{\sum_{i=1}^n (y_i - \overline{y})^2} = 1 - R^2$, $\frac{e^*e}{\sum_{i=1}^n (y_i - \overline{y})^2} = 1 - R_*^2$,故

$$F = \frac{\left[(1 - R_*^2) - (1 - R^2) \right] / (K - 1)}{(1 - R^2) / (n - K)} = \frac{(R^2 - R_*^2) / (K - 1)}{(1 - R^2) / (n - K)}$$

只需证明 $R_*^2 = 0$ 即可。

当 " $H_0: \beta_2 = \cdots = \beta_K = 0$ "成立时, $y_i = \beta_1 + \varepsilon_i$,而 $b_1^* = \overline{y}(只对常数项<math>\beta_1$ 进行回归),故 $\hat{y}_i^* = b_1^* = \overline{y}$ 。

由此可知
$$\sum_{i=1}^{n} (\hat{y}_{i}^{*} - \overline{y})^{2} = 0$$
,故 $R_{*}^{2} = 0$ 。

3.9 分块回归与偏回归(选读)

3.10 预 测

有时也用计量模型进行预测(prediction, forecasting),即给定解释向量 x_0 的(未来)取值,预测被解释变量 y_0 的取值。

假设计量模型对所有观测值都成立(包括外推到未来的观测值),

$$y_0 = \boldsymbol{x}_0' \boldsymbol{\beta} + \varepsilon_0$$

用 $\hat{y}_0 \equiv x_0' b$ 对 y_0 作点预测,b 为 β 的 OLS 估计量。

"预测误差" (prediction error)($\hat{y}_0 - y_0$)可写为

$$\hat{y}_0 - y_0 = x_0' b - x_0' \beta - \varepsilon_0 = x_0' (b - \beta) - \varepsilon_0$$

由于 \boldsymbol{b} 是 $\boldsymbol{\beta}$ 的无偏估计,故E $(\hat{y}_0 - y_0) = \boldsymbol{x}_0' E(\boldsymbol{b} - \boldsymbol{\beta}) - E(\varepsilon_0) = 0$ 。

"无偏预测" (unbiased predictor): 用 \hat{y}_0 来预测 y_0 不会系统高估或低估。

预测 ŷ。的方差为:

$$\operatorname{Var}(\hat{y}_0) = \operatorname{Var}(\boldsymbol{x}_0'\boldsymbol{b}) = \boldsymbol{x}_0' \operatorname{Var}(\boldsymbol{b}) \boldsymbol{x}_0 = \sigma^2 \boldsymbol{x}_0' (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{x}_0$$

此方差反映由于抽样误差($\boldsymbol{b} - \boldsymbol{\beta}$)所带来的预测量 \hat{y}_0 的波动。如果知道 $\boldsymbol{\beta}$,则 $\mathrm{Var}(\hat{y}_0) = \mathrm{Var}(\boldsymbol{x}_0' \boldsymbol{\beta}) = 0$ 。

预测误差 $(\hat{y}_0 - y_0)$ 的方差为:

$$Var(\hat{y}_0 - y_0) = Var[\mathbf{x}'_0(\mathbf{b} - \boldsymbol{\beta}) - \varepsilon_0]$$

$$= Var(\varepsilon_0) + Var[\mathbf{x}'_0(\mathbf{b} - \boldsymbol{\beta})]$$

$$= \sigma^2 + \sigma^2 \mathbf{x}'_0(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0$$

其中,假设 ε_0 与 \boldsymbol{b} 不相关(估计 \boldsymbol{b} 没用到 ε_0 的信息),故 $Cov[\boldsymbol{x}_0'(\boldsymbol{b}-\boldsymbol{\beta}), \varepsilon_0]=0$ 。

预测误差的方差有两个来源,即抽样误差 $\sigma^2 x_0' (X'X)^{-1} x_0$ (不能精确知道参数 β),以及 y_0 本身的不确定性(ε_0 的方差 σ^2)。

假设扰动项为正态,则 $\hat{y}_0 - y_0 \sim N(0, \sigma^2 + \sigma^2 x_0'(X'X)^{-1}x_0)$ 。

用 s^2 估计 σ^2 ,得到t统计量:

$$\frac{\hat{y}_0 - y_0}{s\sqrt{1 + x_0'(X'X)^{-1}x_0}} \sim t(n - K)$$

 y_0 的置信度为 $(1-\alpha)$ 的置信区间为

$$\left(\hat{y}_0 - t_{\alpha/2} s \sqrt{1 + \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0}, \hat{y}_0 + t_{\alpha/2} s \sqrt{1 + \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0}\right)$$