第9章 模型设定与数据问题

如果模型设定(model specification)不当,如解释变量选择不当、测量误差、函数形式不妥等,会出现"设定误差"(specification error)。

数据本身也可能存在问题,如多重共线性、对回归结果影响很大的极端数据等。

9.1 遗漏变量

假设真实的模型为

$$y_i = x_{i1}' \beta_1 + x_{i2}' \beta_2 + \varepsilon_i$$

其中, x_1, x_2 可以是向量,且与扰动项 ε 不相关。而实际估计的模型(estimated model)为

$$y_i = x_{i1}' \beta_1 + u_i$$

遗漏变量(omitted variables) $x'_{i2}\beta_2$,被归入新扰动项 $u_i = x'_{i2}\beta_2 + \varepsilon_i$ 。

考虑以下两种情形:

- (1) $Cov(x_{i1}, x_{i2}) = 0$.
- OLS 一致。遗漏变量 $x'_{i2}\beta_2$ 归入扰动项 u_i 中,可能增大扰动项的方差,影响估计精度。
 - (2) $Cov(x_{i1}, x_{i2}) \neq 0$
 - OLS 不一致,其偏差为"遗漏变量偏差"(omitted variable bias)。

解决遗漏变量偏差的方法主要有:

- (i) 加入尽可能多的控制变量(control variable);
- (ii) 使用"代理变量"(proxy variable);
- (iii) 工具变量法(第 10 章);
- (iv) 使用面板数据(第 15-17 章);
- (v) 随机实验与自然实验(第 18 章)。

第(i)种方法:尽可能去收集数据。或从理论上说明,遗漏变量不会与解释变量相关,或相关性很弱。

例 李宏彬等(2012)通过就业调查数据,研究"官二代"大学毕业生的起薪是否高于非官二代。

由于可能存在遗漏变量,该文包括了尽可能多的控制变量,比如年龄、性别、城镇户口、父母收入、父母学历、高考成绩、大学成绩、文理科、党员、学生会干部、兼职实习经历、拥有技术等级证书等。

第(ii)种方法,即代理变量法。比如,在教育投资回归中,可用智商(IQ)来作为个人能力的代理变量。

理想的代理变量应满足以下两个条件:

(1) 多余性(redundancy):

即代理变量仅通过影响遗漏变量而作用于被解释变量。比如,"智商"仅通过对"能力"的作用来影响工资收入。假如有"能力"的数据,引入"智商"量就是多余的。

(2) 剩余独立性:

遗漏变量中不受代理变量影响的剩余部分与所有解释变量均不相关。

命题 如果上述两个条件满足,使用代理变量能获得一致估计。

证明: 假设真实模型为

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_K x_K + \gamma q + \varepsilon$$

其中,q 为不可观测的遗漏变量。假定 $Cov(x_k, \varepsilon) = 0, \forall k$,但 q 与某解释变量 x_m 相关($1 \le m \le K$),即 $Cov(x_m, q) \ne 0$,故 OLS 不一致。

假设找到代理变量z,满足

$$q = \delta_0 + \delta_1 z + v$$
, $Cov(z, v) = 0$

根据第一个条件(多余性),代理变量z只通过q对y发生作用,

故在回归方程已经包含 q 的情况下,z 与 y 的扰动项 ε 不相关,即 $Cov(z,\varepsilon)=0$ 。

根据第二个条件,q 的扰动项v与所有解释变量均不相关,即 $Cov(x_k,v)=0, \forall k$ 。将 q 的表达式代入原模型可得

$$y = (\beta_0 + \gamma \delta_0) + \beta_1 x_1 + \dots + \beta_K x_K + \gamma \delta_1 z + (\gamma v + \varepsilon)$$

容易证明,新扰动项 $(\gamma v + \varepsilon)$ 与所有解释变量均不相关,

$$Cov(x_k, \gamma v + \varepsilon) = \gamma \underbrace{Cov(x_k, v)}_{\text{condition 2}} + \underbrace{Cov(x_k, \varepsilon)}_{\text{assumption}} = 0 + 0 = 0 \quad (\forall k)$$

$$Cov(z, \gamma v + \varepsilon) = \gamma \underbrace{Cov(z, v)}_{\text{assumption}} + \underbrace{Cov(z, \varepsilon)}_{\text{condition 1}} = 0 + 0 = 0$$

故 OLS 一致。如果代理变量不满足这两个条件,则不一致。

任何实证研究中几乎总是存在遗漏变量。

论文应说明,如何在存在遗漏变量的情况下避免遗漏变量偏差。

9.2 无关变量

假设真实模型为

$$y_i = x'_{i1}\beta_1 + \varepsilon_i$$

其中, $Cov(x_{i1}, \varepsilon_i) = 0$ 。而实际估计的模型为

$$y_i = x'_{i1}\beta_1 + x'_{i2}\beta_2 + (\varepsilon_i - \underbrace{x'_{i2}\beta_2}_{=0})$$

由于真实参数 $\beta_2 = 0$,故可将模型写为 $y_i = x'_{i1}\beta_1 + x'_{i2}\beta_2 + \varepsilon_i$ 。

由于 x_2 与y无关,故 x_2 也与y的扰动项 ε 无关,即Cov(x_{i2}, ε_i)=0。

故 OLS 一致,即
$$\lim_{n\to\infty} \hat{\beta}_1 = \beta_1$$
, $\lim_{n\to\infty} \hat{\beta}_2 = \beta_2 = 0$ 。

但引入无关变量后,估计量Â的方差一般会增大。

9.3 建模策略:"由小到大"还是"由大到小"

"由小到大"(specific to general)的建模方式,首先从最简单的小模型开始,逐渐增加解释变量。

但小模型很可能存在遗漏变量,导致估计量不一致,t 检验、F 检验都将失效,很难确定该如何取舍变量。

"由大到小"(general to specific)的建模方式,从尽可能大的模型 开始,收集所有可能的解释变量,逐步剔除不显著的解释变量。

虽冒着包含无关变量的危险,但危害性没有遗漏变量严重。但 在实际操作上,常常很难找到足够多的解释变量。

实践中,常采用这两种策略的折衷方案。

9.4 解释变量个数的选择

加入过多解释变量可提高模型解释力,但牺牲模型的简洁性 (parsimony)。权衡标准:

- (1) 校正可决系数 \bar{R}^2 : 选择解释变量的个数 K 以最大化 \bar{R}^2 。
- (2) "赤池信息准则" (Akaike Information Criterion,简记 AIC): 选择解释变量的个数 K,使得以下目标函数最小化:

$$\min_{K} AIC \equiv \ln(e'e/n) + \frac{2}{n}K$$

右边第一项为对模型拟合度的奖励(减少残差平方和),第二项为对解释变量过多的惩罚(解释变量个数K的增函数)。

当 K 上升时,第一项下降而第二项上升。

(3)"贝叶斯信息准则"(Bayesian Information Criterion, 简记 BIC) 或"施瓦茨信息准则"(Schwarz Information Criterion, 简记 SIC 或 SBIC):

$$\min_{K} BIC \equiv \ln(e'e/n) + \frac{\ln n}{n}K$$

一般来说, $\ln n > 2$,故 BIC 准则对于解释变量过多的惩罚比 AIC 严厉。BIC 准则更强调模型的简洁性。

(4) "汉南-昆信息准则" (Hannan-Quinn Information Criterion, 简记 HQIC):

$$\min_{K} \text{HQIC} \equiv \ln(e'e/n) + \frac{\ln[\ln(n)]}{n}K$$

在时间序列模型中,常用信息准则来确定滞后阶数。

比如,AR(p)模型:

$$y_t = \beta_0 + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + \varepsilon_t, \quad t = 1, \dots, T$$

根据 BIC 或 HQIC 计算的 \hat{p} 是p的一致估计,即当 $T \to \infty$ 时, $\Pr(\hat{p} < p) \to 0$, $\Pr(\hat{p} = p) \to 1$, $\Pr(\hat{p} > p) \to 0$ 。

根据 AIC 计算的 \hat{p} 不一致,在大样本中可能高估p,虽然 $Pr(\hat{p} < p) \rightarrow 0$,但 $Pr(\hat{p} > p) \rightarrow c > 0$ 。

在实践中,常用 AIC 与 BIC。

虽然 BIC 一致而 AIC 不一致,但现实样本有限,而 BIC 准则可能导致模型过小,故 AIC 准则依然常用。

9.5 对函数形式的检验

如果回归方程中存在非线性项,则边际效应不再是常数。

【例】

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \gamma x_1^2 + \delta x_2 x_3 + \varepsilon$$

各变量的边际效应为:

$$\frac{\mathrm{E}(y)}{\partial x_1} = \beta_1 + 2\gamma x_1, \quad \frac{\mathrm{E}(y)}{\partial x_2} = \beta_2 + \delta x_3, \quad \frac{\mathrm{E}(y)}{\partial x_3} = \beta_3 + \delta x_2$$

如怀疑边际效应非常数,应考虑中引入非线性项。

"Ramsey's RESET 检验" (Regression Equation Specification Error Test)的基本思想是,如怀疑遗漏非线性项,则引入非线性项,并检验其系数是否显著。

假设线性回归模型为

$$y = x'\beta + \varepsilon$$

回归拟合值 $\hat{y} = x'b$ 。 $\hat{y} \in x$ 的线性组合, \hat{y}^2 包含解释变量二次项(含平方项与交叉项)的信息, \hat{y}^3 包含解释变量三次项的信息,等等。

考虑回归方程:

$$y = \mathbf{x}'\mathbf{\beta} + \delta_2 \hat{y}^2 + \delta_3 \hat{y}^3 + \delta_4 \hat{y}^4 + \varepsilon$$

对 $H_0: \delta_2 = \delta_3 = \delta_4 = 0$ 作 F 检验。如拒绝 H_0 ,说明应有高次项;

如接受 H_0 ,可使用线性模型。

RESET 检验的缺点是,拒绝 H_0 时,不知道具体遗漏哪些高次项。

另一检验为"连接检验"(link test)。"连接"指的是,将解释变量与被解释变量连接在一起的函数形式是否正确。

进行以下回归:

$$y = \delta_0 + \delta_1 \hat{y} + \delta_2 \hat{y}^2 + error$$

检验 " H_0 : $\delta_2 = 0$ "。如果模型设定正确,则 \hat{y}^2 不应对 y 有解释力。如果拒绝 H_0 : $\delta_2 = 0$,则认为模型设定有误,可考虑加入非线性项或改变回归的函数形式(比如,取对数)。

在确定回归方程的函数形式时,最好从经济理论出发。

如缺乏理论指导,可从线性模型出发,再进行 RESET 或连接检验,看是否应加入非线性项。

9.6 多重共线性

如果数据矩阵*X*不满列秩,即某一解释变量可由其他解释变量 线性表出,则存在"严格多重共线性"。

近似的多重共线性表现为,将第 k 个解释变量 x_k 对其余的解释变量 $\{x_1, \dots, x_{k-1}, x_{k+1}, \dots, x_K\}$ 进行回归,所得可决系数(记为 R_k^2)较高。

在多重共线性下,OLS 仍是 BLUE,但不表示 OLS 估计量方差 在绝对意义上小。

由于存在多重共线性,矩阵(XX)变得几乎不可逆,(XX)⁻¹变得很"大",致使方差 $Var(b|X) = \sigma^2(XX)^{-1}$ 增大,系数估计不准确。

X中元素轻微变化就会引起 $(XX)^{-1}$ 很大变化,导致 OLS 估计值 b发生很大变化。

通常的"症状"是,虽然整个回归方程的 R^2 较大、F 检验也很显著,但单个系数的 t 检验却不显著。

另一"症状"是,增减解释变量使得系数估计值发生较大变化(比如,最后加入的解释变量与已有解释变量构成多重共线性)。

如果两个(或多个)解释变量高度相关,则不易区分各自对被解释变量的影响。如一个变量是另一变量的倍数,则完全无法区分。

可以证明, 协方差矩阵主对角线上的第 k 个元素为

$$\operatorname{Var}(b_k \mid \boldsymbol{X}) = \frac{\sigma^2}{(1 - R_k^2)S_{kk}}$$

其中, $S_{kk} \equiv \sum_{i=1}^{n} (x_{ik} - \overline{x}_k)^2$ 为 x_k 的离差平方和,反映 x_k 的变动幅度。如 x_k 完全不变, $S_{kk} = 0$,则完全无法估计 b_k 。

定义第 k 个解释变量 x_k 的"方差膨胀因子"(Variance Inflation Factor,简记 VIF)为

$$VIF_k = \frac{1}{1 - R_k^2}$$

则 $Var(b_k | X) = VIF_k \cdot (\sigma^2 / S_{kk})$ 。VIF越大, 多重共线性问题越严重。

经验规则: $\max\{VIF_1, \dots, VIF_k\}$ 不超过 10。

处理多重共线性的方法:

- (1) 如果不关心具体的回归系数,只关心整个方程的预测能力,则通常可不必理会多重共线性。多重共线性的主要后果是使得对单个变量的贡献估计不准,但所有变量的整体效应仍可准确估计。
 - (2) 如果关心具体的回归系数,但多重共线性并不影响所关心变

量的显著性,也可不必理会。即使在有方差膨胀的情况下,这些系数依然显著;如果没有多重共线性,只会更加显著。

(3) 如果多重共线性影响到所关心变量的显著性,则需要增大样本容量,剔除导致严重共线性的变量,或对模型设定进行修改。

9.7 极端数据

如果样本数据中的少数观测值离大多数观测值很远,可能对OLS 的回归系数产生很大影响,称为"极端观测值"(outliers or influential data)。

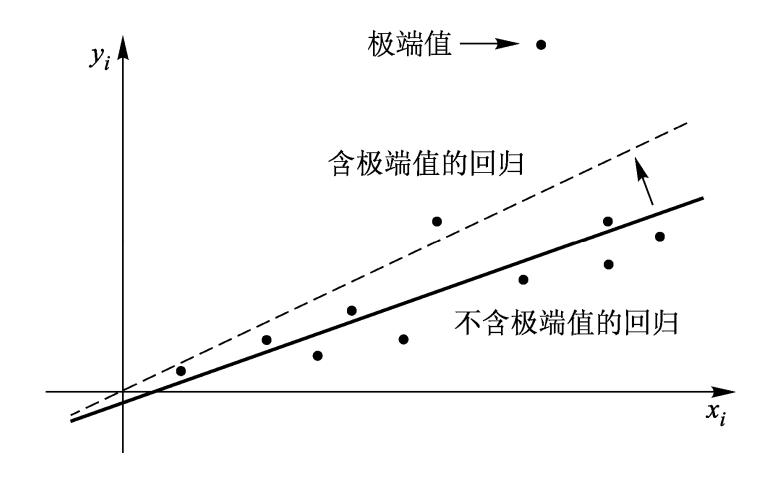


图 9.1 极端观测值对回归系数的影响

第 i 个观测数据对回归系数的"影响力"或"杠杠作用"(leverage)可通过投影矩阵 $P \equiv X(X'X)^{-1}X'$ 的第 i 个主对角线元素来表示:

$$\operatorname{lev}_i \equiv \boldsymbol{x}_i' (\boldsymbol{X}' \boldsymbol{X})^{-1} \boldsymbol{x}_i$$

所有观测数据的影响力lev,满足:

- (i) $0 \le \text{lev}_i \le 1$, $(i = 1, \dots, n)$;
- (ii) $\sum_{i=1}^{n} \text{lev}_i = K(解释变量个数)。影响力lev_i的平均值为(K/n)。$

记 $b^{(i)}$ 为去掉第i个观测数据后的OLS估计值,可以证明:

$$\boldsymbol{b} - \boldsymbol{b}^{(i)} = \left(\frac{1}{1 - \text{lev}_i}\right) (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{x}_i e_i$$

 lev_i 越大则 $(\boldsymbol{b}-\boldsymbol{b}^{(i)})$ 的变化越大。

如果 lev_i 比平均值(K/n)高很多,则可能对回归系数有很大影响。

如何处理极端观测值:

首先,应检查是否因数据输入有误导致极端观测值。

其次,对出现极端观测值的个体进行背景调查,看看是否由与研究课题无关的特殊现象所致,必要时可以删除极端数据。

最后,可同时汇报"全样本"(full sample)与删除极端数据后的"子样本"(subsample)的回归结果,让读者自己做判断。

9.8 虚拟变量

对于"定性数据"(qualitative data)或"分类数据"(categorical data),需引入"虚拟变量",即取值为 0 或 1 的变量。

比如,性别分男女,可定义
$$D = \begin{cases} 1, & \mathbb{R} \\ 0, & \mathbf{y} \end{cases}$$

对于全球的五大洲,则需要四个虚拟变量,即

$$D_1 = \begin{cases} 1, & \text{Asia} \\ 0, & \text{other} \end{cases}, \qquad D_2 = \begin{cases} 1, & \text{America} \\ 0, & \text{other} \end{cases}, \qquad D_3 = \begin{cases} 1, & \text{Europe} \\ 0, & \text{other} \end{cases}$$

$$D_4 = \begin{cases} 1, & \text{Africa} \\ 0, & \text{other} \end{cases}$$

如果 $D_1 = D_2 = D_3 = D_4 = 0$, 则表明为大洋洲。

在有常数项的模型中,如定性指标分M类,最多只能有(M-1)个虚拟变量。

如果引入M个虚拟变量,会产生严格多重共线性,因为如果将这M个虚拟变量对应的列向量相加,就得到常数项。

这种情况称为"虚拟变量陷阱"(dummy variable trap)。

Stata 会自动识别严格多重共线性,这种担心已不重要。

如果模型中没有常数项,可以有M个虚拟变量。

在模型中引入虚拟变量,会带来什么影响呢?

考虑一个有关中国经济的时间序列模型:

$$y_{t} = \alpha + \beta x_{t} + \varepsilon_{t}, \quad t = 1950, \dots, 2000$$

由于经济结构可能在1978年后有变化,引入虚拟变量:

$$D = \begin{cases} 1, & \text{若 } t \ge 1978 \\ 0, & \text{其他} \end{cases}$$

考虑以下两种情况。

(1) 仅仅引入虚拟变量本身

$$y_t = \alpha + \beta x_t + \gamma D_t + \varepsilon_t$$

该模型等价于

$$y_{t} = \begin{cases} \alpha + \beta x_{t} + \varepsilon_{t}, & \text{若} t < 1978 \\ (\alpha + \gamma) + \beta x_{t} + \varepsilon_{t}, & \text{若} t \geq 1978 \end{cases}$$

仅引入虚拟变量,相当于在不同时期使用不同的截距项。

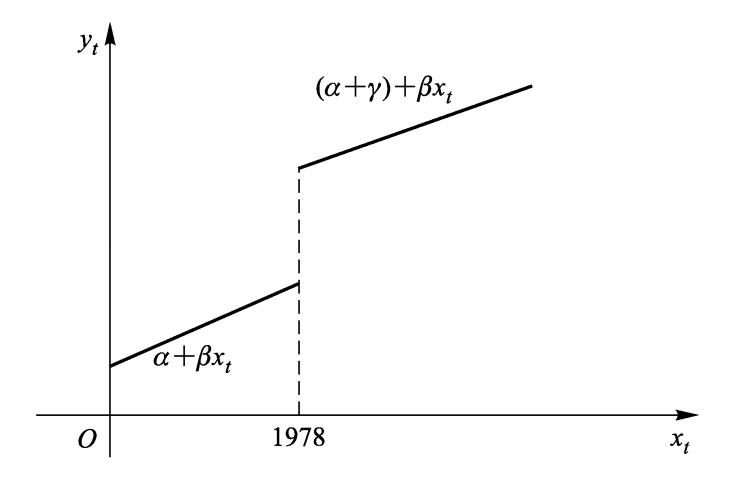


图 9.2 仅引入虚拟变量的效果

(2) 引入虚拟变量,以及虚拟变量与解释变量的"互动项" (interaction term):

$$y_{t} = \alpha + \beta x_{t} + \gamma D_{t} + \delta D_{t} x_{t} + \varepsilon_{t}$$

该模型等价于

$$y_{t} = \begin{cases} \alpha + \beta x_{t} + \varepsilon_{t}, & \text{ if } t < 1978 \\ (\alpha + \gamma) + (\beta + \delta)x_{t} + \varepsilon_{t}, & \text{ if } t \geq 1978 \end{cases}$$

引入虚拟变量及其互动项相当于,在不同时期使用不同的截距项与斜率。

如果仅仅引入互动项,则仅改变斜率。

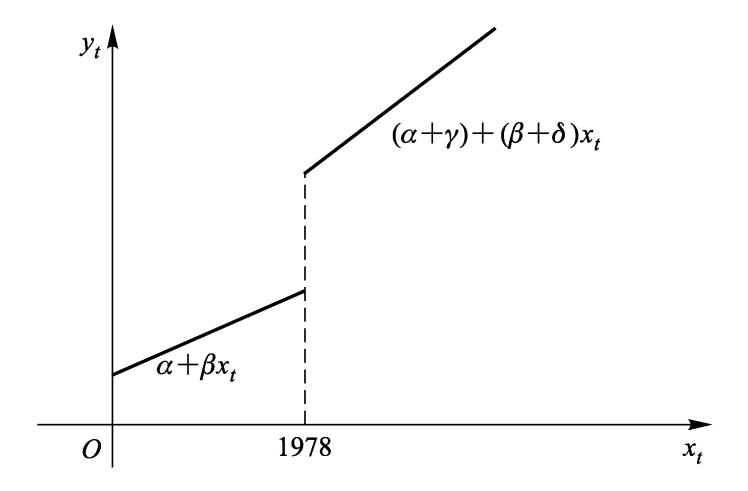


图 9.3 引入虚拟变量及其互动项的效果

9.9 经济结构变动的检验

1. 结构变动日期已知

如果存在"结构变动"(structural break),但未加考虑,也是一种模型设定误差。

首先考虑结构变动日期已知的情形。

假设要检验中国经济是否在1978年发生结构变动。

定义第 1 个时期为1950 $\leq t <$ 1978,第 2 个时期为1978 $\leq t \leq$ 2000,

两个时期对应的回归方程可以分别记为

$$\mathbf{y}^1 = \mathbf{X}^1 \boldsymbol{\beta}^1 + \boldsymbol{\varepsilon}^1$$

$$y^2 = X^2 \beta^2 + \varepsilon^2$$

需要检验的原假设为,经济结构没有变化,即 $H_0: \boldsymbol{\beta}^1 = \boldsymbol{\beta}^2$ 。

假设有K个解释变量,则 H_0 共有K个约束。

在无约束的情况下,可对两个时期分别进行回归。

在有约束(即 H_0 成立)的情况下,可将模型合并为

$$y = X\beta + \varepsilon$$

其中, $\mathbf{y} = \begin{pmatrix} \mathbf{y}^1 \\ \mathbf{y}^2 \end{pmatrix}$, $\mathbf{X} = \begin{pmatrix} \mathbf{X}^1 \\ \mathbf{X}^2 \end{pmatrix}$, $\boldsymbol{\varepsilon} = \begin{pmatrix} \boldsymbol{\varepsilon}^1 \\ \boldsymbol{\varepsilon}^2 \end{pmatrix}$ 。可将所有样本数据合在一起回归。

传统的"邹检验"(Chow, 1960):

首先,回归整个样本1950 $\leq t \leq 2000$,得到残差平方和e'e。

其次,回归第 1 部分子样本1950 $\leq t <$ 1978,得到残差平方和 $e_1'e_1$ 。

最后,回归第 2 部分子样本1978 $\leq t \leq 2000$,得到残差平方和 $e_2'e_2$ 。

 $e'e \ge e'_1e_1 + e'_2e_2$,因为将整个样本一起回归为"有约束 OLS",而将样本一分为二为"无约束 OLS",故前者的拟合优度比后者更差。

如果 H_0 成立,则 $(e'e-e'_1e_1-e'_2e_2)$ 应该比较小。

如果 $(e'e - e'_1e_1 - e'_2e_2)$ 很大,倾向于认为 H_0 不成立,存在结构变动。

由于约束条件共有 K 个,而无约束回归的解释变量个数为 2K ,故根据似然比检验原理的 F 统计量为

$$F = \frac{(e'e - e'_1e_1 - e'_2e_2)/K}{(e'_1e_1 + e'_2e_2)/(n - 2K)} \sim F(K, n - 2K)$$

其中,n为样本容量,K为回归方程中解释变量的个数(含截距项)。

检验结构变动的另一简便方法是引入虚拟变量,并检验所有虚拟变量以及其与解释变量交叉项的系数的联合显著性。

进行如下回归:

$$y_{t} = \alpha + \beta x_{t} + \gamma D_{t} + \delta D_{t} x_{t} + \varepsilon_{t}$$

然后检验 " $H_0: \gamma = \delta = 0$ "。此

此检验的F统计量与传统的邹检验完全相同,二者等价。

虚拟变量法的优点:

(1)只需生成虚拟变量即可检验,十分方便;

- (2) 邹检验在同方差假设下得到,不适用于条件异方差的情形。 在条件异方差的情况下,仍可使用虚拟变量法,只要使用异方差 稳健的标准误即可。
- (3) 如发现存在结构变动, 邹检验并不提供究竟是截距项还是斜率变动的信息, 而虚拟变量法可提供这些信息。

2. 结构变动日期未知

假设不知道结构变动的具体时间。比如,也许不能肯定结构变动一定发生在1978年。

选择一个区间[τ_0 , τ_1] \subseteq [1, T] (无法检验过于靠近端点的位置), 其中 T 为样本容量,而 1950 年对应于第 1 年。

计算在此区间中的每一年份 $t(\tau_0 \le t \le \tau_1)$ 所对应的 F 统计量,然后取其最大者。此统计量称为"匡特似然比"(Quandt Likelihood Ratio,简记 QLR),是邹统计量的推广。

QLR 统计量不再服从 F 分布,其分布取决于约束条件的个数,以及 (τ_0/T) 与 (τ_1/T) 。

如果 τ_0 太接近于 1,或 τ_1 太接近于 T,则 QLR 统计量的渐近分布对有限样本分布的近似将变得不准确。

通常选择 $\tau_0 = 0.15T$, $\tau_1 = 0.85T$ (选择最接近的整数),称为"15% 修边"(15% trimming)。

表 9.1 QLR 统计量临界值表(15%修边)

			=
约束条件个数	10%	5%	1%
1	7.12	8.68	12.16
2	5.00	5.86	7.78
3	4.09	4.71	6.02
4	3.59	4.09	5.12
5	3.26	3.66	4.53
6	3.02	3.37	4.12
7	2.84	3.15	3.82
8	2.69	2.98	3.57
9	2.58	2.84	3.38
10	2.48	2.71	3.23
11	2.40	2.62	3.09
12	2.33	2.54	2.97

13	2.27	2.46	2.87
14	2.21	2.40	2.78
15	2.16	2.34	2.71
16	2.12	2.29	2.64
17	2.08	2.25	2.58
18	2.05	2.20	2.53
19	2.01	2.17	2.48
20	1.99	2.13	2.43

资料来源: Stock and Watson (2011), p.559, Table 14.6。

如果 QLR 统计量小于临界值,则接受"无结构变动"的原假设。反之,则认为发生了结构变动,而 F 统计量取最大值的那个日期 \hat{r} 就是对结构变动日期(break date) τ 的一致估计。

9.10 缺失数据与线性插值

在数据缺失不严重的情况下,为了保持样本容量,可采用"线性插值"(linear interpolation)的方法来补上缺失数据。

考虑最简单的情形。已知 x_{t-1} 与 x_{t+1} ,但缺失 x_t 的数据,则 x_t 对时间 t 的线性插值为

$$\hat{x}_{t} = \frac{x_{t-1} + x_{t+1}}{2}$$

一般地,假设与x(通常为时间)对应的y缺失,而最临近的两个点分别为 (x_0,y_0) 与 (x_1,y_1) ,且 $x_0 < x < x_1$,则y对x的线性插值为

$$\hat{y} = \frac{y_1 - y_0}{x_1 - x_0} (x - x_0) + y_0$$

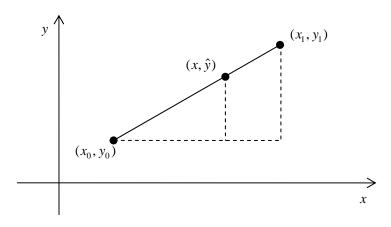


图 9.5 线性插值示意图

如果变量 y 有指数增长趋势(比如 GDP),则应先取对数,再用 ln y 进行线性插值,以避免偏差。

如果需要以原变量 y 进行回归,可将线性插值的对数值 $\ln \hat{y}$ 再取 反对数(antilog),即计算 $\exp(\ln \hat{y})$ 。

9.11 变量单位的选择

在选择变量单位时,应尽量避免变量间的数量级差别过于悬殊,以免出现计算机运算的较大误差。

比如,通货膨胀率通常小于1,而如果模型中有GDP这个变量,则GDP应该使用亿或万亿作为单位。

否则,变量 GDP 的取值将是通货膨胀率的很多倍,即数据矩阵 X 中某列的数值是另一列的很多倍,这可能使计算机在对 $(XX)^{-1}$ 进行数值计算时出现较大误差。