© 陈强,《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

第12章 多值选择模型

12.1 多项 Logit 与多项 Probit

假设可供个体选择的方案为y=1,2,...,J,其中J为正整数。

个体i选择方案j的效用为

$$U_{ij} = \mathbf{x}_i' \boldsymbol{\beta}_j + \varepsilon_{ij} \quad (i = 1, \dots, n; \ j = 1, \dots, J)$$

解释变量 x_i 只随个体i而变,不随方案j而变(比如,个体的性

别、年龄、收入等特征),称为"只随个体而变"(case-specific)或"不随方案而变"(alternative-invariant)。

系数 β_j 表明, x_i 对效用 U_{ij} 的作用取决于方案j。

个体i选择方案j,当且仅当方案j的效用高于所有其他方案:

$$P(y_{i} = j \mid \mathbf{x}_{i}) = P(U_{ij} \geq U_{ik}, \forall k \neq j)$$

$$= P(U_{ik} - U_{ij} \leq 0, \forall k \neq j)$$

$$= P(\varepsilon_{ik} - \varepsilon_{ij} \leq \mathbf{x}_{i}' \boldsymbol{\beta}_{j} - \mathbf{x}_{i}' \boldsymbol{\beta}_{k}, \forall k \neq j)$$

假设 $\{\varepsilon_{ij}\}$ 为 iid 且服从 I 型极值分布(type I extreme value

distribution), 可证明:

$$P(y_i = j \mid \mathbf{x}_i) = \frac{\exp(\mathbf{x}_i' \boldsymbol{\beta}_j)}{\sum_{k=1}^{J} \exp(\mathbf{x}_i' \boldsymbol{\beta}_k)}$$

选择各方案的概率之和为 1,即 $\sum_{j=1}^{J} P(y_i = j | \mathbf{x}_i) = 1$ 。

这是二值选择 Logit 模型向多值选择模型的推广。

无法同时识别所有的系数 β_k , $k=1,\dots,J$ 。

如将 $\boldsymbol{\beta}_k$ 变为 $\boldsymbol{\beta}_k^* = \boldsymbol{\beta}_k + \boldsymbol{\alpha} \ (\boldsymbol{\alpha}$ 为常数向量),不影响模型拟合。

通常将某方案(比如,方案 1)作为"参照方案"(base category),令相应系数 $\beta_1 = 0$,可得

$$P(y_i = j \mid \boldsymbol{x}_i) = \begin{cases} \frac{1}{1 + \sum_{k=2}^{J} \exp(\boldsymbol{x}_i' \boldsymbol{\beta}_k)} & (j = 1) \\ \frac{\exp(\boldsymbol{x}_i' \boldsymbol{\beta}_j)}{1 + \sum_{k=2}^{J} \exp(\boldsymbol{x}_i' \boldsymbol{\beta}_k)} & (j = 2, \dots, J) \end{cases}$$

"j=1"所对应的方案为参照方案。

此模型为"多项 logit" (multinomial logit),可用 MLE 估计。

个体i的似然函数为

$$L_i(\boldsymbol{\beta}_1, \dots, \boldsymbol{\beta}_J) = \prod_{j=1}^J \left[P(y_i = j \mid \boldsymbol{x}_i) \right]^{I(y_i = j)}$$

其对数似然函数为

$$\ln L_i(\boldsymbol{\beta}_1, \dots, \boldsymbol{\beta}_J) = \sum_{i=1}^J \boldsymbol{I}(y_i = j) \cdot \ln P(y_i = j \mid \boldsymbol{x}_i)$$

如果假设 $\{\varepsilon_{i1},\dots,\varepsilon_{iJ}\}$ 服从J维正态分布,则可得"多项 probit" (multinomial probit)模型,但涉及高维积分,不易计算。

12.2 条件 Logit 模型

有些解释变量既随个体而变, 也随方案而变。

比如,在选择交通工具时,乘车时间既因个体而异(不同个体的行车路线可能不同),也因交通工具而异(坐公交的时间与乘出租车的时间不同)。

这种解释变量称为"随方案而变"(alternative-specific),既包括同时随方案与个体而变的变量,也包括随方案而变但不随个体而变的变量(比如,选择加入某协会时,所有人交的会费都一样)。

个体i选择方案j的效用:

$$U_{ij} = \mathbf{x}'_{ij}\boldsymbol{\beta} + \varepsilon_{ij} \quad (i = 1, \dots, n; \ j = 1, \dots, J)$$

解释变量 x_{ii} 既随个体i而变,也随方案j而变。

系数 β 表明, x_{ij} 对效用 U_{ij} 的作用不依赖于方案j,比如乘车时间依个体与方案而变,但乘车时间太长所带来的负效用是一致的。

个体 i 选择方案 j 的概率:

$$P(y_i = j \mid \boldsymbol{x}_{ij}) = \frac{\exp(\boldsymbol{x}'_{ij}\boldsymbol{\beta})}{\sum_{k=1}^{J} \exp(\boldsymbol{x}'_{ik}\boldsymbol{\beta})}$$

此模型称为"条件 logit"(conditional logit), 也称为"McFadden 选择模型" (McFadden's choice model)。

条件 Logit 模型的估计方法与多项 Logit 模型类似。

不同的是,在条件 Logit 模型中,由于系数 β 不依赖于方案,故不需要选择参照方案,也不需要将 β 的某部分标准化为0。

12.3 混合 Logit 模型

上面分别考虑了解释变量不随方案而变的多项 Logit 模型, 以及解释变量随方案而变的条件 Logit 模型。

考虑这两种情况同时发生的混合情形。

假设个体i选择方案j的效用:

$$U_{ij} = \mathbf{x}'_{ij}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\gamma}_{j} + \boldsymbol{\varepsilon}_{ij} \quad (i = 1, \dots, n; \ j = 1, \dots, J)$$

解释变量 x_{ii} 既随个体i而变,也随方案j而变;解释变量 z_{i} 只

随个体i而变。个体i选择方案j的概率:

$$P(y_i = j \mid \boldsymbol{x}_{ij}, \boldsymbol{z}_i) = \frac{\exp(\boldsymbol{x}'_{ij}\boldsymbol{\beta} + \boldsymbol{z}'_{i}\boldsymbol{\gamma}_j)}{\sum_{k=1}^{J} \exp(\boldsymbol{x}'_{ik}\boldsymbol{\beta} + \boldsymbol{z}'_{i}\boldsymbol{\gamma}_k)}$$

在文献中称为"混合Logit"(mixed logit), Stata 仍称为条件Logit。

为识别该模型,也需选择一个参照方案(比如方案 1), $\Diamond \gamma_1 = 0$ 。

在多值选择模型中,被解释变量必然为"多项分布"(multinomial distribution),故一般不必使用稳健标准误,使用普通标准误即可;这一点类似于二值选择模型。

如果数据为聚类样本,则应使用聚类稳健的标准误。

在多项 Logit 与混合 Logit 模型中, 对参数估计值 $\hat{\pmb{\beta}}_j$ 的解释以参照方案为转移。

以多项 Logit 为例,假设"方案 1"或"方案 j" ($j \neq 1$)必然发生(二者必居其一),则在此条件下,"方案 j" 发生的条件概率为

$$P(y = j | y = 1 \text{ or } j) = \frac{P(y = j)}{P(y = 1) + P(y = j)} = \frac{\exp(x_i' \beta_j)}{1 + \exp(x_i' \beta_j)}$$

上式与二值 Logit 具有完全相同的形式。

"几率比" (odds ratio)或"相对风险" (relative risk)为

$$\frac{P(y=j)}{P(y=1)} = \exp(\mathbf{x}_i' \boldsymbol{\beta}_j)$$

对数几率比(log-odds ratio)为

$$\ln\left[\frac{P(y=j)}{P(y=1)}\right] = \mathbf{x}_i' \boldsymbol{\beta}_j$$

该条件概率不依赖于任何其他方案。如果将多值选择模型中的 任何两个方案单独挑出来,都是二值 logit 模型。 此假定称为"无关方案的独立性"(Independence of Irrelevant Alternatives, 简记 IIA)。

类似地,条件 logit 模型也服从 IIA 假定。

在实践中,如果不同方案之间很类似,则 IIA 假设不一定满足。 这是多项 Logit、条件 logit 与混合 Logit 模型的共同缺点。

比如,假设共有三个备选的交通方式,即自驾车、乘红色公共汽车(red bus)、乘蓝色公共汽车(blue bus)。

根据"无关选择的独立性"假定,在给定选择"自驾车"或"乘红色公共汽车"条件下,选择"自驾车"的条件概率与是否存在

"乘蓝色公共汽车"的选择无关。

由于"蓝色公共汽车"与"红色公共汽车"仅颜色不同,故加上"蓝色公共汽车"的选择之后,对"自驾车"概率没有影响,但将使"红色公共汽车"概率降低一半。

因此,引入"蓝色公共汽车"后,上述条件概率将增大,与"无关选择的独立性"假定相矛盾。称为"红车蓝车问题"(red bus-blue bus problem)。

对于 IIA 假定, 检验方法之一为豪斯曼检验。

如果 IIA 假定成立,则去掉某个方案不影响对其他方案参数的一致估计,只是降低效率。

故在 IIA 成立情况下,去掉某个方案后子样本的系数估计值(记为 $\hat{\beta}_{\scriptscriptstyle E}$)与全样本的系数估计值(记为 $\hat{\beta}_{\scriptscriptstyle E}$)没有系统差别。

Hausman and McFadden (1984)提出统计量:

$$(\hat{\boldsymbol{\beta}}_R - \hat{\boldsymbol{\beta}}_F)' \left[\widehat{\operatorname{Var}(\hat{\boldsymbol{\beta}}_R)} - \widehat{\operatorname{Var}(\hat{\boldsymbol{\beta}}_F)} \right]^{-1} (\hat{\boldsymbol{\beta}}_R - \hat{\boldsymbol{\beta}}_F)' \xrightarrow{d} \chi^2(m)$$

其中,m等于 $\hat{\beta}_R$ 的维度。

检验 IIA 假定的方法之二为 Small and Hsiao (1985)所提出。

Cheng and Long (2007)通过蒙特卡罗方法发现,这两个检验的小样本性质都不好,结论只有参考价值)。

12.4 嵌套 Logit

多项 Logit、条件 Logit 与混合 Logit 都须满足 IIA 假定。在实践中,如果方案比较类似,则 IIA 假设可能不满足。

解决方法之一是,把相似的方案归入一组,允许同组内的方案相关,但不同组的方案相互独立。

比如,在交通工具的选择上,可把"公交车、地铁"归入"公共交通组",而把"自驾车、出租车"归入"私人交通组",形成嵌套式(nested)的树形结构。

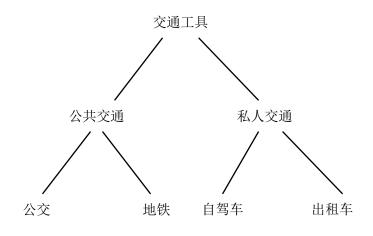


图 12.1 嵌套 Logit 的树形结构

图 12.1 中的"交通工具"可视为此树形结构的"根部"(root),第一层(level 1)的"公共交通、私人交通"为"树干"(limb),而第二层(level 2)的"公交、地铁、自驾车、出租车"为"树枝"(branch)。

可将此树形结构视为"决策树"(decision tree),但关键在于它的统计性质,即在第二层的每组内部允许扰动项相关,比如 $(\varepsilon_{i,bus}, \varepsilon_{i,subway})$ 相关, $(\varepsilon_{i,car}, \varepsilon_{i,taxi})$ 相关;但这两组之间不相关,即 $(\varepsilon_{i,bus}, \varepsilon_{i,subway})$ 与 $(\varepsilon_{i,car}, \varepsilon_{i,taxi})$ 不相关。

如果所有方案的扰动项都互不相关,则回到多项 logit 或条件 logit 的情形。

更一般地,假设在第一层共有J个树干备选,而树干j包含 K_j 个树枝(不同树干包含的树枝数可以不同),分别以j1,…,jK $_j$ 来指代。个体i选择树干j树枝k方案的效用为(略去个体i下标)

$$U_{jk} = \mathbf{x}'_{jk}\boldsymbol{\beta} + \mathbf{z}'_{j}\boldsymbol{\gamma}_{j} + \boldsymbol{\varepsilon}_{jk} \quad (j = 1, \dots, J; k = 1, \dots, K)$$

其中,解释变量 z_j 只随树干而不随树枝方案而变(故其系数 γ_j 可随 j 而变),而 x_{jk} 同时随树干与树枝方案而变(故其系数 β 没有下标,不随 j,k 而变)。

McFadden (1978) 假定扰动项 ε_{jk} 服从"广义极值分布" (Generalized Extreme Value distribution,简记GEV),其cdf为

$$F(\varepsilon) = \exp\left[-G(e^{-\varepsilon_{11}}, \dots, e^{-\varepsilon_{1K_1}}; \dots; e^{-\varepsilon_{J1}}, \dots, e^{-\varepsilon_{JK_J}})\right]$$

其中,函数 $G(\cdot)$ 的形式为

$$G(\mathbf{w}) = G(w_{11}, \dots, w_{1K_1}; \dots; w_{J1}, \dots, w_{JK_J}) = \sum_{j=1}^{J} \left(\sum_{k=1}^{K_j} w_{jk}^{1/\tau_j} \right)^{\tau_j}$$

上式右边的 $\left(\sum_{k=1}^{K_j} w_{jk}^{1/\tau_j}\right)^{\tau_j}$, 在形式上为不变替代弹性函数

(Constant Elasticity of Substitution, CES).

参数 $\tau_j = \sqrt{1-\text{Corr}(\varepsilon_{jk}, \varepsilon_{jl})}$,与 $(\varepsilon_{jk}, \varepsilon_{jl})$ 的相关系数呈反向变动的关系,称为"不相似参数" (dissimilarity parameter),在 Stata 中记为 tau。 $0 \le \tau_i \le 1$ 。

如果 $\tau_j = 1$ ($j = 1, \dots, J$),则所有方案的扰动项均不相关,满足 IIA 假定,回到多项 logit、条件 logit 或混合 logit 的情形。

选择树干j树枝k方案的概率为:

$$p_{jk} = p_j \times p_{k|j} = \frac{\exp(\mathbf{z}_j' \mathbf{y} + \tau_j \mathbf{I}_j)}{\sum_{m=1}^{J} \exp(\mathbf{z}_m' \mathbf{y} + \tau_m \mathbf{I}_m)} \times \frac{\exp(\mathbf{x}_{jk}' \mathbf{\beta}_j / \tau_j)}{\sum_{l=1}^{K_j} \exp(\mathbf{x}_{jl}' \mathbf{\beta}_j / \tau_j)}$$

其中, p_j 为选择树干j的概率, $p_{k|j}$ 为在选择树干j的情况下,选择树枝k的条件概率;而 I_i 的定义为

$$I_{j} \equiv \ln \left[\sum_{l=1}^{K_{j}} \exp(\mathbf{x}_{jl}' \boldsymbol{\beta}_{j} / \tau_{j}) \right]$$

其中, I_i 称为"包含价值"(inclusive value)或"对数和"(log-sum)。

根据此式写出整个样本的对数似然函数,称为"全信息最大似然估计"(Full Information Maximum Likelihood,简记 FIML)。

另一方法为分步对 p_j 与 $p_{k|j}$ 进行 MLE 估计,称为"有限信息最大似然估计"(Limited Information Maximum Likelihood,简记LIML),但不如 FIML 有效率。

进行 FIML 估计后,可对联合假设 " H_0 : $\tau_1 = \cdots = \tau_J = 1$ " 进行 似然比检验。

如果接受原假设,则 IIA 假定成立,不需要使用嵌套 logit,可直接使用多项 logit、条件 logit 或混合 logit 模型。