# 第13章 排序与计数模型

#### 13.1 排序模型

有些离散数据有天然的排序。比如,公司债券的评级(AAA, AA, A, B, C级);对"春节联欢晚会"的满意度(很满意、满意、不满意、很不满意);

Li and Zhou(2005)研究经济增长绩效对地方官员仕途的影响,以0表示"卸任",1表示"留任或平级调动",2表示"提拔"。

这种数据称为"排序数据"(ordered data)。

如使用 multinomial logit,将无视数据内在的排序,而 OLS 又把排序视为基数来处理。

可用潜变量法推导 MLE 估计量。

假设 $y^* = x'\beta + \varepsilon(y^*$ 不可观测),而选择规则为

$$y = \begin{cases} 0, & \text{若 } y^* \le r_0 \\ 1, & \text{若 } r_0 < y^* \le r_1 \\ 2, & \text{若 } r_1 < y^* \le r_2 \\ & \dots \\ J, & \text{若 } r_{J-1} \le y^* \end{cases}$$

 $r_0 < r_1 < r_2 < \dots < r_{J-1}$ 为待估参数,称为"切点"(cutoff points)。

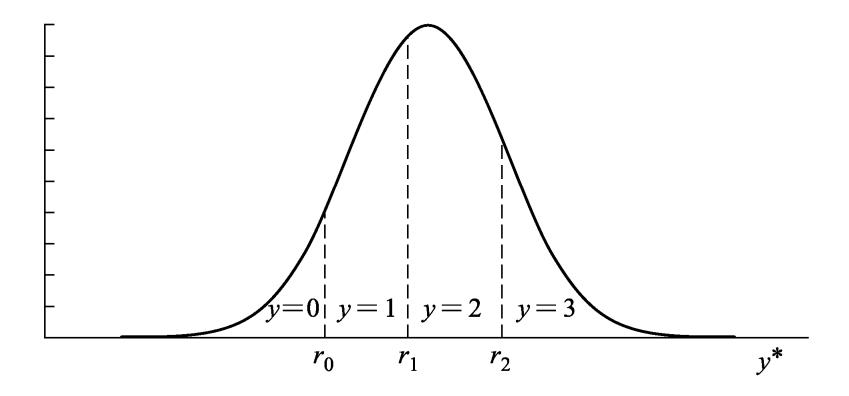


图 13.1 ordered logit 示意图

## 假设 $\varepsilon \sim N(0,1)$ (将扰动项 $\varepsilon$ 的方差标准化为1),则

$$P(y = 0 \mid \boldsymbol{x}) = P(y^* \le r_0 \mid \boldsymbol{x}) = P(\boldsymbol{x}'\boldsymbol{\beta} + \varepsilon \le r_0 \mid \boldsymbol{x})$$
$$= P(\varepsilon \le r_0 - \boldsymbol{x}'\boldsymbol{\beta} \mid \boldsymbol{x}) = \Phi(r_0 - \boldsymbol{x}'\boldsymbol{\beta})$$

$$P(y=1|\mathbf{x}) = P(r_0 < y^* \le r_1 | \mathbf{x})$$

$$= P(y^* \le r_1 | \mathbf{x}) - P(y^* < r_0 | \mathbf{x})$$

$$= P(\mathbf{x}'\boldsymbol{\beta} + \varepsilon \le r_1 | \mathbf{x}) - \Phi(r_0 - \mathbf{x}'\boldsymbol{\beta})$$

$$= P(\varepsilon \le r_1 - \mathbf{x}'\boldsymbol{\beta} | \mathbf{x}) - \Phi(r_0 - \mathbf{x}'\boldsymbol{\beta})$$

$$= \Phi(r_1 - \mathbf{x}'\boldsymbol{\beta}) - \Phi(r_0 - \mathbf{x}'\boldsymbol{\beta})$$

$$P(y = 2 | x) = \Phi(r_2 - x'\beta) - \Phi(r_1 - x'\beta)$$
.....
$$P(y = J | x) = 1 - \Phi(r_{J-1} - x'\beta)$$

写出样本似然函数,可得 MLE 估计量,即 ordered probit 模型。 如果假设扰动项服从逻辑分布,则为 ordered logit 模型。

#### 13.2 泊松回归

有些被解释变量只能取非负整数,即0,1,2,…。

比如,专利个数、奥运金牌个数、子女人数、看病次数。

对于这一类计数数据(count data),常使用"泊松回归"(Poisson regression)。

对于个体 i,记被解释变量为 $Y_i$ ,假设 $Y_i = y_i$ 的概率由参数为 $\lambda_i$ 的 泊松分布决定:

$$P(Y_i = y_i | \mathbf{x}_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!} \quad (y_i = 0, 1, 2, \dots)$$

 $\lambda_i > 0$ 为"泊松到达率",表示事件发生的平均次数,由解释变量  $x_i$ 所决定。

泊 松 分 布 的 期 望 与 方 差 都 等 于 泊 松 到 达 率 , 即  $E(Y_i | x_i) = Var(Y_i | x_i) = \lambda_i$ 。

为保证 $\lambda_i$ 非负,假设 $Y_i$ 的"条件期望函数"为

$$E(Y_i \mid \boldsymbol{x}_i) = \lambda_i = \exp(\boldsymbol{x}_i'\boldsymbol{\beta})$$

假定样本 iid,则似然函数为

$$L(\boldsymbol{\beta}) = \frac{\exp(-\sum_{i=1}^{n} \lambda_i) \cdot \prod_{i=1}^{n} \lambda_i^{y_i}}{\prod_{i=1}^{n} y_i!}$$

对数似然函数为

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^{n} \left[ -\lambda_i + y_i \ln \lambda_i - \ln(y_i!) \right]$$
$$= \sum_{i=1}^{n} \left[ -\exp(\boldsymbol{x}_i'\boldsymbol{\beta}) + y_i \boldsymbol{x}_i'\boldsymbol{\beta} - \ln(y_i!) \right]$$

#### 最大化的一阶条件为

$$\sum_{i=1}^{n} [y_i - \exp(x_i' \boldsymbol{\beta})] x_i = \boldsymbol{0}$$

根据 MLE 理论,如果似然函数正确,则 $\hat{\pmb{\beta}}_{\text{MLE}}$ 为一致估计量。

即使似然函数不正确,由于泊松分布属于线性指数分布族,故只要条件期望函数 $\lambda_i = \exp(x_i'\boldsymbol{\beta})$ 正确,则 $\hat{\boldsymbol{\beta}}_{OMLE}$ 就是一致的。

如果似然函数不正确,则常规的标准误(比如,OIM 或 BHHH 法)不是真实标准误的一致估计量,必须使用在 QMLE 基础上计算的稳健标准误,它对于似然函数是否正确比较稳健。

$$\hat{\boldsymbol{\beta}}_{\text{MLE}}$$
不表示边际效应。由于 $\ln \lambda_i = \boldsymbol{x}_i' \boldsymbol{\beta}$ ,故 $\frac{\partial \ln \lambda_i}{\partial x_k} = \boldsymbol{\beta}_k$ 。

可将 $\beta_k$ 解释为"半弹性"(semi-elasticity),即当解释变量 $x_k$ 增加微小量时,事件的平均发生次数将增加多少百分点。

由于泊松到达率 $\lambda_i = \exp(\mathbf{x}_i'\boldsymbol{\beta})$ ,故也可计算 $\exp(\beta_k)$ ,称为"发生率比" (Incidence Rate Ratio,简记 IRR)

IRR 表示,当 $x_k$ 增加一单位时(从 $x_k$ 增加到 $x_k$ +1),事件的平均发生次数将是原来的多少倍,因为

$$\exp[(x_k + 1)\beta_k] / \exp(x_k \beta_k) = \exp(\beta_k)$$

泊松分布描述, 在给定时间内某观测单位的事件发生次数。

如果观测时间变长,或观测单位的空间规模变大,则事件发生的平均次数也应同比例增多。

记个体i在单位时间内事件发生的平均次数为¢。

如果不同个体的时间或空间规模不同,记为 $T_i$ ,称为"暴露期" (exposure),则该事件发生的平均次数也须相应调整为 $\phi_i T_i$ 。

比如,考察某疾病在不同城市的发病人数,而各城市的人口基数不同:

$$P(Y_i = y_i \mid \mathbf{x}_i, T_i) = \frac{e^{-\phi_i T_i} (\phi_i T_i)^{y_i}}{y_i!} \quad (y_i = 0, 1, 2, \dots)$$

假设 $\phi_i = \exp(\mathbf{x}_i'\boldsymbol{\beta})$ 。在上式中,令 $\lambda_i \equiv \phi_i T_i$ ,则 $\ln \lambda_i = \mathbf{x}_i'\boldsymbol{\beta} + \ln T_i$ 。

如果暴露期 $T_i$ 随i而变,应把 $\ln T_i$ 作为解释变量放入泊松回归,并且令其系数为 1。

#### 13.3 负二项回归

泊松分布的期望与方差一定相等,称为"均等分散" (equidispersion);此特征常与实际数据不符。

如果被解释变量的方差明显大于期望,即存在"过度分散" (overdispersion)。

在条件期望函数的对数表达式中加入一项:

$$\ln \lambda_i = \boldsymbol{x}_i' \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i$$

 $\varepsilon_i$ 表示不可观测部分或个体的异质性。可得:

$$\lambda_i = \exp(\mathbf{x}_i' \boldsymbol{\beta}) \cdot \exp(\varepsilon_i) \equiv u_i v_i$$

 $u_i \equiv \exp(\mathbf{x}_i'\boldsymbol{\beta})$ 为 $\mathbf{x}_i$ 的确定性函数,而 $v_i \equiv \exp(\varepsilon_i) > 0$ 为随机变量。

给定 $x_i$ 与 $v_i$ ,则 $y_i$ 依然服从泊松分布:

$$P(Y_i = y_i \mid \mathbf{x}_i, v_i) = \frac{e^{-u_i v_i} (u_i v_i)^{y_i}}{y_i!} \quad (y_i = 0, 1, 2, \dots)$$

由于v,不可观测,无法对此方程进行估计。

记 $v_i$ 的概率密度函数为 $g(v_i)$ ,可将 $v_i$ 积分掉,计算 $y_i$ 的边缘密度:

$$P(Y_i = y_i \mid \mathbf{x}_i) = \int_0^\infty \frac{e^{-u_i v_i} (u_i v_i)^{y_i}}{y_i!} g(v_i) dv_i$$

由于 $v_i > 0$ ,通常选择 $v_i$ 服从 Gamma 分布(指数分布与卡方分布为 Gamma 分布的特例)。

假设 $v_i \sim \text{Gamma}(1/\alpha, \alpha)$ ,其中 $\alpha > 0$ 。

对于Gamma(a,b),期望为ab,方差为 $ab^2$ 。故 $E(v_i)=1$ ,而 $Var(v_i)=\alpha$ 。

代入 $Gamma(1/\alpha, \alpha)$ 的概率密度,可得负二项分布的概率密度,进行 MLE 估计, 称为"负二项回归"(negative binomial regression)。

有关负二项分布。

假设某事件在一次实验中成功的概率为 $\theta$  (0< $\theta$ <1)。

记Y为在第J次成功前失败的总次数,则Y的分布律为

$$P(Y = y | \theta, J) = C_{y+J-1}^{J-1} \theta^{J} (1-\theta)^{y} \quad (y = 0, 1, 2, \dots)$$

由于第(y+J)次一定为成功,故只要在前面的(y+J-1)次中找出成功的(J-1)次的组合次数即可。

负二项回归模型的条件期望仍为 $E(Y_i | x_i) = u_i = \exp(x_i' \beta)$ ,而条件方差为

$$Var(Y_i \mid \boldsymbol{x}_i) = u_i + \alpha u_i^2 > u_i = E(Y_i \mid \boldsymbol{x}_i)$$

条件方差的表达式包含条件期望 $u_i$ 的平方项,称为"NB2模型"。

进行负二项回归后,只要对原假设" $H_0$ :  $\alpha = 0$ "进行检验,即可确定应使用负二项回归还是泊松回归。

如果将Gamma( $1/\alpha$ ,  $\alpha$ )中的 $\alpha$ 换为 $\delta/u_i$ ,即假设  $v_i \sim \text{Gamma}(u_i/\delta, \delta/u_i)$ ,其中 $\delta > 0$ ,则条件方差函数变为:

$$Var(Y_i | x_i) = u_i + (\delta/u_i)u_i^2 = u_i + \delta u_i > u_i$$

条件方差为条件期望 $u_i$ 的一次函数,称为"NB1模型",是负二项回归的另一形式。

如果 $\delta \to 0$ ,则回到泊松回归的特例。Stata 会汇报对原假设"delta=0"的检验结果。

实践中,常使用 NB2 模型。

多数情况下,NB2模型更符合数据特点。

使用 NB2 模型的另一好处是,即使似然函数不正确,只要条件期望函数正确,则 $\hat{oldsymbol{eta}}_{ ext{OMLE}}$ 依然是一致估计,NB1 模型则无此优点。

在 NB2 负二项回归中,条件方差函数主要由参数α来刻画。

作为推广,可让此参数依个体i而变,记为 $\alpha_i$ ,并让 $\ln \alpha_i$ 依赖于变量 $z_i(z_i$ 可与 $x_i$ 重叠)。

然后使用 MLE 对条件均值方程与条件方差方程同时进行估计, 称为"广义负二项回归"(generalized negative binomial regression)。

究竟何时使用泊松回归或负二项回归?

即使数据中存在过度分散,"泊松回归+稳健标准误"依然提供了对参数及标准误的一致估计。

另一方面,如果比较了解条件方差函数,则"负二项回归+稳健标准误"可提供更有效率的估计。

如果研究者只关心参数 $\beta$ 的估计值,或许泊松回归就足够了;但如果希望预测"Y = y"的发生概率,则可考虑负二项回归。

另外,对" $H_0$ :  $\alpha = 0$ "的 LR 检验结果也提供了在泊松回归与 负二项回归之间选择的参考依据。

### 13.4 零膨胀泊松回归与负二项回归

如果计数数据中含有大量的"0"值,可考虑使用"零膨胀泊松回归"(Zero-inflated Poisson Regression,简记 ZIP)或"零膨胀负二项回归"(Zero-inflated Negative Binomial Regression,简记 ZINB)。

决策可能分两阶段进行。

首先,决定"取零"(无)或"取正整数"(有),相当于二值选择。

其次,如果决定"取正整数",进一步确定具体选择哪个正整数。

假定被解释变量 $y_i$ 服从以下"混合分布"(mixed distribution):

$$\begin{cases} P(y_i = 0 \mid \mathbf{x}_i) = \theta \\ P(y_i = j \mid \mathbf{x}_i) = \frac{(1 - \theta)e^{-\lambda_i} \lambda_i^j}{j!(1 - e^{-\lambda_i})} & (j = 1, 2, \dots) \end{cases}$$

 $\lambda_i = \exp(\mathbf{x}_i'\boldsymbol{\beta})$ ,而 $\theta > 0$ 与 $\boldsymbol{\beta}$ 为待估参数。

可以证明, 
$$\sum_{j=0}^{\infty} P(y_i = j \mid \mathbf{x}_i) = 1.$$

也可让 $\theta$ 依赖于解释变量 $z_i(z_i$ 可与 $x_i$ 重叠)。

使用 MLE 估计以上模型,即得到"零膨胀泊松回归"。

类似地,可以定义"零膨胀负二项回归"。

究竟应该使用标准的泊松回归(standard Poisson)还是零膨胀泊松回归(ZIP)?

Stata 提供了一个"Vuong 统计量"(Vuong, 1989), 其渐近分布为标准正态。

如果 Vuong 统计量很大(为正数),则应选择零膨胀泊松回归(或零膨胀负二项回归)。

反之,如果 Vuong 统计量很小(为负数),则应选择标准的泊松回归(或"标准的负二项回归")。