第14章 受限被解释变量

被解释变量的取值范围有时受限制,称为"受限被解释变量" (Limited Dependent Variable)。

14.1 断尾回归

对线性模型 $y_i = x_i' \beta + \varepsilon_i$,假设只有满足 $y_i \ge c$ 的数据才能观测到。

例: y_i 为所有企业的销售收入,而统计局只收集规模以上企业数据,比如 $y_i \ge 100,000$ 。被解释变量在 100,000 处存在"左边断尾"。

断尾随机变量的概率分布

随机变量 y 断尾后, 其概率密度随之变化。

记y的概率密度为f(y),在c处左边断尾后的条件密度函数为

由于概率密度曲线下面积为 1,故断尾变量的密度函数乘以因子 $\frac{1}{P(y>c)}$ 。

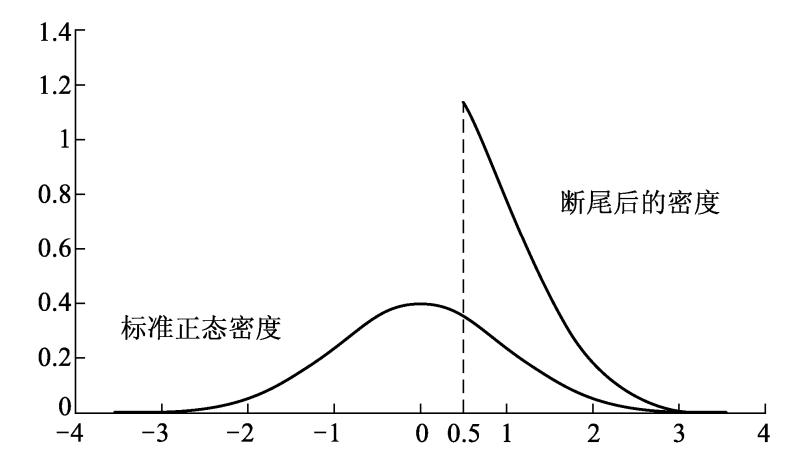


图 14.1 断尾的效果

断尾分布的期望也发生变化。以左边断尾为例。

对于最简单情形, $y \sim N(0,1)$,可证明(参见附录)

$$E(y \mid y > c) = \frac{\phi(c)}{1 - \Phi(c)}$$

对于任意实数 c,定义"反米尔斯比率"(Inverse Mill's Ratio,简记 IMR)为

$$\lambda(c) \equiv \frac{\phi(c)}{1 - \Phi(c)}$$

则 $E(y | y > c) = \lambda(c)$ 。

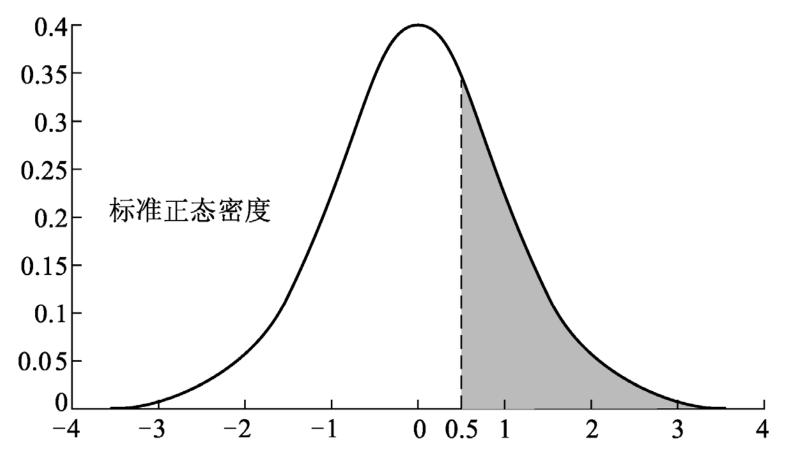


图 14.2 反米尔斯比率

对于正态分布 $y \sim N(\mu, \sigma^2)$, 定义 $z = \frac{y - \mu}{\sigma} \sim N(0, 1)$,则 $y = \mu + \sigma z$ 。故

$$E(y | y > c) = E(\mu + \sigma z | \mu + \sigma z > c) = E[\mu + \sigma z | z > (c - \mu)/\sigma]$$
$$= \mu + \sigma E[z | z > (c - \mu)/\sigma] = \mu + \sigma \cdot \lambda[(c - \mu)/\sigma]$$

对于模型 $y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i$, $\varepsilon_i \mid \mathbf{x}_i \sim N(0, \sigma^2)$, 则 $y_i \mid \mathbf{x}_i \sim N(\mathbf{x}_i' \boldsymbol{\beta}, \sigma^2)$, 故 $\mathrm{E}(y_i \mid y_i > c) = \mathbf{x}_i' \boldsymbol{\beta} + \sigma \cdot \lambda \left[(c - \mathbf{x}_i' \boldsymbol{\beta}) / \sigma \right]$

如果用 OLS 估计 $y_i = x_i' \boldsymbol{\beta} + \varepsilon_i$,则遗漏了非线性项 $\sigma \cdot \lambda [(c - x_i' \boldsymbol{\beta})/\sigma]$,与 x_i 相关,导致 OLS 不一致。

参见图 14.3。总体回归线为 $\alpha+\beta x_i$,而样本回归线为 $\hat{\alpha}+\hat{\beta} x_i$ 。

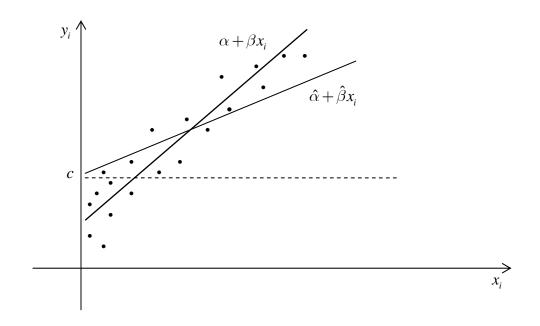


图 14.3 断尾回归示意图

使用 MLE 可得到一致估计。断尾前的概率密度:

$$f(y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2} \left(\frac{y_i - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)^2\right\} = \frac{1}{\sigma} \phi\left(\frac{y_i - \mathbf{x}_i'\boldsymbol{\beta}}{\sigma}\right)$$

样本被观测到的概率:

$$P(y_{i} > c \mid \mathbf{x}_{i}) = 1 - P(y_{i} \le c \mid \mathbf{x}_{i})$$

$$= 1 - P\left(\frac{y_{i} - \mathbf{x}_{i}'\boldsymbol{\beta}}{\sigma} \le \frac{c - \mathbf{x}_{i}'\boldsymbol{\beta}}{\sigma} \middle| \mathbf{x}_{i}\right)$$

$$= 1 - P\left(\frac{\varepsilon_{i}}{\sigma} \le \frac{c - \mathbf{x}_{i}'\boldsymbol{\beta}}{\sigma} \middle| \mathbf{x}_{i}\right)$$

$$= 1 - \Phi\left(\frac{c - \mathbf{x}_{i}'\boldsymbol{\beta}}{\sigma}\right)$$

断尾后的条件密度:

$$f(y_i | y_i > c, \mathbf{x}_i) = \frac{\frac{1}{\sigma} \phi [(y_i - \mathbf{x}_i' \boldsymbol{\beta}) / \sigma]}{1 - \Phi [(c - \mathbf{x}_i' \boldsymbol{\beta}) / \sigma]}$$

14.2 零断尾泊松回归与负二项回归

计数数据有时仅包括正整数,不包括取值为 0 的观测值,称为 "零断尾"(zero-truncated)。

例:在商场发放问卷调查,研究消费者每周去商场的次数。

例:在公交车上发放问卷调查,研究乘车者每周坐公交的次数。

如果不对似然函数进行调整,将得不到一致估计。

记f(y)为y的概率函数,而 $F(y) \equiv P(Y \le y)$ 为 cdf。如果存在零断尾,则断尾后的概率函数为

$$f(y | y \ge 1) = \frac{f(y)}{1 - F(0)}, \quad y = 1, 2, \dots$$

如果 y 服从泊松分布,则

$$f(y | y \ge 1) = \frac{e^{-\lambda} \lambda^y}{y!(1-e^{-\lambda})}, \quad y = 1, 2, \dots$$

进行 MLE 估计,得到"零断尾泊松回归"(zero-truncated Poisson regression)。如果 y 服从负二项分布(NB1 或 NB2),可进行"零断尾负二项回归"(zero-truncated negative binomial regression)。

14.3 随机前沿模型(选读)

14.4 偶然断尾与样本选择

被解释变量 y_i 的断尾有时与另一变量 z_i 有关,称为"偶然断尾" (incidental truncation)或"样本选择"(sample selection)。

称zi为选择变量。

例 在美国的亚裔移民给人的整体印象是聪明能干。但在美国的亚裔并非亚洲人口的代表性样本。通常只有受过高等教育或具有吃苦冒险精神的亚裔才会"自我选择"(self selection)移民。

决定移民与否的变量便对被解释变量产生了断尾作用,故"样本选择"将导致"选择性偏差"(selection bias)。

例 妇女劳动力供给模型:

劳动时间方程 hours = $\alpha_0 + \alpha_1$ wage+ α_2 children+ α_3 marriage+ u 工资方程 $\mathbf{w}^o - \mathbf{w}^r = \beta_0 + \beta_1$ age+ β_2 education+ β_3 children+ β_0 location+ v \mathbf{w}^o 表示 offered wage, \mathbf{w}^r 表示 reservation wage。

如果 $\mathbf{w}^o - \mathbf{w}^r < 0$,则选择不工作,无法观测到劳动时间(hours),造成劳动时间方程的偶然断尾与样本选择问题。

考虑二维正态随机向量(y,z),记期望为 (μ_y,μ_z) ,标准差为 (σ_y,σ_z) ,相关系数为 ρ ,联合密度函数为f(y,z)。

假设个体进入样本的"选择机制"(selection mechanism)为"选择变量z大于某常数c"。

比如,在妇女劳动力供给例子中, $z = \mathbf{w}^o - \mathbf{w}^r$,而c = 0。

断尾后的联合分布:

$$f(y, z \mid z > c) = \frac{f(y, z)}{P(z > c)}$$

偶然断尾 y 的条件期望:

$$E(y \mid z > c) = \mu_{y} + \rho \sigma_{y} \lambda \left[(c - \mu_{z}) / \sigma_{z} \right]$$

 $\lambda(\cdot)$ 为反米尔斯比率(IMR)函数。

如果 $\rho = 0$ (y 与 z 相互独立),则 z 的选择过程并不对 y 产生影响。

如果 $\rho > 0$ (即 y 与 z 正相关),则 "z > c" 偶然断尾的结果是把 y 的整个分布推向右边(因为 $\lambda(\cdot) > 0$),从而使得条件期望 E(y|z>c) 大于无条件期望 E(y)。

在"z < c"条件下,偶然断尾 y 的条件期望为

$$E(y \mid z < c) = \mu_y - \rho \sigma_y \lambda [(\mu_z - c) / \sigma_z]$$

假设回归模型为 $y_i = x_i' \beta + \varepsilon_i$ 。

 y_i 是否可观测取决于选择变量 z_i (取值为 0 或 1)

$$y_i = \begin{cases} \overline{\text{可观测}} & z_i = 1 \\ \overline{\text{不可观测}} & z_i = 0 \end{cases}$$

决定二值变量zi的方程为

$$z_{i} = \begin{cases} 1, & \text{ if } z_{i}^{*} > 0 \\ 0, & \text{ if } z_{i}^{*} \leq 0 \end{cases}$$

$$z_i^* = \mathbf{w}_i' \mathbf{\gamma} + u_i$$

 z_i^* 为不可观测的潜变量。

假设 u_i 服从正态分布,则 z_i 为 Probit 模型,故 $P(z_i = 1 | w_i) = \Phi(w_i' \gamma)$ 。可观测样本的条件期望:

$$E(y_i | y_i 可 观测) = E(y_i | z_i^* > 0) = E(x_i' \beta + \varepsilon_i | w_i' \gamma + u_i > 0)$$

$$= E(x_i' \beta + \varepsilon_i | u_i > -w_i' \gamma) = x_i' \beta + E(\varepsilon_i | u_i > -w_i' \gamma)$$

$$= x_i' \beta + \rho \sigma_{\varepsilon} \lambda(-w_i' \gamma)$$

其中, $E(\varepsilon_i) = E(u_i) = 0$,并将 Probit 扰动项的标准差 σ_u 标准化为 1。

OLS 估计,将遗漏非线性项 $\rho\sigma_{\varepsilon}\lambda(-w_i'\gamma)$ 。

如 \mathbf{w}_i 与 \mathbf{x}_i 相关,则OLS不一致,除非" $\rho=0$ "(即 \mathbf{y} 与 \mathbf{z} 不相关)。

解释变量 x_{ik} 的边际效应:

$$\frac{\partial E(y_i \mid z_i^* > 0)}{\partial x_{ik}} = \beta_k + \rho \sigma_{\varepsilon} \frac{\partial \lambda(-w_i' \gamma)}{\partial x_{ik}}$$

右边第一项为直接影响,第二项是通过改变个体进入样本可能 性而产生的间接影响(即选择性偏差)。

如知道 γ ,就知道 $\lambda(-w'_i\gamma)$,可把它作为解释变量引入回归方程。

Heckman (1979)提出"两步估计法",也称"Heckit"。

第一步:用 Probit 估计方程 $P(z_i = 1 | w) = \Phi(w_i' \gamma)$,得到估计值 $\hat{\gamma}$,计算 $\hat{\lambda}(-w_i' \hat{\gamma})$ 。

第二步:用OLS回归 $y_i \xrightarrow{\text{OLS}} x_i, \hat{\lambda}_i$,得到估计值 $\hat{\beta}, \hat{\rho}, \hat{\sigma}_{\varepsilon}$ 。

更有效率的方法是 MLE。

在两步法中,第一步误差被带入第二步,效率不如 MLE 的整体估计。

两步法的优点在于,操作简便;对于分布的假设也更弱(即使不假设二维正态分布,也可能成立)。

为检验是否存在样本选择偏差(sample selection bias),可使用似然比检验来检验原假设" H_0 : $\rho = 0$ "。

如使用 Heckit, 无法进行此 LR 检验。

14.5 归并回归

对于线性模型 $y_i = x_i' \beta + \varepsilon_i$,当 $y_i \ge c$ (或 $y_i \le c$)时,所有 y_i 都被归并为 c,称为"归并数据" (censored data)。

例 (上不封顶的数据, top coding)在问卷调查中,常有诸如"收入在¥50,000及以上"这样的选项。

例 (边角解)考虑买车的决定,并考察"买车开支"这个变量。如果不买车,则"买车开支"的最优解为边角解,即买车开支为0; 反之,如果买车,则买车开支一定为正数。

例 (边角解)考察"劳动时间"这个变量。对于失业或待业者而言,"劳动时间"的最优解为边角解,即劳动时间为 0;而就业者

的劳动时间一定为正数。

归并回归(censored regression)与断尾回归不同的是,虽有全部观测数据,但某些数据的 y_i 被压缩在一个点上。

 y_i 的概率分布就变成由一个离散点与一个连续分布所组成的混合分布(mixed distribution)。

假设 $y_i^* = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i (y_i^* 不可观测), \varepsilon_i | \mathbf{x}_i \sim N(0, \sigma^2), 归并点为<math>c = 0$ 。

假设可观测到:

$$y_{i} = \begin{cases} y_{i}^{*}, & 若 & y_{i}^{*} > 0 \\ 0, & 若 & y_{i}^{*} \leq 0 \end{cases}$$

如使用满足条件" $y_i > 0$ "的子样本,将导致断尾,出现偏差,因为

由于忽略非线性项 $\sigma \cdot \lambda(-x_i'\boldsymbol{\beta}/\sigma)$,导致扰动项与 x_i 相关,故 OLS 不一致。

对于整个样本,

$$E(y_i | \mathbf{x}_i) = 0 \cdot P(y_i = 0 | \mathbf{x}_i) + E(y_i | \mathbf{x}_i; y_i > 0) \cdot P(y_i > 0 | \mathbf{x}_i)$$

$$= E(y_i | \mathbf{x}_i; y_i > 0) \cdot P(y_i > 0 | \mathbf{x}_i)$$

其中,
$$P(y_i > 0 \mid \mathbf{x}_i) = P(y_i^* > 0 \mid \mathbf{x}_i) = P(\mathbf{x}_i'\boldsymbol{\beta} + \varepsilon_i > 0 \mid \mathbf{x}_i)$$

 $= P(\varepsilon_i > -\mathbf{x}_i'\boldsymbol{\beta} \mid \mathbf{x}_i) = P\left(\frac{\varepsilon_i}{\sigma} > \frac{-\mathbf{x}_i'\boldsymbol{\beta}}{\sigma} \mid \mathbf{x}_i\right)$
 $= 1 - \Phi(-\mathbf{x}_i'\boldsymbol{\beta}/\sigma) = \Phi(\mathbf{x}_i'\boldsymbol{\beta}/\sigma)$

$$E(y_i \mid \boldsymbol{x}_i) = E(y_i \mid \boldsymbol{x}_i, y_i > 0) \cdot P(y_i > 0 \mid \boldsymbol{x}_i) = \Phi(\boldsymbol{x}_i' \boldsymbol{\beta} / \sigma) [\boldsymbol{x}_i' \boldsymbol{\beta} + \sigma \cdot \lambda (-\boldsymbol{x}_i' \boldsymbol{\beta} / \sigma)]$$

是解释变量 x_i 的非线性函数。如果使用 OLS 对整个样本进行回归,非线性项将被纳入扰动项中,导致不一致估计。

Tobin (1958)提出用 MLE 估计这个模型, 称为"Tobit"。

在归并数据情况下, $y_i > 0$ 时的概率密度依然不变,仍为

$$\frac{1}{\sigma}\phi\big[(y_i-x_i'\boldsymbol{\beta})/\sigma\big]$$

 $y_i \le 0$ 时的分布被挤到" $y_i = 0$ "上,即

$$P(y_i = 0 | x) = 1 - P(y_i > 0 | x) = 1 - \Phi(x_i' \beta / \sigma)$$

该混合分布的概率密度为

$$f(y_i \mid \boldsymbol{x}) = \left[1 - \Phi(\boldsymbol{x}_i'\boldsymbol{\beta}/\sigma)\right]^{I(y_i=0)} \left[\frac{1}{\sigma}\phi((y_i - \boldsymbol{x}_i'\boldsymbol{\beta})/\sigma)\right]^{I(y_i>0)}$$

Tobit 模型的缺陷是对分布的依赖性强,不够稳健。

如果似然函数不正确(扰动项不服从正态分布或存在异方差),则 QMLE 估计不一致。

使用 Tobit 模型时,需要检验正态性与同方差性。

为了检验正态性,可将 Tobit 模型的 MLE 一阶条件视为某种矩条件,并基于此进行"条件矩检验"(conditional moment test)。

但条件矩统计量的真实分布与渐近分布有相当差距,存在较严重的显著性水平扭曲,故使用"参数自助法"来获得校正的临界值。

为了检验同方差的原假设" $H_0: \sigma_i^2 = \sigma^2$ ", 考虑替代假设

" H_1 : $\sigma_i^2 = \exp(\mathbf{z}_i'\boldsymbol{\alpha})$ ",其中 \mathbf{z}_i 通常等于解释变量 \mathbf{x}_i (也可不同)。

然后通过辅助回归,构建 LM 统计量来检验 $\alpha = 0$,参见 Cameron and Trivedi (2010, p.550)。

如果发现扰动项不服从正态分布或存在异方差,解决方法之一为使用更稳健的"归并最小绝对离差法"(Censored Least Absolute Deviations,简记 CLAD)。

CLAD 法仅要求扰动项为 iid,即使在非正态与异方差情况下也一致,且在一定正则条件下,服从渐近正态分布。

将归并数据模型简洁地写为

$$y_i = \max(0, \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i)$$

如果 $\mathbf{x}_{i}'\boldsymbol{\beta} + \varepsilon_{i} \geq 0$,则 $y_{i} = \mathbf{x}_{i}'\boldsymbol{\beta} + \varepsilon_{i}$;反之, $y_{i} = 0$ 。

CLAD 法的目标函数为离差绝对值之和:

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} |y_i - \max(0, \boldsymbol{x}_i' \boldsymbol{\beta})|$$

选择 β 使得离差绝对值之和最小化,即可得到 CLAD 估计量。

- 14.6 归并数据的两部分模型(选读)
- 14.7 含内生解释变量的 Tobit 模型 (选读)