© 陈强,《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

第15章 短 面 板

15.1 面板数据的特点

面板数据(panel data 或 longitudinal data),指的是在一段时间内跟踪同一组个体(individual)的数据。

它既有横截面的维度 $(n \land \land \land \land)$,又有时间维度 $(T \land \land)$ 。

一个T=3的面板数据结构如表 15.1。

表 15.1 面板数据的结构

		У	\mathcal{X}_1	x_2	x_3
Individual 1: t	t=1				
Individual 1: t	t=2				
Individual 1: t	t=3				
•••••					
Individual <i>n</i> : t	t=1				
Individual <i>n</i> : t	t=2				
Individual <i>n</i> : t	t=3				

如果面板数据 T 较小,而 n 较大,在使用大样本理论时让 n 趋于无穷大。这种面板数据被称为"短面板"(short panel)。

反之,如果 T较大,而 n 较小,则被称为"长面板"(long panel)。

在面板模型中,如果解释变量包含被解释变量的滞后值,则称为"动态面板"(dynamic panel);反之,则称为"静态面板"(static panel)。

如果在面板数据中,每个时期在样本中的个体完全一样,则称为"平衡面板数据"(balanced panel);反之,则称为"非平衡面板数据"(unbalanced panel)。

面板数据的优点:

(1) 解决遗漏变量问题:

遗漏变量常由不可观测的个体差异或"异质性"(heterogeneity)造成。

如果个体差异"不随时间而改变"(time invariant),则面板数据可解决遗漏变量问题。

(2) 提供个体动态行为的信息:

例: 考虑区分规模效应与技术进步对企业生产效率的影响。对于截面数据,没有时间维度,无法观测到技术进步。对于时间序列,无法区分生产效率的提高究竟有多少由于规模扩大,有多少

由于技术进步。

例:对于失业问题,截面数据能告诉在某个时点上哪些人失业,时间序列数据能告诉某个人就业与失业的历史,但这两种数据均无法告诉是否失业的总是同一批人(低流转率),还是失业的人群总在变动(高流转率)。

(3) 样本容量较大:同时有截面维度与时间维度,面板数据的样本容量更大,可提高估计精度。

面板数据也会带来问题,比如,数据通常不满足独立同分布的假定,因为同一个体在不同期的扰动项一般存在自相关。

面板数据的收集成本通常较高,不易获得。

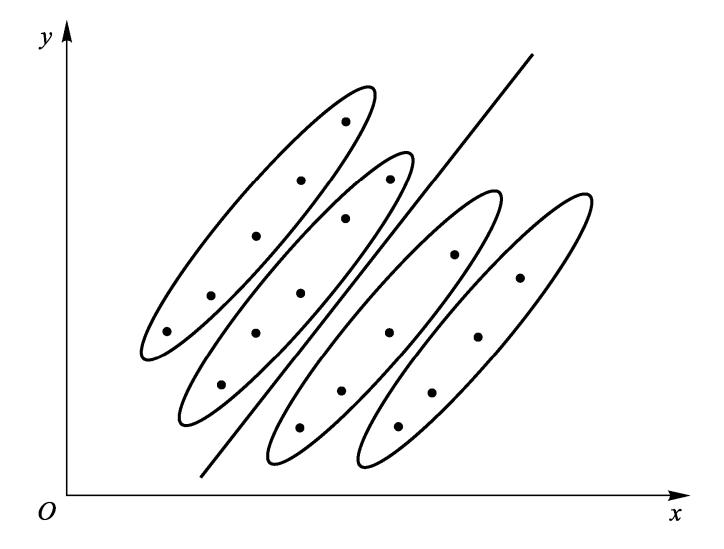
15.2 面板数据的估计策略

一个极端策略是将其看成是截面数据而进行混合回归(pooled regression),要求样本中每位个体拥有相同的回归方程。

此策略忽略个体间不可观测或被遗漏的异质性(heterogeneity), 而该异质性可能与解释变量相关,导致估计不一致。

另一极端策略则是,为每位个体估计一个单独的回归方程。此策略忽略了个体的共性,可能没有足够大的样本容量。

实践中常采用折衷的估计策略,即假定个体的回归方程拥有相同的斜率,但可有不同的截距项,以此来捕捉异质性。



个体效应模型 (individual-specific effects model)

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + u_i + \varepsilon_{it}$$
 $(i = 1, \dots, n; t = 1, \dots, T)$

 z_i 为不随时间而变(time invariant)的个体特征,比如性别;

 x_{it} 可随个体及时间而变(time-varying);

扰动项由 $(u_i + \varepsilon_{ii})$ 两部分构成,称为"复合扰动项"(composite error term);不可观测的随机变量 u_i 是代表个体异质性的截距项。

 ε_{it} 为随个体与时间而改变的扰动项。假设 $\{\varepsilon_{it}\}$ 为 iid,且与 u_i 不相关。

如果 u_i 与某个解释变量相关,则称为"固定效应模型"(Fixed Effects Model,简记 FE)。此时,OLS 不一致。

如果 u_i 与所有解释变量(\mathbf{x}_{it} , \mathbf{z}_i)均不相关,则称为"随机效应模型"(Random Effects Model,简记 RE)。

15.3 混合回归

如果所有个体拥有一样的回归方程,则方程可写为

$$y_{it} = \alpha + x'_{it} \beta + z'_{i} \delta + \varepsilon_{it}$$

 x_{ii} 不包括常数项。把所有数据放在一起,像对待横截面数据那样进行 OLS 回归,称为"混合回归"(pooled regression)。

应使用聚类稳健的标准误(cluster-robust standard errors),聚类 (cluster)由每位个体不同期的所有观测值所组成。

15.4 个体固定效应模型

对于固定效应模型,给定个体 i,将方程两边对时间平均:

$$\overline{y}_i = \overline{x}_i' \beta + z_i' \delta + u_i + \overline{\varepsilon}_i$$

将原方程减去平均后的方程可得:

$$y_{it} - \overline{y}_i = (\boldsymbol{x}_{it} - \overline{\boldsymbol{x}}_i)' \boldsymbol{\beta} + (\varepsilon_{it} - \overline{\varepsilon}_i)$$

定义
$$\tilde{y}_{it} \equiv y_{it} - \overline{y}_{i}$$
, $\tilde{x}_{it} \equiv x_{it} - \overline{x}_{i}$, $\tilde{\varepsilon}_{it} \equiv \varepsilon_{it} - \overline{\varepsilon}_{i}$, 则

$$\tilde{y}_{it} = \tilde{x}'_{it} \boldsymbol{\beta} + \tilde{\varepsilon}_{it}$$

上式已将 u_i 消去,只要 $\tilde{\varepsilon}_{it}$ 与 \tilde{x}_{it} 不相关,可用 OLS 一致地估计 $\boldsymbol{\beta}$,称为"固定效应估计量"(Fixed Effects Estimator),记为 $\hat{\boldsymbol{\beta}}_{\text{FE}}$ 。

 $\hat{m{\beta}}_{\text{FE}}$ 主要使用了每个位体的组内离差信息,也称"组内估计量" (within estimator)。

即使个体特征 u_i 与解释变量 x_i 相关,组内估计量也一致。

在作离差转换时, $z_i'\delta$ 也被消掉,无法估计 δ ,故 FE 无法估计不随时间而变的变量之影响。

为保证 $(\varepsilon_{it} - \overline{\varepsilon}_i)$ 与 $(x_{it} - \overline{x}_i)$ 不相关,要求第i个观测值满足严格外

生性,即 $\mathbf{E}(\varepsilon_{ii}|\mathbf{x}_{i1},\cdots,\mathbf{x}_{iT})=0$,因为 $\bar{\mathbf{x}}_i$ 中包含了所有 $(\mathbf{x}_{i1},\cdots,\mathbf{x}_{iT})$ 的信息。扰动项须与各期解释变量均不相关(不仅仅是当期解释变量)。

在原方程中引入(n-1)个虚拟变量(如果没有截距项,则引入 n个虚拟变量)来代表不同的个体,可得到同样结果。

FE 也称为"最小二乘虚拟变量模型"(Least Square Dummy Variable Model, 简记 LSDV)。

正如线性回归与离差形式的回归在某种意义上是等价的。比如,

$$y_i = \alpha + \beta x_i + \varepsilon_i \iff y_i - \overline{y} = \beta (x_i - \overline{x}) + (\varepsilon_i - \overline{\varepsilon})$$

使用 LSDV 的好处是可以得到个体异质性 u_i 的估计。

LSDV 法的缺点是,如果 n 很大,须在回归方程中引入很多虚拟变量,可能超出计量软件所允许的解释变量个数。

15.5 时间固定效应

引入时间固定效应,可解决不随个体而变(individual invariant)但随时间而变(time varying)的遗漏变量问题。假设模型为

$$y_{it} = \mathbf{x}_{it}' \mathbf{\beta} + \mathbf{z}_{i}' \mathbf{\delta} + \gamma S_{t} + u_{i} + \varepsilon_{it}$$

 S_t 不可观测。定义 $\lambda_t \equiv \gamma S_t$,则

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + \lambda_{t} + u_{i} + \varepsilon_{it}$$

将 λ_t 视为第t期独有的截距项,并将其解释为"第t期"对y的效应,故 $\lambda_1, \dots, \lambda_r$ 称为"时间固定效应"(time fixed effects)。

使用 LSDV 法来,对每个时期定义一个虚拟变量,把(T-1)个时间虚拟变量包括在回归方程中:

$$y_{it} = \mathbf{x}_{it}' \boldsymbol{\beta} + \mathbf{z}_{i}' \boldsymbol{\delta} + \gamma_2 D 2_t + \dots + \gamma_T D T_t + u_i + \varepsilon_{it}$$

其中,时间虚拟变量 $D2_t = 1$,如果t = 2; $D2_t = 0$,如果 $t \neq 2$; 以此类推。

此方程既考虑个体固定效应,又考虑时间固定效应,称为"双向固定效应"(Two-way FE)。

为节省参数,可引入时间趋势项,替代(T-1)个时间虚拟变量:

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + \gamma t + u_{i} + \varepsilon_{it}$$

上式隐含较强假定,即每个时期的时间效应相等,每期均增加γ。

15.6 一阶差分法

对于固定效应模型,可对原方程两边进行一阶差分,以消去个体效应 u_i (同时把 z_i' δ 消掉了),

$$y_{it} - y_{i, t-1} = (\boldsymbol{x}_{it} - \boldsymbol{x}_{i, t-1})' \boldsymbol{\beta} + (\varepsilon_{it} - \varepsilon_{i, t-1})$$

对此方程使用 OLS, 即得到"一阶差分估计量"(First Differencing Estimator),记为 $\hat{\pmb{\beta}}_{ ext{FD}}$ 。

只要 $(\varepsilon_{it} - \varepsilon_{i,t-1})$ 与 $(x_{it} - x_{i,t-1})$ 不相关,则 $\hat{\beta}_{FD}$ 一致。

此一致性条件比严格外生性假定更弱,这是 $\hat{oldsymbol{eta}}_{ ext{FD}}$ 的主要优点。

可以证明(参见习题),如果T=2,则 $\hat{\boldsymbol{\beta}}_{FD}=\hat{\boldsymbol{\beta}}_{FE}$ 。

对于T > 2,如果 $\{\varepsilon_{it}\}$ 为 iid,则 $\hat{\boldsymbol{\beta}}_{FE}$ 比 $\hat{\boldsymbol{\beta}}_{FD}$ 更有效率,故实践中主要使用 $\hat{\boldsymbol{\beta}}_{FE}$ 。

对于动态面板(第16章),严格外生性假定无法满足,用差分法。

15.7 随机效应模型

对于方程 $y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\delta} + u_{i} + \varepsilon_{it}$,随机效应模型假设 u_{i} 与解释变量 $\{\mathbf{x}_{it}, \mathbf{z}_{i}\}$ 均不相关,故 OLS 一致。

但扰动项由($u_i + \varepsilon_{it}$)组成,不是球型扰动项,故 OLS 不是最有效率的,应进行 FGLS 估计。

假设不同个体之间的扰动项互不相关。由于 u_i 的存在,同一个体不同时期的扰动项之间仍存在自相关,

 σ_u^2 为 u_i 的方差, σ_{ε}^2 为 ε_{it} 的方差。

当 $t \neq s$ 时,其自相关系数为

$$\rho \equiv \operatorname{Corr}(u_i + \varepsilon_{it}, \ u_i + \varepsilon_{is}) = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2}$$

自相关系数 ρ 不随时间距离(t-s)而改变。

 ρ 越大,则复合扰动项 $(u_i + \varepsilon_{ii})$ 中个体效应的部分 (u_i) 越重要。

同一个体扰动项的协方差阵为

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_u^2 + \sigma_{\varepsilon}^2 & \sigma_u^2 & \dots & \sigma_u^2 \\ \sigma_u^2 & \sigma_u^2 + \sigma_{\varepsilon}^2 & \dots & \sigma_u^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_u^2 & \sigma_u^2 & \dots & \sigma_u^2 + \sigma_{\varepsilon}^2 \end{pmatrix}_{T \times T}$$

整个样本的协方差阵为块对角矩阵(block diagonal matrix),

$$\mathbf{\Omega} = \begin{pmatrix} \mathbf{\Sigma} & & 0 \\ & \ddots & \\ 0 & & \mathbf{\Sigma} \end{pmatrix}_{nT \times nT}$$

由于 OLS 是一致的,且其扰动项为 $(u_i + \varepsilon_{it})$,故可用 OLS 的残差来估计 $(\sigma_u^2 + \sigma_\varepsilon^2)$ 。

另一方面,FE 也一致,且其扰动项为($\varepsilon_{it} - \overline{\varepsilon}_{i}$),故可用 FE 的残差来估计 σ_{ε}^{2} 。

然后,用 FGLS 估计原模型,得到"随机效应估计量"(Random Effects Estimator),记为 $\hat{\pmb{\beta}}_{RE}$ 。

具体来说,用 OLS 来估计以下"广义离差"(quasi-demeaned)模型:

$$y_{it} - \hat{\theta} \overline{y}_i = (\mathbf{x}_{it} - \hat{\theta} \overline{\mathbf{x}}_i)' \boldsymbol{\beta} + (1 - \hat{\theta}) \mathbf{z}_i' \boldsymbol{\delta} + \underbrace{\left[(1 - \hat{\theta}) u_i + (\varepsilon_{it} - \hat{\theta} \overline{\varepsilon}_i) \right]}_{\text{\&} \hat{\Xi} \bar{\eta}}$$

其中,
$$\hat{\theta}$$
是 $\theta \equiv 1 - \frac{\sigma_{\varepsilon}}{(T\sigma_{u}^{2} + \sigma_{\varepsilon}^{2})^{1/2}}$ 的一致估计量。

可以证明, 此扰动项不再有自相关。

对于随机效应模型,如果进一步假设扰动项服从正态分布,可进行 MLE 估计。

15.8 组间估计量

对于随机效应模型,还可使用"组间估计量"。

如果个体数据较不准确,可对每位个体取时间平均值,然后用 平均值来回归:

$$\overline{y}_i = \overline{x}_i' \beta + z_i' \delta + u_i + \overline{\varepsilon}_i \quad (i = 1, \dots, n)$$

对上式用 OLS, 可得"组间估计量"(Between Estimator), 记 $\hat{oldsymbol{eta}}_{\mathrm{BE}}$ 。

由于 $\{\bar{x}_i, z_i\}$ 中包含了 $\{x_{it}, z_i\}$ 的信息,如果 u_i 与解释变量 $\{x_{it}, z_i\}$ 相关,则 $\hat{\beta}_{BE}$ 不一致。故不能在固定效应模型下使用组间估计法。

15.9 拟合优度的度量

在有常数项的情况下,线性模型的 R^2 等于被解释变量 y 与预测值 ŷ之间相关系数的平方,即 $R^2 = [corr(y, \hat{y})]^2$ 。

对于面板模型,如使用混合回归,可直接用混合回归的 R^2 。

如使用固定效应、随机效应或组间回归,拟合优度略复杂。

给定估计量($\hat{\boldsymbol{\beta}}$, $\hat{\boldsymbol{\delta}}$), Stata 提供了以下三种 R^2 。

首先,对应于原模型,称 $[Corr(y_{it}, x'_{it}\hat{\boldsymbol{\beta}} + z'_{i}\hat{\boldsymbol{\delta}})]^{2}$ 为"整体 R^{2} " (R^{2} overall),衡量估计量($\hat{\boldsymbol{\beta}}$, $\hat{\boldsymbol{\delta}}$)对原模型的拟合优度。

其次,对应于组内模型,称 $[Corr(\tilde{y}_{it}, \tilde{x}'_{it}\hat{\boldsymbol{\beta}})]^2$ 为"组内 R^2 " (R^2 within),衡量估计量($\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\delta}}$)对组内模型的拟合优度。

再次,对应于组间模型,称 $[Corr(\bar{y}_i, \bar{x}_i'\hat{\boldsymbol{\beta}} + z_i'\hat{\boldsymbol{\delta}})]^2$ 为"组间 R^2 " (R^2 between),衡量估计量($\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\delta}}$)对组间模型的拟合优度。

对于固定效应模型,建议使用组内 R^2 ,即组内方程的 R^2 。

对于组间回归模型,建议使用组间 R^2 ,即组间方程的 R^2 。

对于随机效应模型,这三种 R^2 都只是相应的相关系数平方,而非随机效应方程的 R^2 。

15.10 非平衡面板

非平衡面板数据并不影响计算离差形式的组内估计量(within estimator),固定效应模型的估计可照样进行。

对于随机效应模型而言,非平衡面板数据也没有实质性影响, 只要在做广义离差变换时让

$$\theta_i \equiv 1 - \frac{\sigma_{\varepsilon}}{(T_i \sigma_u^2 + \sigma_{\varepsilon}^2)^{1/2}}$$

其中, T_i 为个体i的时间维度,就可照常进行FGLS估计。

非平衡面板的最大问题是, 那些原来在样本中但后来丢掉的个

体,如果"丢掉"的原因是内生的(即与扰动项相关),则会导致样本不具有代表性(不再是随机样本),从而导致估计量不一致。

比如,低收入的人群更易从面板数据中丢掉。

15.11 究竟该用固定效应还是随机效应模型

检验原假设" $H_0: u_i 与 x_{it}, z_i$ 不相关"(即随机效应模型为正确模型)。

无论原假设成立与否, FE 都是一致的。

如果原假设不成立,则RE不一致。

如果 H_0 成立,则 FE 与 RE 估计量将共同收敛于真实的参数值,故

 $(\hat{\boldsymbol{\beta}}_{\text{FE}} - \hat{\boldsymbol{\beta}}_{\text{RE}}) \xrightarrow{p} \mathbf{0}$ 。如果二者的差距过大,则倾向于拒绝原假设。

豪斯曼检验(Hausman, 1978)的统计量为

$$(\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE})' \left[\widehat{Var}(\hat{\boldsymbol{\beta}}_{FE}) - \widehat{Var}(\hat{\boldsymbol{\beta}}_{RE}) \right]^{-1} (\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE}) \xrightarrow{d} \chi^{2}(K)$$

其中,K为 $\hat{\beta}_{\text{FE}}$ 的维度。

上述检验假设在 H_0 成立的情况下, $\hat{\boldsymbol{\beta}}_{RE}$ 最有效率。如果存在异方差,则 $\hat{\boldsymbol{\beta}}_{RE}$ 并非最有效率的估计量,故不适用异方差的情形。

解决方法之一,通过自助法计算 $Var(\hat{\beta}_{FE} - \hat{\beta}_{RE})$,参见第 19 章。

解决方法之二,进行以下辅助回归(Wooldridge, 2010),

$$y_{it} - \hat{\theta} \overline{y}_i = (\mathbf{x}_{it} - \hat{\theta} \overline{\mathbf{x}}_i)' \boldsymbol{\beta} + (1 - \hat{\theta}) \mathbf{z}_i' \boldsymbol{\delta} + (\mathbf{x}_{it} - \overline{\mathbf{x}}_i)' \boldsymbol{\gamma} + \left[(1 - \hat{\theta}) u_i + (\varepsilon_{it} - \hat{\theta} \overline{\varepsilon}_i) \right]$$

使用聚类稳健标准误检验原假设" $H_0: \gamma = \mathbf{0}$ ",此检验在异方差的情况下也适用。

由于总可以把原模型变换为随机效应的方程:

$$y_{it} - \hat{\theta} \overline{y}_i = (\mathbf{x}_{it} - \hat{\theta} \overline{\mathbf{x}}_i)' \boldsymbol{\beta} + (1 - \hat{\theta}) \mathbf{z}_i' \boldsymbol{\delta} + \underbrace{\left[(1 - \hat{\theta}) u_i + (\varepsilon_{it} - \hat{\theta} \overline{\varepsilon}_i) \right]}_{\text{\&} \pm \overline{y}}$$

故在上面的辅助回归中, $\gamma = 0$ 。

如果随机效应模型成立,则 OLS 一致,故 $\lim_{n\to\infty}\hat{\gamma}=\gamma=0$ 。

如果固定效应模型成立,扰动项 $\left[(1-\hat{\theta})u_i + (\varepsilon_{it} - \hat{\theta}\overline{\varepsilon}_i)\right]$ 与 $(x_{it} - \overline{x}_i)$ 相关(因为 u_i 与 x_{it} 相关),OLS 不一致,即 $\lim_{n\to\infty}\hat{\gamma} = \gamma^* \neq \gamma = \mathbf{0}$ 。

拒绝 " $H_0: \gamma = \mathbf{0}$ ",则意味着拒绝随机效应,接受固定效应。 对于非平衡面板,则以 $\hat{\theta}$,替代方程中的 $\hat{\theta}$ 即可。

15.12 个体时间趋势

个体异质性还可能表现为个体的不同时间趋势。比如,在跨国面板中,各国的经济增长率可能不同。考虑以下模型:

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + \gamma_{i}t + u_{i} + \varepsilon_{it}$$

 $\gamma_i t$ 为个体时间趋势。

一般将 γ_i 视为来自某分布的随机变量(从该分布随机抽出一个观测值后,就不再随时间而变)。

此模型称为"随机趋势模型"(random trend model)。

如果 y_{it} 取对数形式(比如 $\ln GDP_{it}$),则 γ_i 可解释为在给定(\mathbf{x}_{it} , \mathbf{z}_i)条件下的平均增长率(即 $\partial E(\ln GDP_{it})/\partial t$),故也称"随机增长模型" (random growth model)。

首先对方程两边做差分,去掉u;:

$$\Delta y_{it} = \Delta x_{it}' \beta + \gamma_i + \Delta \varepsilon_{it}$$

在形式上,此方程与标准的个体效应模型一样。

如果 γ_i 与解释变量 Δx_{ii} 不相关,可用 RE 估计此方程。

如果 γ_i 与解释变量 Δx_{it} 相关,可用 FE 或 FD 估计此方程。