© 陈强,《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

第17章 非线性面板

17.1 面板二值选择模型

对于面板数据,如果被解释变量为虚拟变量,则为"面板二值选择模型"(binary choice model for panel data)。

二值选择行为可通过"潜变量"(latent variable)来概括其净收益。 净收益大于 0,则选择做;否则,不做。

1

假设净收益为

$$y_{it}^* = \mathbf{x}_{it}' \boldsymbol{\beta} + u_i + \varepsilon_{it} \quad (i = 1, \dots, n; \ t = 1, \dots, T)$$

 y_{it}^* 不可观测, u_i 为个体效应,解释变量 x_{it} 不含常数项。选择规则:

$$y_{it} = \begin{cases} 1 & \text{if } y_{it}^* > 0 \\ 0 & \text{if } y_{it}^* \le 0 \end{cases}$$

给定 x_{it} , β , u_i ,则有

$$P(y_{it} = 1 | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i) = P(y_{it}^* > 0 | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i)$$

$$= P(\mathbf{x}'_{it}\boldsymbol{\beta} + u_i + \varepsilon_{it} > 0 | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i)$$

$$= P(\varepsilon_{it} > -u_i - \mathbf{x}'_{it}\boldsymbol{\beta} | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i)$$

$$= P(\varepsilon_{it} < u_i + \mathbf{x}'_{it}\boldsymbol{\beta} | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i)$$

$$= F(u_i + \mathbf{x}'_{it}\boldsymbol{\beta})$$

 $F(\cdot)$ 为 ε_{it} 的 cdf,并假设 ε_{it} 的密度函数关于原点对称。

如果 $\varepsilon \sim N(0,1)$,则为 Probit 模型,

$$P(y_{it} = 1 \mid \boldsymbol{x}_{it}, \boldsymbol{\beta}, u_i) = \Phi(u_i + \boldsymbol{x}'_{it}\boldsymbol{\beta})$$

如果 ε 服从逻辑分布,则为Logit模型,

$$P(y_{it} = 1 | \mathbf{x}_{it}, \boldsymbol{\beta}, u_i) = \Lambda(u_i + \mathbf{x}'_{it}\boldsymbol{\beta}) = \frac{e^{u_i + \mathbf{x}'_{it}\boldsymbol{\beta}}}{1 + e^{u_i + \mathbf{x}'_{it}\boldsymbol{\beta}}}$$

面板二值模型的估计方法包括混合回归、随机效应估计与固定效应估计。

如果 $u_1 = u_2 = \cdots = u_n$,则为混合回归(pooled probit 或 pooled logit),可作为截面数据处理,应使用以面板为聚类的聚类稳健标准误(cluster-robust standard errors)。

17.2 面板二值选择模型的随机效应估计

更一般地,允许个体效应的存在,不同的个体拥有不同的 u_i 。

如果 u_i 与所有解释变量 x_{it} 均不相关,称为"随机效应模型" (Random Effects Model,简记 RE)。

如果 u_i 与某个解释变量相关,则称为"固定效应模型"(Fixed Effects Model,简记 FE)。

但非线性面板不便使用 FGLS, 故使用 MLE。

假设 $u_i \sim N(0, \sigma_u^2)$, 记其密度函数为 $g(u_i)$ 。

以 Logit 模型为例。

给定 u_i ,则个体i的条件分布为(推导过程参考第 11 章),

$$f(y_{i1}, y_{i2}, \dots, y_{iT} \mid \boldsymbol{x}_{it}, \boldsymbol{\beta}, u_i) = \prod_{t=1}^{T} \left[\Lambda(u_i + \boldsymbol{x}'_{it}\boldsymbol{\beta}) \right]^{y_i} \left[1 - \Lambda(u_i + \boldsymbol{x}'_{it}\boldsymbol{\beta}) \right]^{1-y_i}$$

但 u_i 不 可 观 测 。 记 $(y_{i1}, y_{i2}, \dots, y_{iT}, u_i)$ 的 联 合 密 度 为 $f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i)$,并进行如下分解,

$$f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i) = f(y_{i1}, y_{i2}, \dots, y_{iT} \mid u_i) \cdot g(u_i)$$

在 $(y_{i1}, y_{i2}, \dots, y_{iT}, u_i)$ 的联合密度中,将 u_i 积分积掉,可得 $(y_{i1}, y_{i2}, \dots, y_{iT})$ 的边缘密度,

$$f(y_{i1}, y_{i2}, \dots, y_{iT}) = \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i) du_i$$

$$= \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT} | u_i) \cdot g(u_i) du_i$$

$$= \int_{-\infty}^{+\infty} \left\{ \prod_{t=1}^{T} \left[\Lambda(u_i + \mathbf{x}'_{it}\boldsymbol{\beta}) \right]^{y_i} \left[1 - \Lambda(u_i + \mathbf{x}'_{it}\boldsymbol{\beta}) \right]^{1-y_i} \right\} \cdot g(u_i) du_i$$

上式无解析解,Butler and Moffitt (1982)提出使用"Gauss-Hermite quadrature"方法进行数值积分。

Stata 的默认方法为在 12 个点上进行"adaptive Gauss-Hermite quadrature"计算。

此积分的精度依赖于数值计算的点数,故 Stata 提供命令quadchk 来检验积分的精度,即使用其他计算点数,比较结果的稳定性。

最大化此似然函数即得到对 β 的"随机效应 Logit 估计量"(Random Effect Logit)。

如果将逻辑分布 $\Lambda(\cdot)$ 改为正态分布 $\Phi(\cdot)$,则为"随机效应 Probit估计量"(Random Effect Probit)。

在估计时已将 u_i 积分掉,故得不到对个体效应 u_i 的估计,也无法预测 y_i 的发生概率或计算解释变量的边际效应。

解决方法之一是假设 $u_i = 0$ 。

由于u_i的存在,同一个体不同期的扰动项之间仍存在自相关,

$$Cov(u_i + \varepsilon_{it}, u_i + \varepsilon_{is}) = \begin{cases} \sigma_u^2 & \text{if } t \neq s \\ \sigma_u^2 + \sigma_\varepsilon^2 & \text{if } t = s \end{cases}$$

 σ_u^2 为 u_i 的方差, σ_ε^2 为 ε_{it} 的方差。当 $t \neq s$ 时,其自相关系数为,

$$\rho = \operatorname{Corr}(u_i + \varepsilon_{it}, \ u_i + \varepsilon_{is}) = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2}$$

 ρ 越大,则复合扰动项 $(u_i + \varepsilon_{ii})$ 中个体效应的部分 (u_i) 越重要。如果 $\rho = 0$,则 $\sigma_u^2 = 0$,不存在个体随机效应,应选择混合回归。

如果拒绝 " $H_0: \rho = 0$ ",则认为应采用随机效应模型;反之,则支持混合回归。

17.3 面板二值选择模型的固定效应估计

在面板二值模型中,如果 u_i 与 x_{ii} 相关,则为固定效应模型,

$$P(y_{it} = 1 | x_{it}, \beta, u_i) = F(u_i + x'_{it}\beta)$$

其中, $F(\cdot)$ 为 $\Phi(\cdot)$ 或 $\Lambda(\cdot)$ 。随机效应模型或混合回归将不一致。

对于线性面板,可通过组内变换 $(y_{it} - \overline{y}_i)$ 或一阶差分 $(y_{it} - y_{i,t-1})$ 消去固定效应 u_i 。

对于非线性面板,这些变换不起作用。

即使在模型中增加个体虚拟变量(LSDV 法),仍得不到一致估计 (除非 $T \to \infty$)。因为当 $n \to \infty$ 时,待估计的个体效应 $\{u_i\}_{i=1}^n$ 的个数也 随之增加,这些 $\{u_i\}_{i=1}^n$ 称为"伴生参数" (incidental parameters)。

每个 u_i 只能由个体i的T个观测值来估计,而T并不增加。对于短面板,当 $n \to \infty$ 而T为有限值,对 $\{u_i\}_{i=1}^n$ 的估计不一致。

对于 u_i 的不一致估计还会"污染"对 β 的估计,导致对 β 的估计也不一致,称为"伴生参数问题"(incidental parameters problem)。

在线性面板中,可通过组内变换或差分变换解决伴生参数问题。 对于固定效应的面板 Probit, 无法解决此伴生参数问题。

对于固定效应的面板 Logit,可通过寻找 u_i 的"充分统计量" (sufficient statistic),然后在给定此充分统计量的条件下进行"条件最大似然估计" (conditional MLE)。

考虑总体参数 θ 与统计量 W。如果统计量 W包含了样本中所有可用来估计 θ 的信息,则称 W为参数 θ 的充分统计量。

换言之,给定W之后,任何根据样本计算的其他统计量都不可能 提供关于 θ 的额外信息。

样本数据在给定充分统计量 W 后的条件分布将不再依赖于 θ ,否则,控制了 W 之后的条件分布仍将包含 θ 的信息。

Chamberlain (1980)提出使用 $n_i = \sum_{t=1}^T y_{it}$ 作为 u_i 的充分统计量,并计算在给定 n_i 情况下的条件似然函数(此条件似然函数不再依赖于 u_i),然后进行条件 MLE 估计。

由于逻辑函数的指数形式,故 Logit 模型存在u_i的充分统计量。

以两期模型为例,即 T = 2。对于个体 i,只有三种可能,即 $n_i = y_{i1} + y_{i2} = 0$,1,或 2。

(1)
$$n_i = y_{i1} + y_{i2} = 0$$
.

必然有 $y_{i1} = y_{i2} = 0$,即 $P(y_{i1} = 0, y_{i2} = 0 | n_i = 0) = 1$,其对数似然函数为 ln1 = 0,对整个样本的对数似然函数没有贡献。

由于此条件似然函数为常数,故此观测值不包含可用于估计 β 的信息,等于损失了此观测值。

(2)
$$n_i = y_{i1} + y_{i2} = 2$$
.

必然有 $y_{i1} = y_{i2} = 1$,即 $P(y_{i1} = 1, y_{i2} = 1 | n_i = 2) = 1$ 。这些观测值不包含任何有助于估计 β 的信息,也可忽略。

(3) $n_i = y_{i1} + y_{i2} = 1$ 。 或者($y_{i1} = 0$, $y_{i2} = 1$), 或者($y_{i1} = 1$, $y_{i2} = 0$)。 分别计算其条件概率如下。

$$P(y_{i1} = 0, y_{i2} = 1 \mid n_i = 1) = \frac{P(y_{i1} = 0, y_{i2} = 1)}{P(y_{i1} = 0, y_{i2} = 1) + P(y_{i1} = 1, y_{i2} = 0)}$$

$$P(y_{i1} = 1, y_{i2} = 0 \mid n_i = 1) = \frac{P(y_{i1} = 1, y_{i2} = 0)}{P(y_{i1} = 0, y_{i2} = 1) + P(y_{i1} = 1, y_{i2} = 0)}$$

假设在给定 u_i 与 x_{ii} 的条件下, y_{i1} 与 y_{i2} 相互独立,则

$$P(y_{i1} = 0, y_{i2} = 1) = \frac{1}{1 + e^{u_i + x'_{i1}\beta}} \cdot \frac{e^{u_i + x'_{i2}\beta}}{1 + e^{u_i + x'_{i2}\beta}}$$

$$P(y_{i1} = 1, y_{i2} = 0) = \frac{e^{u_i + x'_{i1}\beta}}{1 + e^{u_i + x'_{i1}\beta}} \cdot \frac{1}{1 + e^{u_i + x'_{i2}\beta}}$$

代入方程可得,

$$\begin{split} \mathbf{P}(y_{i1} = 0, \ y_{i2} = 1 \, | \ n_i = 1) &= \frac{e^{u_i + x_{i2}' \beta}}{e^{u_i + x_{i1}' \beta} + e^{u_i + x_{i2}' \beta}} \\ &= \frac{e^{x_{i2}' \beta}}{e^{x_{i1}' \beta} + e^{x_{i2}' \beta}} = \frac{e^{(x_{i2} - x_{i1})' \beta}}{1 + e^{(x_{i2} - x_{i1})' \beta}} = \Lambda[(x_{i2} - x_{i1})' \beta] \end{split}$$

上式分子与分母的 e^{u_i} 同时消去。同理,

$$P(y_{i1} = 1, y_{i2} = 0 \mid n_i = 1) = \Lambda[-(x_{i2} - x_{i1})' \beta] = 1 - \Lambda[(x_{i2} - x_{i1})' \beta]$$

定义虚拟变量 $d_i = 1$,如果 $(y_{i1} = 0, y_{i2} = 1)$; $d_i = 0$,如果 $(y_{i1} = 1, y_{i2} = 0)$ 。

个体 i 的条件对数似然函数为:

$$\ln L_i(\boldsymbol{\beta}) = \left\{ d_i \ln \Lambda[(\boldsymbol{x}_{i2} - \boldsymbol{x}_{i1})' \boldsymbol{\beta}] + (1 - d_i) \ln\{1 - \Lambda[(\boldsymbol{x}_{i2} - \boldsymbol{x}_{i1})' \boldsymbol{\beta}]\} \right\} \cdot \boldsymbol{I}(n_i = 1)$$

小结:

- (1) 给定 n_i 的条件似然函数不再依赖于 u_i (已在推导中消去);
- (2) 此条件似然函数仍为Logit模型,只是解释变量变为 $(x_{i2}-x_{i1});$
- (3) 不随时间变化的变量将无法识别其系数,因为 $(x_{i2} x_{i1}) = 0$ 。固定效应的似然函数不含积分,无须进行数值积分。

对于T > 2,可计算给定 $n_i = 1$, $n_i = 2$,……,或 $n_i = T - 1$ 的条件似然函数。

固定效应模型的缺点是,将损失所有 $n_i = 0$ 或 $n_i = T$ 的观测值。

而且,无法估计个体效应 u_i (已被消去),故无法预测 y_i 的发生概率或解释变量的边际效应。

解决方法之一是假设 $u_i = 0$ 。

如何在固定效应模型与混合回归之间选择?可使用豪斯曼检验。

原假设为不存在个体效应,即" $H_0: u_i = u$ "。

如果原假设成立,则固定效应模型与混合回归都一致。

反之,如果原假设不成立,则固定效应一致,而混合回归不一致。

如果二者的系数估计值相差较大(以二次型来衡量),则倾向于拒绝原假设,接受存在个体效应的替代假设。

对于固定效应与随机效应之间的选择,也可进行豪斯曼检验。

17.4 面板二值选择模型的 Stata 实例

17.5 面板泊松回归

考虑被解释变量为计数变量的面板数据。

例: 若干企业在一段时间内每年获得专利的个数

例:全国各省在几年内每年发生矿难的数目

例: 世界各国近几十年每年发生示威游行的次数

例:一些病人在一段时间内的每期发病次数

对于个体 i,时期 t,记被解释变量为 Y_{it} ,假设 $Y_{it} = y_{it}$ 的概率由参数为 λ_{it} 的泊松分布所决定:

$$P(Y_{it} = y_{it} \mid \mathbf{x}_{it}) = \frac{e^{-\lambda_{it}} \lambda_{it}^{y_{it}}}{y_{it}!} \quad (y_{it} = 0, 1, 2, \dots)$$

 $\lambda_{tt} > 0$ 为泊松到达率。为保证 λ_{tt} 非负,假设

$$\lambda_{it} = \exp(\mathbf{x}_{it}' \boldsymbol{\beta} + u_i) = \exp(\mathbf{x}_{it}' \boldsymbol{\beta}) \cdot \exp(u_i) \equiv v_i \exp(\mathbf{x}_{it}' \boldsymbol{\beta})$$

 x_{it} 不含常数项,而 $v_i \equiv \exp(u_i)$ 为乘积形式的个体效应 (multiplicative individual effects)。

如果 $v_1 = v_2 = \cdots = v_n$,不存在个体效应,为混合泊松回归(pooled

Poisson),可作截面数据处理,须使用聚类稳健标准误。

一般地,允许个体效应的存在,即不同个体拥有不同的vi。

如果 v_i 与所有解释变量 \mathbf{x}_{it} 均不相关,则为"随机效应模型" (Random Effects Model,简记 RE)。

如果 v_i 与某个解释变量相关,则为"固定效应模型"(Fixed Effects Model,简记 FE)。

首先考虑随机效应模型,进行 MLE 估计。

记 v_i 的密度函数为 $g(v_i)$ 。

假设样本为iid,在给定 v_i 情况下,个体i的条件分布为,

$$f(y_{i1}, y_{i2}, \dots, y_{iT} | v_i) = \prod_{t=1}^{T} \left(\frac{e^{-\lambda_{it}} \lambda_{it}^{y_{it}}}{y_{it}!} \right) = \prod_{t=1}^{T} \left(\frac{e^{-v_i \exp(x'_{it} \boldsymbol{\beta})} [v_i \exp(x'_{it} \boldsymbol{\beta})]^{y_{it}}}{y_{it}!} \right)$$

但 v_i 不 可 观 测 。 记 $(y_{i1}, y_{i2}, \dots, y_{iT}, v_i)$ 的 联 合 密 度 为 $f(y_{i1}, y_{i2}, \dots, y_{iT}, v_i)$,并进行如下分解,

$$f(y_{i1}, y_{i2}, \dots, y_{iT}, v_i) = f(y_{i1}, y_{i2}, \dots, y_{iT} | v_i) \cdot g(v_i)$$

将 v_i 积分积掉,可得到 $(y_{i1}, y_{i2}, \dots, y_{iT})$ 的边缘密度,

$$f(y_{i1}, y_{i2}, \dots, y_{iT}) = \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT}, v_i) dv_i$$
$$= \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT} | v_i) \cdot g(v_i) dv_i$$

由于 $v_i = \exp(u_i) > 0$,常选择 v_i 服从 Gamma 分布(指数分布与卡方分布为 Gamma 分布的特例)。

假设 $v_i \sim \text{Gamma}(1/\alpha, \alpha)$, $\alpha > 0$,则 $E(v_i) = 1$, $Var(v_i) = \alpha$ 。

将 $Gamma(1/\alpha,\alpha)$ 的概率密度代入,可得负二项分布的概率密度,然后进行MLE估计。

参数 α 为个体异质性 v_i 的方差,故可对" $H_0: \alpha = 0$ " (Stata 称

为"alpha = 0")进行 LR 检验来判断是否存在个体异质性,即究竟应使用随机效应泊松回归还是混合泊松回归。

另一方法是,假设 $u_i \sim N(0, \sigma_u^2)$,但无解析解,一般用 "Gauss-Hermite quadrature"方法进行数值积分;也需用 Stata 命 ϕ quadchk 检验数值积分的精度。

可检验 " H_0 : $\sigma_u = 0$ " (Stata 称为 "sigma_u = 0")判断是否存在个体异质性。

固定效应的面板泊松模型:

可使用 $n_i \equiv \sum_{t=1}^T y_{it}$ 作为 v_i 的充分统计量,计算在给定 n_i 情况下的条件似然函数,然后进行条件 MLE 估计。

如果 $n_i = 0$,则 $y_{i1} = \cdots = y_{iT} = 0$,个体 i 的观测值对于条件似然函数的贡献为 0,此观测值将被去掉,损失样本容量。

另一缺点是,无法估计不随时间而变的变量系数。

在固定效应与随机效应泊松回归之间选择时,可用豪斯曼检验。

17.6 面板负二项回归

泊松回归假设均等分散,即方差等于期望。如果存在过度分散,即方差大于期望,可考虑负二项回归。

如果不存在个体异质性,可进行混合负二项回归。

对于随机效应的面板负二项模型,假设个体异质性服从Beta(r,s)分布(取值范围为[0,1]),则可将个体异质性积分掉,然后进行MLE估计。

对于固定效应的面板负二项模型,可考虑在给定 $n_i = \sum_{t=1}^T y_{it}$ (个体异质性的充分统计量)情况下的条件似然函数,然后进行条件

MLE 估计。

固定效应负二项回归的奇特之处在于,它可以估计不随时间而变的变量系数。

在固定效应与随机效应负二项回归之间选择,可用豪斯曼检验。

如何在泊松回归与负二项回归之间进行选择,这涉及到在稳健性与有效性之间的权衡(前者稳健,而后者更有效)。

17.7 面板计数模型的 Stata 实例

17.8 面板 Tobit

考虑归并数据(censored data)的面板模型。假设

$$y_{it}^* = \mathbf{x}_{it}' \boldsymbol{\beta} + u_i + \varepsilon_{it}$$

 y_i^* 不可观测,扰动项 $\varepsilon_{it} \sim N(0, \sigma_{\varepsilon}^2)$, u_i 为个体效应。

假定在 0 处存在左归并(left-censored)。假设可以观测到

如果 $u_1 = u_2 = \cdots = u_n$,则可直接进行混合 Tobit 回归,但须使用聚类稳健标准误。

更一般地, 允许个体效应的存在。

如果 u_i 与解释变量 x_{it} 不相关,则为随机效应模型(RE);反之,则为固定效应模型(FE)。

对于固定效应的 Tobit 模型,由于找不到个体异质性 u_i 的充分统计量,故无法进行条件 MLE 估计。如果直接在混合 Tobit 回归中加入个体虚拟变量(LSDV 法),也不一致。

考虑随机效应的 Tobit 模型。在给定个体效应 u_i 的情况下,个体i的条件分布为:

$$f(y_{i1}, y_{i2}, \dots, y_{iT} \mid u_i)$$

$$= \prod_{t=1}^{T} \left[1 - \Phi \left((\mathbf{x}_{it}' \boldsymbol{\beta} + u_i) / \sigma_{\varepsilon} \right) \right]^{I(y_{it}=0)} \left[\frac{1}{\sigma_{\varepsilon}} \phi \left((y_{it} - \mathbf{x}_{it}' \boldsymbol{\beta} - u_i) / \sigma_{\varepsilon} \right) \right]^{I(y_{it}>0)}$$

推导方法与第14章第5节类似。

但 u_i 不可观测。假设 $u_i \sim N(0, \sigma_u^2)$,记其概率密度函数为 $g(u_i)$ 。

记 $(y_{i1}, y_{i2}, \dots, y_{iT}, u_i)$ 的联合密度为 $f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i)$, 进行分解:

$$f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i) = f(y_{i1}, y_{i2}, \dots, y_{iT} \mid u_i) \cdot g(u_i)$$

将 u_i 积分掉,可得 $(y_{i1}, y_{i2}, \dots, y_{iT})$ 的边缘密度,

$$f(y_{i1}, y_{i2}, \dots, y_{iT}) = \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT}, u_i) du_i$$
$$= \int_{-\infty}^{+\infty} f(y_{i1}, y_{i2}, \dots, y_{iT} | u_i) \cdot g(u_i) du_i$$

上式积分无解析解,一般使用"Gauss-Hermite quadrature"方法 进行数值积分;也需用 Stata 命令 quadchk 检验此积分的精度。

可通过检验 " H_0 : $\sigma_u = 0$ " (Stata 称为 "sigma_u = 0")判断是 否存在个体异质性。

定义同一个体不同期扰动项的自相关系数为,

$$\rho = \operatorname{Corr}(u_i + \varepsilon_{it}, \ u_i + \varepsilon_{is}) = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2} \quad (t \neq s)$$

 ρ 越大,则复合扰动项 $(u_i + \varepsilon_{it})$ 中个体效应的部分 (u_i) 越重要。

如果 $\rho=0$,则 $\sigma_u^2=0$,不存在个体随机效应,应选择混合回归。

17.9 面板随机前沿模型(选读)