第19章 蒙特卡罗法与自助法

19.1 蒙特卡罗法的思想与用途

通过计算机模拟从总体抽取大量随机样本的计算方法统称为"蒙特卡罗法"(Monte Carlo Methods,简记 MC)。

例(计算圆周率π): 在边长为1的正方形中内接1/4单位圆。正方形面积为1,1/4圆面积为π/4。如知道1/4单位圆占正方形面积的比例,就可计算π。

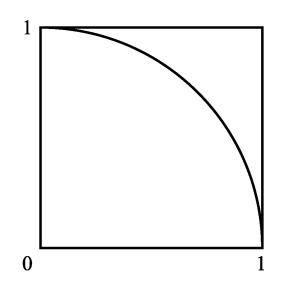


图 19.1 计算圆周率π的随机实验

向这个正方形随机地射箭,落点在正方形上服从二维均匀分布。 重复实验n次,其中有m次落在1/4圆内。 根据大数定律, $m/n \xrightarrow{p} \pi/4$, 故 $\pi \approx 4m/n$ 。

在计量中,常用 MC 来确定统计量的小样本性质。

【例】对于 $y_i = x_i' \beta + \varepsilon_i$ $(i = 1, \dots, n)$,对 $H_0: R\beta = r$ 进行显著性水平为 5%的大样本检验:

$$W = n(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})' \left[\widehat{\mathbf{R}} \widehat{\mathbf{A}} \widehat{\mathbf{var}} (\hat{\boldsymbol{\beta}}) \mathbf{R}' \right]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}) \xrightarrow{d} \chi^{2}(m)$$

其中 $\hat{\beta}$ 为 OLS 估计量, m 为线性约束个数。

渐近 χ^2 分布只是真实分布的近似,故"5%"可能只是"名义显著性水平"(nominal size),而非"真实显著性水平"(true or actual size),二者之差称为"显著性水平扭曲"(size distortion)。

可用 MC 来确定"真实显著性水平"。

第一步,给定 β 的具体取值,以及x与 ϵ 的概率分布。

第二步,从x与 ε 的分布中随机抽样,得到 $\{x_1, x_2, \dots, x_n\}$ 与 $\{\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n\}$ 。

第三步,根据方程 $y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i$ 计算 $\{y_1, y_2, \dots, y_n\}$ 。

第四步,对此样本进行 OLS 估计,计算统计量W,与 $\chi^2(m)$ 的 5% 临界值比较,确定是否拒绝原假设 $H_0: \mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ 。

第五步,大量重复第二至第四步,得到 M 个随机样本(比如,M=1000),进行 M 次检验,则拒绝原假设的比例就是真实显著性

水平。

19.2 蒙特卡罗法实例:模拟中心极限定理

19.3 蒙特卡罗法实例: 服从卡方分布的扰动项

19.4 蒙特卡罗积分

MC 的另一用途是计算复杂或高维的积分,称为"蒙特卡罗积分" (Monte Carlo integration)。

考虑计算定积分 $\int_a^b f(x)dx$, 其中a,b为有限值。

通过变量替换,可将积分上下限变为1与0,故仅考虑 $I = \int_0^1 f(x) dx$ 。

假设x服从在[0,1]上的均匀分布,则随机变量函数f(x)的期望值

$$E[f(x)] = \int_0^1 f(x) \cdot 1 \, dx \equiv I$$

抽取随机变量 x 的样本容量为 S 的随机样本,记为 $\{x_1, \dots, x_s, \dots, x_s\}$,则蒙特卡罗积分估计值为f(x)的样本均值:

$$\hat{I}_{\text{MC}} = \frac{1}{S} \sum_{s=1}^{S} f(x_s)$$

根据大数定律,当 $S \to \infty$ 时,样本均值 $\hat{I}_{MC} \xrightarrow{p} E[f(x)] = I$ 。

如果积分上限a或下限b为无穷,可从某个适当的概率密度g(x)中抽取随机样本 $\{x_1, \dots, x_s, \dots, x_s\}$ 。原积分总可写为

$$\int_{a}^{b} f(x) dx = \int_{a}^{b} \left[\frac{f(x)}{g(x)} \right] g(x) dx \equiv \int_{a}^{b} w(x) g(x) dx = \mathbb{E} [w(x)]$$

其中, $w(x) = \frac{f(x)}{g(x)}$ 。蒙特卡罗积分估计值为

$$\hat{I}_{\text{MC}} = \frac{1}{S} \sum_{s=1}^{S} w(x_s)$$

从密度函数g(x)中抽样的方法称为"重要性抽样"(importance

sampling),因为函数w(x)决定了每个样本点的权重或重要性。

19.5 最大模拟似然法与模拟矩估计

使用 MLE 的前提是,能写出似然函数 $f(y|x,\theta)$ 。

有时,该似然函数可能包含无法求解的积分。

比如,在随机效应的非线性面板模型中,要将个体效应 u_i 积分掉(u_i 不可观测),才能写出似然函数。

记 u_i 的密度函数为 $g(u_i)$,并假设第i个观测值的似然函数为

$$f(y_i \mid \mathbf{x}_i, \boldsymbol{\theta}) = \int h(y_i \mid \mathbf{x}_i, \boldsymbol{\theta}, u_i) g(u_i) du_i$$

如果积分无解析解,可使用蒙特卡罗积分进行估计。

从分布 $g(u_i)$ 中随机抽取 S 个观测值,记为 $\left\{u_i^1, \cdots, u_i^S\right\}$,则上式的估计值为

$$\hat{f}(y_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}) = \frac{1}{S} \sum_{s=1}^{S} h(y_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}, u_i^s)$$

假设样本为 iid,则整个样本的对数似然函数估计值为

$$\ln \hat{L}(\boldsymbol{\theta}) = \sum_{i=1}^{n} \ln \hat{f}(y_i \mid \boldsymbol{x}_i, \boldsymbol{\theta})$$

其中, n 为样本容量。

最大化上式所得到的估计量 $\hat{\theta}_{MSL}$ 称为"最大模拟似然估计量" (Maximum Simulated Likelihood Estimator,简记 MSL)。

在一定正则条件下,当模拟抽样的次数 $S \to \infty$ 时, \hat{f} 对f的近似程度越来越好,即($\hat{f} - f$)— $\stackrel{p}{\longrightarrow} 0$,则 MSL 为一致估计量。

如果 $\sqrt{n}/S \to 0$ (即 S 的增长速度快于 \sqrt{n}),则 MSL 为渐近有效估计量(渐近等价于 MLE),且服从渐近正态分布。

类似地,在进行矩估计时,如果矩条件中包含无解析解的积分,也可使用蒙特卡罗积分来估计此矩条件,然后进行矩估计。

此法称为"模拟矩估计"(Method of Simulated Moments),简记MSM。

19.6 自助法的思想与用途

MC 虽然威力大,但必须对总体模型做很具体的假定,所得结论不清楚在多大意义上能够推广。

Efron (1979)提出了对原始样本进行"再抽样"(resampling)的方法,即"自助法"或"自举法"(bootstrap)。

假设从总体抽得样本容量为n的随机样本。来自总体的样本带有总体的信息。

将此样本看作一个总体,进行"有放回"(with replacement)地抽样,样本容量仍然为n。这种样本被称为"自助样本"(bootstrap sample)。

由于是有放回地抽样,原来的某些观测值可能不出现,而有些观测值则可能多次出现。

可通过计算机模拟获得许多自助样本,然后利用这些自助样本对总体进行统计推断。

假设 $\{x_1, x_2, \dots, x_n\}$ 是来自总体 F 的随机样本。

定义总体 F 的经验分布函数(empirical distribution function) F_n :

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(x_i \le x), \quad -\infty < x < \infty$$

 $I(\cdot)$ 为示性函数,而 $\sum_{i=1}^{n} I(x_i \le x)$ 表示样本中小于或等于 x 的个数。 经验分布函数的形状为阶梯函数,在每个 x_i 处向上跳一个台阶。 可以证明,对任意 x, $F_n(x) \xrightarrow{p} F(x)$,这是自助法成立的前提。 自助法可看成是从经验分布函数中不断地抽样。 自助法的用途主要有两个方面。

首先,对于某些统计量(比如,样本中位数),常规方法很难得到标准误。可使用自助法,计算每个自助样本的样本中位数,得到样本中位数的分布,并计算其标准误。

其次,可使用自助法得到更加渐近有效的估计量(asymptotic refinement)。

19.7 自助法的分类

(1) **非参数自助法**(nonparametric bootstrap),也称"经验分布自助法" (empirical distribution function bootstrap)。将原始样本进行有放回地随机抽样。在回归模型中,意味着将 (y_i, x_i) 成对抽样,故也称"成对自助法"(paired bootstrap)。

(2) 参数自助法(parametric bootstrap)。

假设总体分布函数的形式已知,为 $F(x,\theta)$,而 θ 未知。先得到 θ 的估计量 $\hat{\theta}$ (比如使用 MLE),然后从总体 $F(x,\hat{\theta})$ 中重复抽样。

此法的前提是对总体分布函数的形式比较确信。在此前提下,参数自助法比非参自助法更有效率。

在回归模型中,需先确定条件分布的具体形式,即 $y|x \sim F(x,\theta)$ 。

一种方法是,得到估计量 $\hat{\theta}$ 后,从 $F(x_i, \hat{\theta})$ 中随机抽样得到对应的 y_i 。这相当于是"固定解释变量"(fixed regressors)的情形。

另一种方法是,先从 $\{x_1, x_2, \dots, x_n\}$ 中进行再抽样(resample),得到

 \mathbf{x}_{i}^{*} ,然后再从 $F(\mathbf{x}_{i}^{*}, \hat{\boldsymbol{\theta}})$ 中随机抽样得到对应的 y_{i} 。这相当于"随机解释变量"(stochastic regressors)的情形。

(3) 残差自助法(residual bootstrap)。

对于回归模型 $y_i = g(\mathbf{x}_i, \boldsymbol{\beta}) + \varepsilon_i$,首先通过估计得到残差 $\hat{\varepsilon}_i = y_i - g(\mathbf{x}_i, \hat{\boldsymbol{\beta}})$ 。

对残差 $\{\hat{\varepsilon}_1,\hat{\varepsilon}_2,\dots,\hat{\varepsilon}_n\}$ 使用自助法,得到残差的自助样本 $\{\hat{\varepsilon}_1^*,\hat{\varepsilon}_2^*,\dots,\hat{\varepsilon}_n^*\}$ 。

计算对应的 $y_i^* = g(\mathbf{x}_i, \hat{\boldsymbol{\beta}}) + \hat{\varepsilon}_i^*$, 进而得到自助样本 $\{(y_1^*, \mathbf{x}_1), \dots, (y_n^*, \mathbf{x}_n)\}$ 。

19.8 使用自助法估计标准误

假设原始样本为 $\{x_1, x_2, \dots, x_n\}$ 。对于未知参数 θ 的估计量 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$,需计算标准误 $\sigma_{\hat{\theta}} = \sqrt{\operatorname{Var}(\hat{\theta})}$,但有时无解析式。

如果从真实总体 F 获得样本容量为 n 的 B 个随机样本,对每个样本都可计算 $\hat{\theta}$,得到 B 个估计值 $\{\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_B\}$,则

$$s_{\hat{\theta}} \equiv \sqrt{\frac{1}{B-1} \sum_{i=1}^{B} (\hat{\theta}_i - \overline{\theta})^2}$$

其中
$$\bar{\theta} \equiv \frac{1}{B} \sum_{i=1}^{B} \hat{\theta}_{i}$$
。

但真实总体 F 的分布未知,而从总体多次抽样的成本可能很高。

以经验分布函数 F_n 来近似真实分布 F_n ,并从 F_n 中大量抽取随机样本,即在原始样本 $\{x_1, x_2, \dots, x_n\}$ 中每次有放回地抽样,得到样本容量为n的自助样本 $\{x_1^*, x_2^*, \dots, x_n^*\}$,并计算 $\hat{\theta}^* = \hat{\theta}(x_1^*, x_2^*, \dots, x_n^*)$ 。

如此重复,共抽取 B 个自助样本,则得到 θ 的 B 个自助估计值 $\left\{\hat{\theta}_{1}^{*},\hat{\theta}_{2}^{*},\cdots,\hat{\theta}_{B}^{*}\right\}$ 。可以定义标准误的自助估计为

$$s_{\hat{\theta}}^* \equiv \sqrt{\frac{1}{B-1} \sum_{i=1}^{B} (\hat{\theta}_i^* - \overline{\theta}^*)^2}$$

其中,
$$\bar{\theta}^* \equiv \frac{1}{B} \sum_{i=1}^B \hat{\theta}_i^*$$
。

19.9 使用自助法进行区间估计

(1) 百分位法(percentile method)。

得到自助估计量 $\hat{\theta}^*$ 的经验分布 $\{\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*\}$ 。

将 $\{\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_B^*\}$ 按从小到大的顺序排列,并记其 $\alpha/2$ 与 $(1-\alpha/2)$ 上分位数(upper quantile)分别为 $\hat{\theta}_{\alpha/2}^*$ 与 $\hat{\theta}_{1-\alpha/2}^*$,则 θ 的置信区间为

$$\left[\hat{ heta}_{ ext{l}-lpha/2}^*,\;\hat{ heta}_{lpha/2}^*
ight]$$

(2) 基于正态的置信区间(normal-based confidence interval)。

使用标准正态分布来估计置信区间,即

$$\left[\hat{\theta} - 1.96 \times s_{\hat{\theta}}^*, \hat{\theta} + 1.96 \times s_{\hat{\theta}}^*\right]$$

其中, $s_{\hat{\theta}}^*$ 是用自助法估计的标准误,并假定置信度为95%。

(3) 百分位 t 法(percentile-t method)。

根据每个自助样本计算对应的自助 t 统计量,

$$t_i^* \equiv \frac{\hat{\theta}_i^* - \hat{\theta}}{S_{\hat{\theta}_i^*}}, \quad i = 1, \dots, B$$

其中, $\hat{\theta}$ 为根据原始样本计算的 θ 估计量,而 $s_{\hat{\theta}_i^*}$ 是根据 $\left\{\hat{\theta}_1^*,\hat{\theta}_2^*,\cdots,\hat{\theta}_B^*\right\}$ 计算的标准误。

得到自助t统计量的经验分布 $\{t_1^*, t_2^*, \dots, t_B^*\}$,并记其 $\alpha/2$ 与 $(1-\alpha/2)$ 上分位数(upper quantile)分别为 $t_{\alpha/2}^* > 0$ 与 $t_{1-\alpha/2}^* < 0$,则 θ 的置信区间为

$$\left[\hat{\theta} + t_{1-\alpha/2}^* \times s_{\hat{\theta}}, \ \hat{\theta} + t_{\alpha/2}^* \times s_{\hat{\theta}}\right]$$

19.10 使用自助法进行假设检验

考虑用自助法进行如下双边检验, $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。

一种方法是,如果 $\theta_0 \in \left[\hat{\theta}_{1-\alpha/2}^*, \hat{\theta}_{\alpha/2}^*\right]$,则接受原假设 H_0 ;反之,则拒绝。这就是"百分位法"(percentile method)。

另一方法是,在假设 H_0 成立的情况下,计算原始样本的t统计量,

$$t \equiv \frac{\hat{\theta} - \theta_0}{s_{\hat{\theta}}}$$

如果 $t \in [t_{1-\alpha/2}^*, t_{\alpha/2}^*]$,则接受原假设 H_0 ;反之,则拒绝。其中, $t_{\alpha/2}^*$ 与 $t_{1-\alpha/2}^*$ 的定义如上。这就是"百分位 t 法"。

19.11 自助法的一致性(选读)

19.12 异方差情况下的自助法

由于异方差的存在不影响观测数据 (y_i, x_i) 仍然为 iid,故仍可使用成对自助法(paired bootstrap)。

但残差自助法(residual bootstrap)却不成立,因为在条件异方差的情况下,扰动项不是 iid,故经验分布函数 F_n 不是总体分布函数F的一致估计,自助估计量也就不一致。

Wu(1986)与 Liu(1988)提出"野自助法"(wild bootstrap),对残差 $\{\hat{\varepsilon}_1, \hat{\varepsilon}_2, \dots, \hat{\varepsilon}_n\}$ 先进行线性变换再进行抽样,以满足从异方差的扰动项进行抽样的要求。

定义具有两点分布的新残差为:

$$\hat{\varepsilon}_{i}^{*} = \begin{cases} \frac{1-\sqrt{5}}{2}\hat{\varepsilon}_{i}, & \bigcup \frac{\sqrt{5}+1}{2\sqrt{5}} \text{的概率} \\ \frac{1+\sqrt{5}}{2}\hat{\varepsilon}_{i}, & \bigcup \frac{\sqrt{5}-1}{2\sqrt{5}} \text{的概率} \end{cases}$$

可以证明, $E(\hat{\varepsilon}_i^*) = 0$, $Var(\hat{\varepsilon}_i^*) = \hat{\varepsilon}_i^2$ 。

对 $\{\hat{\varepsilon}_1^*, \hat{\varepsilon}_2^*, \dots, \hat{\varepsilon}_n^*\}$ 进行再抽样,就是从异方差的扰动项进行抽样。

19.13 面板数据与时间序列的自助法

可使用成对自助法对个体i进行再抽样,而不对时间t进行再抽样,即如果抽中个体i,则个体i在所有时间的观测值都同时被抽中。

这种方法称为"分块自助法"(block bootstrap),对于非线性面板数据或聚类数据(clustered data)也适用。

由于自助法假定样本为 iid, 而时间序列数据通常存在自相关(故不是 iid), 因此针对时间序列的自助法更为复杂。

- 19.14 自助法的 Stata 命令
- 19.15 使用自助法进行稳健的豪斯曼检验