© 陈强,《高级计量经济学及 Stata 应用》课件,第二版,2014年,高等教育出版社。

第25章 非线性回归与门限回归

25.1 非线性最小二乘法

对于非线性回归模型,除了 MLE, 还可使用"非线性最小二乘法"(Nonlinear Least Square, 简记 NLS)。

考虑以下非线性回归模型:

$$y_i = g(\mathbf{x}_i, \boldsymbol{\beta}) + \varepsilon_i \quad (i = 1, \dots, n)$$

 β 为K维参数向量, $g(\cdot)$ 是 β 的非线性函数,且无法通过变量转换变为 β 的线性函数。

如果 $g(\mathbf{x}_i, \boldsymbol{\beta}) = \mathbf{x}_i' \boldsymbol{\beta}$,则回到古典线性回归模型。

记 $\tilde{\boldsymbol{\beta}}$ 为 $\boldsymbol{\beta}$ 的一个假想值,对应的残差为 $e_i = y_i - g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}})$ 。

非线性最小二乘法通过选择 $\tilde{m{eta}}$,使得残差平方和最小:

$$\min_{\tilde{\boldsymbol{\beta}}} SSR(\tilde{\boldsymbol{\beta}}) = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} \left[y_i - g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}}) \right]^2$$

最小化的一阶条件为

$$\frac{\partial \operatorname{SSR}(\tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}} = -2\sum_{i=1}^{n} \left[y_i - g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}}) \right] \frac{\partial g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}} = \mathbf{0}$$

可简化为

$$\sum_{i=1}^{n} \left[y_i - g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}}) \right] \frac{\partial g(\boldsymbol{x}_i, \tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}} = \mathbf{0}$$

$$\sum_{i=1}^{n} e_{i} \frac{\partial g(\mathbf{x}_{i}, \tilde{\boldsymbol{\beta}})}{\partial \tilde{\boldsymbol{\beta}}} = \mathbf{0}$$

这是一个K个方程、K个未知数的非线性方程组。

满足这个非线性方程组的估计量被称为"非线性最小二乘估计量",记为 $\hat{m{eta}}_{ exttt{NLS}}$ 。

残差向量e与 $\frac{\partial g(x,\tilde{\beta})}{\partial \tilde{\beta}}$ 正交,而不是与x正交(线性回归的情形)。

通常没有解析解,要用数值迭代方法求解,比如牛顿-拉夫森法。

例 考虑如下非线性回归模型:

$$y_i = \beta_1 + \beta_2 \exp(\beta_3 x_i) + \varepsilon_i$$

这个模型含有三个未知参数 $(\beta_1, \beta_2, \beta_3)$,即K=3。

使用 NLS 进行估计, 残差平方和为

$$\min_{\tilde{\beta}} SSR(\tilde{\beta}) = \sum_{i=1}^{n} \left[y_i - \tilde{\beta}_1 - \tilde{\beta}_2 \exp(\tilde{\beta}_3 x_i) \right]^2$$

NLS 估计量的一阶条件为

$$\frac{\partial SSR(\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_1} = -2\sum_{i=1}^n \left[y_i - \tilde{\beta}_1 - \tilde{\beta}_2 \exp(\tilde{\beta}_3 x_i) \right] = 0$$

$$\frac{\partial SSR(\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_2} = -2\sum_{i=1}^n \left[y_i - \tilde{\beta}_1 - \tilde{\beta}_2 \exp(\tilde{\beta}_3 x_i) \right] \exp(\tilde{\beta}_3 x_i) = 0$$

$$\frac{\partial SSR(\tilde{\boldsymbol{\beta}})}{\partial \tilde{\beta}_3} = -2\sum_{i=1}^n \left[y_i - \tilde{\beta}_1 - \tilde{\beta}_2 \exp(\tilde{\beta}_3 x_i) \right] \tilde{\beta}_2 x_i \exp(\tilde{\beta}_3 x_i) = 0$$

NLS 的大样本性质

如果 $E(\varepsilon_i | x_i) = 0$,再加上一些技术性条件,则 $\hat{\beta}_{NLS}$ 为 β 的一致估计量,且 $\hat{\beta}_{NLS}$ 服从渐近正态。

如果扰动项为球型扰动项,则 $\hat{\pmb{\beta}}_{NLS}$ 是渐近有效的(asymptotically efficient)。

25.2 非线性回归的 Stata 命令及实例

25.3 门限回归

考察回归系数是否稳定:将样本分成若干子样本分别回归,能否得到相近的估计系数?

对于时间序列,经济结构是否随着时间推移而改变(Chow test)?

对于横截面数据,比如,样本中有男性与女性,可根据性别将样本一分为二,分别估计男性样本与女性样本。

如果用来划分样本的变量是连续型变量,比如,企业规模、人均国民收入,则需要给出一个划分的标准,即"门限(门槛)值"(threshold level)。

例 在应用研究中,人们常常怀疑大企业与小企业的投资行为不同,那么如何区分大企业与小企业呢?

例 受到流动性约束(liquidity constraint)的企业与没有流动性约束企业的投资行为也可能不同,如何通过债务股本比(debt to equity ratio)或其他指标来区分这两类企业?

例 发达国家与发展中国家的经济增长规律可能不同,如何通过 人均国民收入这一指标来区分一个国家发达与否?

传统的做法由研究者主观确定一个门限值,把样本一分为二,既不对门限值进行参数估计,也不进行统计检验,结果并不可靠。

Hansen(2000)提出"门限(门槛)回归"(threshold regression),以严格的统计推断方法对门限值进行参数估计与假设检验。

假设样本数据为 $\{y_i, \boldsymbol{x}_i, q_i\}_{i=1}^n$ 。

 q_i 为用来划分样本的"门限变量"(threshold variable), q_i 可以是解释变量 x_i 的一部分:

$$\begin{cases} y_i = \boldsymbol{\beta}_1' \boldsymbol{x}_i + \boldsymbol{\varepsilon}_i, \stackrel{\text{若}}{\boldsymbol{\tau}} q_i \leq \boldsymbol{\gamma} \\ \\ y_i = \boldsymbol{\beta}_2' \boldsymbol{x}_i + \boldsymbol{\varepsilon}_i, \stackrel{\text{ដ}}{\boldsymbol{\tau}} q_i > \boldsymbol{\gamma} \end{cases}$$

其中, γ 为待估门限值, x_i 为外生解释变量,与 ε_i 不相关。将此分段函数合并写为

$$y_i = \beta_1' \underbrace{x_i \cdot \mathbf{1}(q_i \leq \gamma)}_{=z_{i1}} + \beta_2' \underbrace{x_i \cdot \mathbf{1}(q_i > \gamma)}_{=z_{i2}} + \varepsilon_i$$

可用 NLS 来估计。

如果 γ 已知,可定义 $\mathbf{z}_{i1} \equiv \mathbf{x}_i \cdot \mathbf{1}(q_i \leq \gamma)$ 与 $\mathbf{z}_{i2} \equiv \mathbf{x}_i \cdot \mathbf{1}(q_i > \gamma)$,将此方程转化为线性回归模型:

$$y_i = \boldsymbol{\beta}_1' z_{i1} + \boldsymbol{\beta}_2' z_{i2} + \varepsilon_i$$

实践中,常分两步来最小化残差平方和。

首先,给定 γ 的取值,用OLS估计 $\hat{\boldsymbol{\beta}}_1(\gamma)$ 与 $\hat{\boldsymbol{\beta}}_2(\gamma)(\hat{\boldsymbol{\beta}}_1与\hat{\boldsymbol{\beta}}_2$ 依赖于 γ),并计算残差平方和SSR(γ)(称为 Concentrated Sum of Squared Residuals),也是 γ 的函数。

其次,选择 γ 使得 $SSR(\gamma)$ 最小化。

给定 q_i ,由于示性函数 $\mathbf{1}(q_i \leq \gamma)$ 与 $\mathbf{1}(q_i > \gamma)$ 只能取值0或1,故是 γ 的阶梯函数,而"阶梯的升降点"正好是 q_i (只有一级"台阶")。

故SSR(γ)也是 γ 的阶梯函数,而阶梯的升降点恰好在 $\{q_i\}_{i=1}^n$ 不重叠的观测值上,因为如果 γ 取 $\{q_i\}_{i=1}^n$ 以外的其他值,不会对子样本的划分产生影响,故不改变SSR(γ)。

最多只需要考虑 γ 取n个值即可,即 $\gamma \in \{q_1, q_2, \dots, q_n\}$ 。

这使得SSR(y)的最小化计算得以简化。

记最后的参数估计量为 $(\hat{\boldsymbol{\beta}}_1(\hat{\gamma}), \hat{\boldsymbol{\beta}}_2(\hat{\gamma}), \hat{\gamma})$ 。

在一定的条件下,Hansen(2000)导出了 $\hat{\gamma}$ 的大样本渐近分布,在此基础上构造 $\hat{\gamma}$ 的置信区间,并对 $H_0: \gamma = \gamma_0$ 进行似然比检验。

类似地,可考虑包含"多个门限值"的门限回归。

比如,对于门限变量 q_i ,假设两个门限值为 $\gamma_1 < \gamma_2$,则门限回归模型为

$$y_i = \beta_1' x_i \cdot \mathbf{1}(q_i \le \gamma_1) + \beta_2' x_i \cdot \mathbf{1}(\gamma_1 < q_i \le \gamma_2) + \beta_3' x_i \cdot \mathbf{1}(q_i > \gamma_2) + \varepsilon_i$$

25.4 面板数据的门限回归

对于面板数据 $\{y_{it}, \mathbf{x}_{it}, q_{it}: 1 \le i \le n, 1 \le t \le T\}$,Hansen (1999)考虑了如下的固定效应门限回归模型:

其中, q_{it} 为门限变量(可以是 x_{it} 的一部分), γ 为门限值,扰动项 ε_{it} 为 iid。假设 x_{it} 为外生变量(不包含 y_{it} 的滞后值),与 ε_{it} 不相关。

将模型更简洁地表示为

$$y_{it} = \mu_i + \beta_1' \mathbf{x}_{it} \cdot \mathbf{1}(q_{it} \le \gamma) + \beta_2' \mathbf{x}_{it} \cdot \mathbf{1}(q_{it} > \gamma) + \varepsilon_{it}$$

假设n较大,T较小(短面板),故大样本的渐近理论基于" $n \to \infty$ "。

定义
$$\boldsymbol{\beta} \equiv \begin{pmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{pmatrix}$$
, $\boldsymbol{x}_{it}(\gamma) \equiv \begin{pmatrix} \boldsymbol{x}_{it} \cdot \mathbf{1}(q_{it} \leq \gamma) \\ \boldsymbol{x}_{it} \cdot \mathbf{1}(q_{it} > \gamma) \end{pmatrix}$, 则方程简化为

$$y_{it} = \mu_i + \boldsymbol{\beta}' \boldsymbol{x}_{it}(\gamma) + \varepsilon_{it}$$

对于个体i,将方程两边对时间求平均:

$$\overline{y}_i = \mu_i + \boldsymbol{\beta}' \overline{\boldsymbol{x}}_i(\gamma) + \overline{\varepsilon}_i$$

将两方程相减,可得离差形式:

$$y_{it} - \overline{y}_i = \beta' [x_{it}(\gamma) - \overline{x}_i(\gamma)] + (\varepsilon_{it} - \overline{\varepsilon}_i)$$

记
$$y_{it}^* \equiv y_{it} - \overline{y}_i$$
, $x_{it}^*(\gamma) \equiv x_{it}(\gamma) - \overline{x}_i(\gamma)$, $\varepsilon_{it}^* \equiv \varepsilon_{it} - \overline{\varepsilon}_i$, 则可得

$$y_{it}^* = \boldsymbol{\beta}' \boldsymbol{x}_{it}^* (\gamma) + \varepsilon_{it}^*$$

仍使用两步法进行估计。首先,给定 γ 的取值,用 OLS 进行一致估计(组内估计量),得到估计系数 $\hat{\boldsymbol{\beta}}(\gamma)$ 以及残差平方和SSR(γ)。

其次,对于 $\gamma \in \{q_{it}: 1 \le i \le n, 1 \le t \le T\}$ (γ 最多有nT 个可能取值),选择 $\hat{\gamma}$,使得SSR($\hat{\gamma}$)最小。最后得到估计系数 $\hat{\beta}$ ($\hat{\gamma}$)。

如果不希望某个子样本中的观测值过少,可限制 γ 的取值,比如不考虑 $\{q_{it}\}$ 中最大 5%或最小 5%的取值。

对于是否存在"门限效应"(threshold effect),可检验原假设:

$$H_0: \boldsymbol{\beta}_1 = \boldsymbol{\beta}_2$$

如果此原假设成立,则不存在门限效应,模型简化为

$$y_{it} = \mu_i + \beta_1' x_{it} + \varepsilon_{it}$$

对于这个标准的固定效应面板模型,将其转化为离差形式,然后用 OLS 来估计(组内估计量)。

记在" H_0 : $\beta_1 = \beta_2$ "约束下所得到的残差平方和为 SSR^* ,以区别于无约束的残差平方和 $SSR(\hat{\gamma})$ 。

显然, $SSR^* \geq SSR(\hat{\gamma})$ 。如果 $\left[SSR^* - SSR(\hat{\gamma})\right]$ 越大,加上约束条件后使得SSR增大越多,则越应该倾向于拒绝" $H_0: \beta_1 = \beta_2$ "。

Hansen (1999)提出使用以下似然比检验(LR)统计量:

$$LR \equiv \left[SSR^* - SSR(\hat{\gamma}) \right] / \hat{\sigma}^2$$

其中, $\hat{\sigma}^2 \equiv \frac{\text{SSR}(\hat{\gamma})}{n(T-1)}$ 为对扰动项方差的一致估计。

如果 " H_0 : $\boldsymbol{\beta}_1 = \boldsymbol{\beta}_2$ "成立,则不存在门限效应,也就无所谓门限值 γ 等于多少。

在 H_0 成立的情况下,无论 γ 取什么值,对模型都没有影响,故参数 γ 不可识别。

检验统计量LR的渐近分布并非标准的 χ^2 分布,而依赖于样本矩,无法将其临界值列表,但可用自助法得到临界值。

如果拒绝 " $H_0: \boldsymbol{\beta}_1 = \boldsymbol{\beta}_2$ ",认为存在门限效应,可进一步对门限值进行检验,即检验 " $H_0: \gamma = \gamma_0$ "。定义似然比检验统计量为

$$LR(\gamma) = \left[SSR(\gamma) - SSR(\hat{\gamma}) \right] / \hat{\sigma}^2$$

在" $H_0: \gamma = \gamma_0$ "成立的情况下, $LR(\gamma)$ 的渐近分布的累积分布函数为 $\left(1-e^{-x/2}\right)^2$,可直接算出临界值。可利用统计量 $LR(\gamma)$ 来计算 γ 的置信区间。

考虑多门限值的面板回归模型。以两个门限值为例:

$$y_{it} = \mu_i + \beta_1' x_{it} \cdot \mathbf{1}(q_{it} \leq \gamma_1) + \beta_2' x_{it} \cdot \mathbf{1}(\gamma_1 < q_{it} \leq \gamma_2) + \beta_3' x_{it} \cdot \mathbf{1}(q_{it} > \gamma_2) + \varepsilon_{it}$$
 其中,门限值 $\gamma_1 < \gamma_2$ 。

将这个模型转换为离差形式,仍用两步法进行估计。首先,给定(γ_1 , γ_2),使用 OLS 估计离差模型,得到残差平方和SSR(γ_1 , γ_2)。 其次,选择(γ_1 , γ_2)使得SSR(γ_1 , γ_2)最小化。