第26章 分位数回归

26.1 为什么需要分位数回归

一般的回归模型着重考察x对y的条件期望E(y|x)的影响,实际上是均值回归。

但我们关心x对整个条件分布y|x的影响,而E(y|x)只是刻画条件分布y|x集中趋势的一个指标而已。

如果y|x不是对称分布,则E(y|x)很难反映条件分布的全貌。

1

如能够估计条件分布y|x的若干重要的条件分位数(conditional quantiles),比如中位数(median)、1/4分位数(lower quartile)、3/4分位数(upper quartile),能更全面认识条件分布y|x。

使用 OLS 进行"均值回归",由于最小化的目标函数为残差平方和($\sum_{i=1}^{n} e_i^2$),故易受极端值影响。

Koenker and Bassett(1978) 提出"分位数回归"(Quantile Regression,简记 QR),使用残差绝对值的加权平均(比如, $\sum_{i=1}^{n} |e_i|$)作为最小化的目标函数,不易受极端值影响,较为稳健。

分位数回归还能提供关于条件分布 y|x 的全面信息。

26.2 总体分位数

假设Y为连续型随机变量,其累积分布函数为 $F_{v}(\cdot)$ 。

Y的"总体 q 分位数"(population q^{th} quantile, 0 < q < 1),记为 y_q ,满足以下定义式:

$$q = P(Y \le y_q) = F_y(y_q)$$

总体q分位数 y_q 正好将总体分布分为两部分,其中小于或等于 y_q 的概率为q,而大于 y_q 的概率为(1-q)。

如果q=1/2,则为中位数,正好将总体分为两个相等的部分。 如果 $F_{v}(\cdot)$ 严格单调递增,则有

$$y_q = F_y^{-1}(q)$$

其中, $F_y^{-1}(\cdot)$ 为 $F_y(\cdot)$ 的逆函数,参见图 26.1。

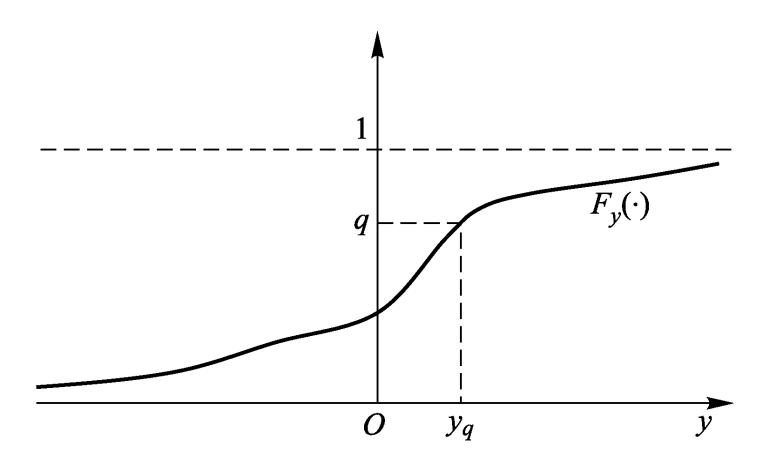


图 26.1 总体 q 分位数与累积分布函数

对于回归模型,记条件分布y|x的累积分布函数为 $F_{y|x}(\cdot)$ 。

条件分布y|x的总体q分位数,记为 y_a ,满足以下定义式:

$$q = F_{y|x}(y_q)$$

假设 $F_{v|x}(\cdot)$ 严格单调递增,则有

$$y_q = F_{y|x}^{-1}(q)$$

由于条件累积分布函数 $F_{y|x}(\cdot)$ 依赖于x,故条件分布y|x的总体 q 分位数 y_q 也依赖于x,记为 $y_q(x)$,称为"条件分位数函数" (conditional quantile function)。

对于线性回归模型,如果扰动项满足同方差的假定,或扰动项异方差的形式为乘积形式,则 $y_q(x)$ 是x的线性函数。

考虑以下模型:

$$y = \mathbf{x}'\boldsymbol{\beta} + u$$
$$u = \mathbf{x}'\boldsymbol{\alpha} \cdot \boldsymbol{\varepsilon}$$
$$\boldsymbol{\varepsilon} \sim \operatorname{iid}(0, \sigma^2)$$

不失一般性,假设 $x'\alpha > 0$ 。

如果 $x'\alpha$ 为常数,则扰动项u为同方差;反之,则为乘积形式的异方差。

根据定义,条件分位数函数 $y_q(x)$ 满足

$$q = P\{y \le y_q(x)\} \qquad (条件分位数的定义)$$

$$= P\{x'\beta + u \le y_q(x)\} \qquad (代入 y = x'\beta + u)$$

$$= P\{u \le y_q(x) - x'\beta\} \qquad (移项)$$

$$= P\{x'\alpha \cdot \varepsilon \le y_q(x) - x'\beta\} \qquad (代入 u = x'\alpha \cdot \varepsilon)$$

$$= P\{\varepsilon \le \frac{y_q(x) - x'\beta}{x'\alpha}\} \qquad (两边同除以 x'\alpha > 0)$$

$$= F_{\varepsilon}\left(\frac{y_q(x) - x'\beta}{x'\alpha}\right) \qquad (累积分布函数的定义)$$

其中, $F_{\varepsilon}(\cdot)$ 为 ε 的累积分布函数。因此,

$$\frac{y_q(\mathbf{x}) - \mathbf{x}'\boldsymbol{\beta}}{\mathbf{x}'\boldsymbol{\alpha}} = F_{\varepsilon}^{-1}(q)$$

$$y_q(\mathbf{x}) = \mathbf{x}'\boldsymbol{\beta} + \mathbf{x}'\boldsymbol{\alpha}F_{\varepsilon}^{-1}(q) = \mathbf{x}'\Big[\boldsymbol{\beta} + \boldsymbol{\alpha}F_{\varepsilon}^{-1}(q)\Big]$$

故 $y_q(x)$ 是x的线性函数。

在同方差的情况下, $x'\alpha$ 为常数,所有条件分位数函数 $\{y_q(x), 0 < q < 1\}$ 的斜率都等于 β ,只有截距项 $x'\alpha F_{\varepsilon}^{-1}(q)$ 依赖于q。

一般地,条件分位数函数的"斜率"也依赖于q,记为 $\boldsymbol{\beta}_q$ 。

在下文中,假设条件分位数函数是解释变量x的线性函数。

26.3 样本分位数

对于随机变量Y,如果总体的 q 分位数 y_q 未知,可使用样本 q 分位数 \hat{y}_q 来估计 y_q 。

将样本数据 $\{y_1, y_2, ..., y_n\}$ 按从小到大的顺序排列为 $\{y_{(1)}, y_{(2)}, ..., y_{(n)}\}$ 。

 \hat{y}_q 等于第[nq]个最小观测值,其中n为样本容量,[nq]表示大于或等于nq而离nq最近的正整数。

【例】
$$n = 97$$
, $q = 0.25$,则 $[nq] = [97 \times 0.25] = [24.25] = 25$ 。

但这种方法不易推广到回归模型。

一种等价方法是,将样本分位数看成是某最小化问题的解。

样本均值也可看成是最小化残差平方和的解:

$$\min_{\mu} \sum_{i=1}^{n} (y_i - \mu)^2 \quad \Rightarrow \quad \mu = \overline{y} \equiv \frac{1}{n} \sum_{i=1}^{n} y_i$$

样本中位数可视为"最小化残差绝对值之和"问题的解:

$$\min_{\mu} \sum_{i=1}^{n} |y_i - \mu| \implies \mu = \text{median}\{y_1, y_2, \dots, y_n\}$$

为什么求解这个最小化问题会得到样本中位数呢?

因为只要μ的取值偏离中位数,就会使得残差绝对值之和上升。

例 考虑一个样本容量为 99 的样本,假设其样本中位数(即第 50 个最小观测值)为 10,参见图 26.2。

假设第 51 个最小观测值为 12。如让 μ =12而不是 10,则对于前 50 个观测值而言,其残差绝对值 $|y_i - \mu|$ 都将增加 2;

对于后 49 个观测值而言,其残差绝对值 $|y_i - \mu|$ 都将减少 2。

故总变动为 $(50\times2)-(49\times2)=2$,故第 51 个最小观测值不如第 50 个最小观测值(中位数)更能使目标函数最小化。

同理,第49个最小观测值也不如第50个最小观测值。

由此可知,第50个最小观测值(中位数)是最优解。

命题 可以将样本 q 分位数视为以下最小化残差绝对值的加权 平均问题的最优解:

$$\min_{\mu} \sum_{i:y_i \ge \mu}^{n} q |y_i - \mu| + \sum_{i:y_i < \mu}^{n} (1 - q) |y_i - \mu| \implies \mu = \hat{y}_q$$

例 如果q = 1/4,则满足" $y_i \ge \mu$ "条件的观测值只得到1/4的权重,而满足" $y_i < \mu$ "条件的其余观测值则得到3/4的权重。

因为估计的是1/4分位数(位于总体的底部), 故较大的观测值得到的权重较小, 而较小的观测值得到的权重较大。

证明:将目标函数中的绝对值去掉可得

$$\min_{\mu} \sum_{i:y_i \ge \mu}^{n} q(y_i - \mu) + \sum_{i:y_i < \mu}^{n} (1 - q)(\mu - y_i)$$

对μ求一阶导数可得

$$\sum_{i:y_i \ge \mu}^n q(-1) + \sum_{i:y_i < \mu}^n (1 - q) = 0$$

假设 $y_{(k)} < \mu \le y_{(k+1)}$,其中 $y_{(k)}$ 为第k个最小观测值,则共有k个观测值满足" $y_i < \mu$ ",(n-k)个观测值满足" $y_i \ge \mu$ ",故

$$-(n-k)q + k(1-q) = 0$$

经整理可得

$$k = nq$$

k必须是整数。故最优解 $\mu = y_{([nq])} = \hat{y}_q$,即样本分位数。

为证明二阶条件满足,只要说明目标函数为凸函数即可。

定义函数 $\rho_q(\cdot)$ 为

$$\rho_{q}(y_{i} - \mu) \equiv \begin{cases} q | y_{i} - \mu |, \stackrel{\text{red}}{=} y_{i} \geq \mu \\ \\ (1 - q) | y_{i} - \mu |, \stackrel{\text{red}}{=} y_{i} < \mu \end{cases}$$

函数 $\rho_q(y_i - \mu)$ 的形状如图 26.3。

称为"倾斜的绝对值函数"(tilted absolute value function)或"打钩函数"(check function)。

从图形易知, $\rho_q(\cdot)$ 为凸函数。而目标函数可以写为 $\sum_{i=1}^n \rho_q(y_i - \mu)$,即n个凸函数之和,故仍是凸函数。

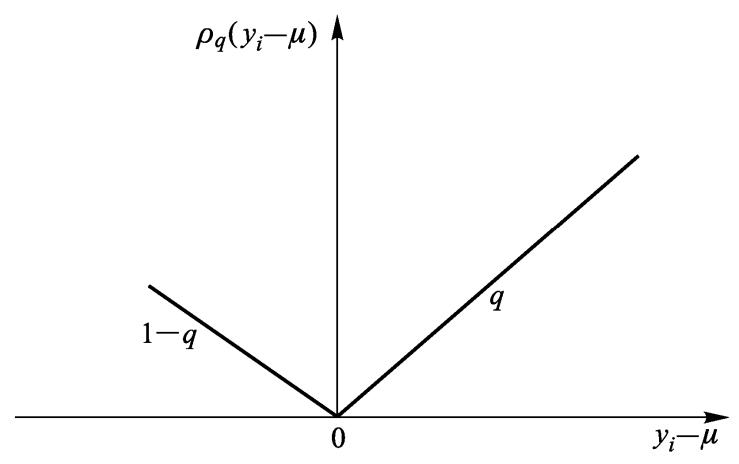


图 26.3 打钩函数 $ho_q(\cdot)$ 及其斜率

26.4 分位数回归的估计方法

将单变量情形下对样本分位数的估计方法推广到线性回归。

假设条件分布y|x的总体q分位数 $y_q(x)$ 是x的线性函数:

$$y_q(\mathbf{x}_i) = \mathbf{x}_i' \boldsymbol{\beta}_q$$

其中, $\boldsymbol{\beta}_q$ 称为"q分位数回归系数",其估计量 $\hat{\boldsymbol{\beta}}_q$ 由以下最小化问题来定义:

$$\min_{\beta_{q}} \sum_{i: y_{i} \geq x_{i}' \beta_{q}}^{n} q |y_{i} - x_{i}' \beta_{q}| + \sum_{i: y_{i} < x_{i}' \beta_{q}}^{n} (1 - q) |y_{i} - x_{i}' \beta_{q}|$$

如果q=1/2,则为"中位数回归" (median regression):

$$\min_{\boldsymbol{\beta}_q} \quad \sum_{i=1}^n \left| y_i - \boldsymbol{x}_i' \boldsymbol{\beta}_q \right|$$

中位数回归也称为"最小绝对离差估计量"(Least Absolute Deviation Estimator,简记 LAD)。

它比均值回归(OLS)更不易受到极端值的影响,更加稳健。

由于分位数回归的目标函数带有绝对值,不可微分,通常使用线性规划的方法来计算 $\hat{m{eta}}_a$ 。

样本分位数回归系数 $\hat{\boldsymbol{\beta}}_q$ 是总体分位数回归系数 $\boldsymbol{\beta}_q$ 的一致估计量,且服从渐近正态分布:

$$\sqrt{n}(\hat{\boldsymbol{\beta}}_q - \boldsymbol{\beta}_q) \xrightarrow{d} N(\boldsymbol{0}, \text{Avar}(\hat{\boldsymbol{\beta}}_q))$$

其中,渐近方差 $\text{Avar}(\hat{\boldsymbol{\beta}}_q) = \boldsymbol{A}^{-1}\boldsymbol{B}\boldsymbol{A}^{-1}$ (夹心估计量), $\boldsymbol{A} = \underset{n \to \infty}{\text{plim}} \frac{1}{n} \sum_{i=1}^n f_{u_q}(0 \mid \boldsymbol{x}_i) \boldsymbol{x}_i \boldsymbol{x}_i', \boldsymbol{B} = \underset{n \to \infty}{\text{plim}} \frac{1}{n} \sum_{i=1}^n q(1-q) \boldsymbol{x}_i \boldsymbol{x}_i', \ \overline{n} f_{u_q}(0 \mid \boldsymbol{x}_i)$ 是扰动项 $u_q = y - \boldsymbol{x}' \boldsymbol{\beta}_q$ 的条件密度函数在 $u_q = 0$ 处的取值。

要计算 $Avar(\hat{\boldsymbol{\beta}}_q)$,首先要估计 $f_{u_q}(0|\boldsymbol{x}_i)$ 。这是Stata 的默认方法。Stata 也提供自助法作为计算 $Avar(\hat{\boldsymbol{\beta}}_q)$ 的另一方法。

对于q分位数回归,可使用准 R^2 度量其拟合优度,其定义为:

$$1 - \frac{\sum_{i: \ y_{i} \geq x_{i}' \hat{\boldsymbol{\beta}}_{q}}^{n} q \left| y_{i} - \boldsymbol{x}_{i}' \hat{\boldsymbol{\beta}}_{q} \right| + \sum_{i: \ y_{i} < x_{i}' \hat{\boldsymbol{\beta}}_{q}}^{n} (1 - q) \left| y_{i} - \boldsymbol{x}_{i}' \hat{\boldsymbol{\beta}}_{q} \right|}{\sum_{i: \ y_{i} \geq \hat{y}_{q}}^{n} q \left| y_{i} - \hat{y}_{q} \right| + \sum_{i: \ y_{i} < \hat{y}_{q}}^{n} (1 - q) \left| y_{i} - \hat{y}_{q} \right|}$$

其中, \hat{y}_q 为样本q分位数,上式第二项的分子为q分位数回归目标函数的最小值(sum of weighted deviations about estimated quantiles),而分母为"sum of weighted deviations about raw quantiles"。