第27章 非参数与半参数估计

27.1 为什么需要非参数与半参数估计

"参数估计法"(parametric estimation)假设总体服从带未知参数的某个分布(比如正态),或具体的回归函数,然后估计这些参数。

其缺点是,对模型设定所作的假定较强,可能导致较大的设定误差,不够稳健。

"非参数估计法"(nonparametric estimation)一般不对模型的具体分布或函数形式作任何假定,更为稳健。

缺点是要求样本容量较大,且估计量收敛的速度较慢。

作为折衷,同时包含参数部分与非参数部分的"半参数方法" (semiparametric estimation),降低对样本容量的要求,又有一定稳健性。

非参及半参方法与传统的参数法互补;后者不太适用时,可考虑前者。

27.2 对密度函数的非参数估计

考虑根据样本数据来推断总体的分布,即密度函数。

如用参数估计法,则先对总体分布的具体形式进行假定。

比如,假设总体服从正态分布 $N(\mu, \sigma^2)$,然后估计参数 (μ, σ^2) 。如果真实总体与正态分布相去甚远,则统计推断有较大偏差。

如不假设总体分布的具体形式,则为非参数方法。

最原始的非参数方法是画直方图,即将数据的取值范围等分为 若干组,计算数据落入每组的频率,以此画图,作为对密度函数 的估计。 直方图的缺点是,即使随机变量连续,直方图始终是不连续的阶梯函数。

为得到对密度函数的光滑估计, Rosenblatt(1956)提出"核密度估计法"(kernel density estimation)。

首先考察直方图的数学本质。假设要估计连续型随机变量x在 x_0 处的概率密度 $f(x_0)$ 。

概率密度 $f(x_0)$ 是累积分布函数 F(x) 在 x_0 处的导数:

$$f(x_0) = \lim_{h \to 0} \frac{F(x_0 + h) - F(x_0 - h)}{2h}$$
$$= \lim_{h \to 0} \frac{P(x_0 - h < x < x_0 + h)}{2h}$$

对于样本 $\{x_1, x_2, \dots, x_n\}$,用数据落入区间 $(x_0 - h, x_0 + h)$ 的频率来估计概率 $P(x_0 - h < x < x_0 + h)$,得到直方图估计量:

$$\hat{f}_{HIST}(x_0) = \frac{\sum_{i=1}^{n} \mathbf{1}(x_0 - h < x_i < x_0 + h) / n}{2h}$$
$$= \frac{1}{nh} \sum_{i=1}^{n} \frac{1}{2} \cdot \mathbf{1} \left\{ \left| \frac{x_i - x_0}{h} \right| < 1 \right\}$$

 $\hat{f}_{HIST}(x_0)$ 对于区间 $(x_0 - h, x_0 + h)$ 内的观测值给予相同权重,而区间外的观测值权重为 0。

区间半径h定义了"在 x_0 附近邻域的大小",称为"带宽" (bandwidth)。2h称为"窗宽" (window width)。

直方图得不到光滑的密度估计,根本原因在于使用示性函数作为"权重函数"(weighting function),以及各组间不允许交叠。

核密度估计法使用更一般的权重函数,并允许各组之间交叠。

核密度估计量为

$$\hat{f}(x_0) = \frac{1}{nh} \sum_{i=1}^{n} K[(x_i - x_0)/h]$$

函数 $K(\cdot)$ 称为"核函数"(kernel function),本质上就是权重函数。

带宽h越大,在 x_0 附近邻域越大,则估计的密度函数 $\hat{f}(x)$ 越光滑,故称带宽h为"光滑参数" (smoothing parameter)。

- 一般假设核函数K(z)满足以下性质:
 - (i) K(z)连续且关于原点对称(偶函数);

(ii)
$$\int_{-\infty}^{+\infty} K(z) dz = 1, \quad \int_{-\infty}^{+\infty} z K(z) dz = 0, \quad \int_{-\infty}^{+\infty} |K(z)| dz < +\infty;$$

- (iii) 或者①存在 $z_0 > 0$,使得当 $|z| > z_0$ 时, K(z) = 0;或者②当 $|z| \to +\infty$ 时, $|z| K(z) \to 0$;
 - (iv) $\int_{-\infty}^{+\infty} z^2 K(z) dz = \gamma$, 其中 γ 为常数。

条件(ii)要求核函数的曲线下面积为 1,并满足一些有界条件。

条件(iii)①比条件(iii)②更强,实践中常采用条件(iii)①。常将邻

域 $[-z_0,z_0]$ 标准化为[-1,1]。条件(iv)也是有界条件。

常见核函数见表 27.1。这些核函数的共同特点是, 离原点越近, 则核函数取值越大, 并在原点达到最大; 即越近的点权重越大。

其中,均匀核也用于直方图,只是在用均匀核进行核密度估计时并不固定分组,而在每个点上进行估计。

最流行的核函数为二次核(也称 Epanechnikov 核)与高斯核。

表 27.1 常用的核函数

核函数名称	核函数的数学形式	δ
均匀核 (uniform or rectangular)	$\frac{1}{2} \cdot 1(z < 1)$	1.3510
三角核 (triangular or Bartlett)	$(1-\left z\right)\cdot1(\left z\right <1)$	
伊番科尼可夫核 (Epanechnikov) 或二次核(quadratic)	$\frac{3}{4}(1-z^2)\cdot1(\left z\right <1)$	1.7188
四次核(quartic)	$\frac{15}{16}(1-z^2)^2 \cdot 1(z < 1)$	2.0362

或双权核(biweight)		
三权核(Triweight)	$\frac{35}{32}(1-z^2)^3 \cdot 1(z < 1)$	2.3122
三三核(Tricubic)	$\frac{70}{81}(1- z ^3)^3 \cdot 1(z <1)$	
高斯核 (Gaussian or Normal)	$\frac{1}{\sqrt{2\pi}}\exp\{-z^2/2\}$	0.7764

注: 其中 δ 为用来计算 "Silverman 嵌入估计"的常数。

给定核函数 $K(\cdot)$ 与带宽h,可估计核密度 $\hat{f}(x_0)$ 。在 Stata 中,默认设置为在等距离的 $\min(n,50)$ 个点来计算 $\hat{f}(x_0)$,然后连成光滑的密度函数。

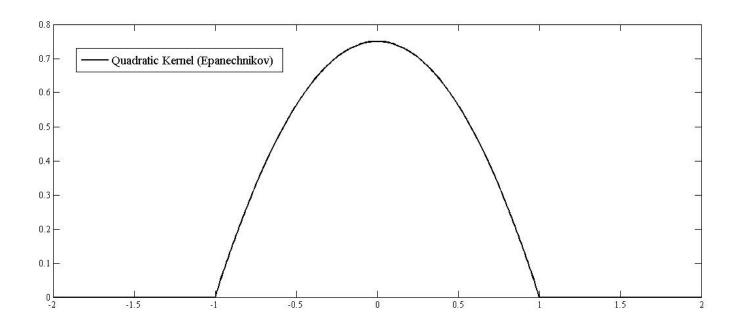


图 27.1 二次核(Epanechnikov 核)

27.3 核密度估计的性质

由于核密度估计使用了在 x_0 附近的点x来估计 $\hat{f}(x_0)$,而一般地,如果 $x \neq x_0$,则 $f(x) \neq f(x_0)$,故核密度估计通常是有偏的:

Bias
$$(x_0) = E[\hat{f}(x_0)] - f(x_0) \approx \frac{1}{2}h^2 f''(x_0) \int_{-\infty}^{+\infty} z^2 K(z) dz$$

即偏差与 h^2 成正比,为 h^2 的同阶无穷小,记为 $O(h^2)$ 。

带宽h越大,则将使用离 x_0 更远的点在估计 $f(x_0)$,导致偏差增大(以 h^2 的速度迅速上升)。

密度函数的二阶导数 $f''(x_0)$ 越大,即在 x_0 处的曲率越大,则 x_0 附近的函数值波动越大,也会引起偏差增大。

偏差还取决于核函数K(z)。

核密度估计的方差为:

$$\operatorname{Var}\left[\hat{f}(x_0)\right] = \frac{1}{nh} f(x_0) \int_{-\infty}^{+\infty} K(z)^2 dz + o(1/nh)$$

故
$$Var[\hat{f}(x_0)] = O(1/nh)$$
,是 $(1/nh)$ 的同阶无穷小。

样本容量n越大,则方差越小;

带宽h越大,由于使用了更多观测点来估计 $f(x_0)$,故方差越小。

 $\exists n \to \infty$ 时,让 $nh \to \infty$ (虽然 $h \to 0$,但h趋于 0 的速度比样本容量 $n \to \infty$ 的速度更慢),则此方差将在大样本中消失。

核密度估计的一致性

当 $n \to \infty$ 时,让带宽 $h \to 0$ 且 $nh \to \infty$,则偏差 $Bias(x_0)$ 与方差 $Var[\hat{f}(x_0)]$ 在大样本下都趋于0。根据均方收敛可知, $\hat{f}(x_0)$ 是 $f(x_0)$ 的一致估计量。

核密度估计的渐近正态性

如果核函数K(z)的条件(iv)满足,则 $\hat{f}(x_0)$ 服从渐近正态分布:

$$\sqrt{nh} \left[\hat{f}(x_0) - f(x_0) - \text{Bias}(x_0) \right] \xrightarrow{d} N \left(0, f(x_0) \int_{-\infty}^{+\infty} K(z)^2 dz \right)$$

据此可进行区间估计。

核密度估计量的收敛速度为√nh。

由于最优带宽 h^* 与 $n^{-0.2}$ 成正比(参见下节),故

$$\sqrt{nh} = \sqrt{n \cdot n^{-0.2}} = \sqrt{n^{0.8}} = n^{0.4} < n^{0.5} = \sqrt{n}$$

这意味着非参估计量的收敛速度 $n^{0.4}$ 慢于参数估计量的通常收敛速度 $n^{0.5}$ 。

27.4 最优带宽

如果带宽h越大,则 x_0 附近的邻域越大,故偏差也越大(偏差与 h^2 成正比);而带宽h越大,则 $\hat{f}(x_0)$ 越光滑,即方差 $Var[\hat{f}(x_0)]$ 越小。

在选择"最优带宽"(optimal bandwidth) h^* 时,希望最小化均方误差(MSE),即方差与偏差平方之和:

$$\min_{h} MSE[\hat{f}(x_0)] = [Bias(x_0)]^2 + Var[\hat{f}(x_0)]$$

由 于 $\operatorname{Bias}(x_0) = O(h^2)$, 故 $\left[\operatorname{Bias}(x_0)\right]^2 = O(h^4)$, 而 $\operatorname{Var}\left[\hat{f}(x_0)\right] = O(1/nh)$,故此最小化问题可大致写为

$$\min_{h} MSE \left[\hat{f}(x_0) \right] = k_1 h^4 + \left(k_2 / nh \right)$$

其中, k_1 , k_2 为常数。对h求导,可得一阶条件为

$$4k_1h^3 + k_2\frac{1}{n}(-1/h^2) = 0$$

$$h = (4k_1/k_2)^{-0.2} n^{-0.2}$$

故最优带宽为 $h^* = O(n^{-0.2})$ 。

随着 n 增大, $n^{-0.2} = 1/\sqrt[5]{n}$ 的下降速度远慢于 $n^{-1} = 1/n$ 。

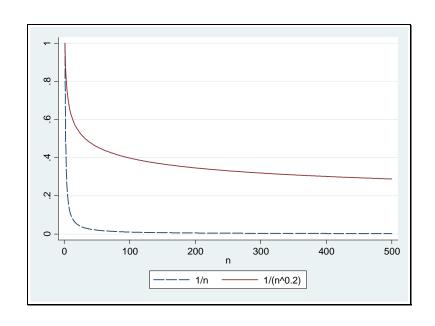


图 27.2 对比 $n^{-0.2}$ 与 n^{-1} 的下降速度

$$\stackrel{\text{def}}{=} n \rightarrow \infty \text{ iff}, \quad h^* \rightarrow 0, \quad \overrightarrow{\text{min}} nh^* = n \cdot O(n^{-0.2}) = O(n^{0.8}) \rightarrow \infty.$$

选择最优带宽h*,就能保证核密度估计的一致性。

均方误差 $MSE[\hat{f}(x_0)]$ 仍取决于 x_0 。为得到对于 x_0 所有可能取值的整体度量,可最小化"积分均方误差"(Integrated Mean Squared Error,简记 IMSE):

$$\min_{h} IMSE = \int_{-\infty}^{+\infty} MSE \left[\hat{f}(x_0) \right] dx_0$$

Silverman(1986)证明最优带宽为:

$$h^* = \delta \left[\int_{-\infty}^{+\infty} f''(x_0)^2 dx_0 \right]^{-0.2} n^{-0.2}$$

其中,常数
$$\delta = \left[\int_{-\infty}^{+\infty} K(z)^2 dz / \left(\int_{-\infty}^{+\infty} z^2 K(z) dz \right)^2 \right]^{0.2}$$
 仅依赖于核函数。

最优带宽 h^* 还取决于密度函数的曲率 $(f''(x_0))$ 。

当密度函数波动较大时,将带来较大偏差,故最优带宽h*较小。

由于 δ 依赖于核函数,故最优带宽 h^* 也依赖于核函数。

对于不同的核函数分别使用相应的最优带宽,则积分均方误差 $IMSE(h^*)$ 差别不大。

能使 IMSE(h*) 最小化的核函数为"伊番科尼可夫核" (Epanechnikov),是 Stata 默认的核函数,但只有微弱优势。

对于最优带宽的选择远比核函数的选择更重要。使用不同核函数得到的密度估计一般非常接近。

最优带宽 h^* 仍依赖于 $f''(x_0)$ 。如果样本来自正态总体,则 $\int_{-\infty}^{+\infty} f''(x_0)^2 dx_0 = 3/(8\sqrt{\pi}\sigma^5) = 0.2116/\sigma^5$,故

$$h^* = 1.3643 \,\delta \, n^{-0.2} s$$

其中,s为样本标准差。为了防止样本标准差受极端值的影响,常使用"Silverman 嵌入估计"(Silverman's plug-in estimate):

$$h^* = 1.3643 \delta n^{-0.2} \min(s, iqr/1.349)$$

其中,"*iqr*"为样本四分位距(sample interquartile range),即样本3/4分位数与1/4分位数之间的距离。

为保险起见,可比较两倍嵌入估计与一半嵌入估计的效果。

实践中也常使用"眼球法"(eyeball method):

用肉眼对带宽进行判断,是否密度函数"过度光滑"(oversmoothed)或"不够光滑"(undersmoothed),再微调到合适的带宽。

27.5 多元密度函数的核估计

对于k维随机变量x,可进行"多元密度函数的核估计":

$$\hat{f}(x_0) = \frac{1}{nh} \sum_{i=1}^{n} K[(x_i - x_0)/h]$$

其中, $K(\cdot)$ 是 k 维核函数,即权重函数。 $K(\cdot)$ 通常为一维核函数的乘积,也可使用多维正态的密度函数。

多元密度函数核估计的性质与一元情形相似。但最优带宽为 $h^* = O(n^{-1/(k+4)})$ (大于一元情形下的最优带宽),而 $\hat{f}(x_0)$ 的收敛速度 也更慢。

在多维情况下,易出现"数据稀疏"问题(sparseness of data),即在 x_0 附近的观测点很少。

估计多维密度函数的用途之一是估计条件密度函数(conditional density function)。

由于条件密度f(y|x) = f(x,y)/f(x),

故可用 $\hat{f}(y|x) = \hat{f}(x,y)/\hat{f}(x)$ 作为条件密度的估计量,

其中, $\hat{f}(x,y)$ 与 $\hat{f}(x)$ 分别为二维与一维的密度函数核估计。

27.6 非参数核回归

考虑以下非参数一元回归模型:

$$y_i = m(x_i) + \varepsilon_i$$
$$\varepsilon_i \sim iid(0, \sigma_{\varepsilon}^2)$$

其中, m(·)是未知函数(连函数形式也未知)。

对于每一个i ($i=1,\dots,n$),分别估计 $m(x_i)$,从而得到对回归函数 m(x)的估计。不寻求m(x)的解析解,而是寻找其数值解。

假设对于x的某个特定取值,比如 x_0 ,都有若干个y的观测值,比如 n_0 个。则可把这 n_0 个y观测值的平均值作为 $m(x_0)$ 的估计量。

现实数据中, n_0 可能很小(对于连续变量,可能仅为 1),导致估计量的方差过大。

解决方法是,对 x_0 附近邻域中的观测值也进行加权平均,即"局部加权平均估计量" (local weighted average estimator):

$$\hat{m}(x_0) = \sum_{i=1}^n w_{i0, h} y_i$$

其中,权重 $w_{i0,h}$ 是 (x_i, x_0, h) 的函数,即 $w_{i0,h} = w(x_i, x_0, h)$,且满足 $\sum_{i=1}^{n} w_{i0,h} = 1. \quad x_i \in X_0$ 附近的点,而h是带宽。

Nadaraya(1964)与 Watson(1964) 使用核函数来定义以下权重,得到"核回归估计量"(kernel regression estimator):

$$w_{i0,h} = \frac{K[(x_i - x_0)/h]}{\sum_{i=1}^{n} K[(x_i - x_0)/h]}$$

故核回归估计量可写为

$$\hat{m}(x_0) = \frac{\sum_{i=1}^{n} K[(x_i - x_0)/h] y_i}{\sum_{i=1}^{n} K[(x_i - x_0)/h]}$$

由于使用了 x_0 附近邻域的信息,核回归估计量 $\hat{n}(x_0)$ 有偏:

Bias
$$(x_0) = E[\hat{m}(x_0)] - m(x_0) = h^2 \left[m'(x_0) \frac{f'(x_0)}{f(x_0)} + \frac{1}{2} m''(x_0) \right] \int_{-\infty}^{+\infty} z^2 K(z) dz$$

故 $Bias(x_0) = O(h^2)$ 。核回归估计的方差为

$$\operatorname{Var}\left[\hat{m}(x_0)\right] = \frac{1}{nh} \frac{\sigma_{\varepsilon}^2}{f(x_0)} \int_{-\infty}^{+\infty} K(z)^2 dz + o(1/nh)$$

故 $\operatorname{Var}[\hat{m}(x_0)] = O(1/nh)$ 。

 $\exists n \to \infty$ 时,让带宽 $h \to 0$,且 $nh \to \infty$,则根据均方收敛,核回

归估计是一致的。

如果 $\{x_1, x_2, \dots, x_n\}$ 为 iid,则核回归估计量 $\hat{m}(x_0)$ 服从渐近正态:

$$\sqrt{nh} \left[\hat{m}(x_0) - m(x_0) - \text{Bias}(x_0) \right] \xrightarrow{d} N \left(0, \frac{\sigma_{\varepsilon}^2}{f(x_0)} \int_{-\infty}^{+\infty} K(z)^2 dz \right)$$

由于Bias $(x_0) = O(h^2)$ 且Var $[\hat{m}(x_0)] = O(1/nh)$,最小化 IMSE 的结果显示,最优带宽为 $h^* = O(n^{-0.2})$ 。

最优带宽 h^* 取决于待估计回归函数的导数(因为 $m'(x_0), m''(x_0)$ 出现在偏差的表达式中),而估计 $m'(x_0), m''(x_0)$ 又需指定最优带宽 h^* 。

实践中常使用"交叉核实"(Cross Validation,简记 CV)的方法来确定最优带宽 h^* 。

基本思想:在估计 $\hat{m}(x_i)$ 时,不使用 y_i 的信息,看其余观测值预测 y_i 的能力有多强;而这个能力又取决于带宽h。故选择带宽h,使得此预测能力最强,即最小化以下目标函数:

$$\min_{h} \quad \text{CV}(h) = \sum_{i=1}^{n} [y_i - \hat{m}_{-1}(x_i)]^2 \pi(x_i)$$

其中, $\hat{m}_{-1}(x_i) = \frac{\sum_{j \neq i} w_{ji,h} y_j}{\sum_{j \neq i} w_{ji,h}}$ 是对 $m(x_i)$ 的"去掉一个观测值"估计

量(leave-one-out estimate),即 $j = 1, \dots, n$,但 $j \neq i$ 。

 $\pi(x_i)$ 是权重函数(weighting function),主要是为了给边界附近的

端点更小的权重,以避免扭曲。比如,不考虑 x_i 的 5%分位数以下与 95%分位数以上的观测值,即对这些观测值令 $\pi(x_i)=0$ 。

之所以去掉自身第i个观测值是因为,如果将它保留,则总可以选择足够小的带宽h使得对于任何i,都有 $\hat{m}(x_i) = y_i$,故CV(h) = 0得到最小化。

可以证明,最小化CV(h)与最小化 IMSE 是渐近等价的。

交叉核实并非决定最优带宽的完美方法,仍常辅之以眼球法。

能使 IMSE(h*) 最小化的核函数为"伊番科尼可夫核" (Epanechnikov), 但只有微弱优势。

27.7 多元核回归

对于k维解释向量x,考虑如下非参数多元回归模型:

$$y_i = m(\boldsymbol{x}_i) + \varepsilon_i = m(x_{1i}, x_{2i}, \dots, x_{ki}) + \varepsilon_i$$

其中, $m(\cdot)$ 是未知的多元函数。在 x_0 处的核回归估计量为

$$\hat{m}(\mathbf{x}_0) = \frac{\sum_{i=1}^{n} K[(\mathbf{x}_i - \mathbf{x}_0)/h] y_i}{\sum_{i=1}^{n} K[(\mathbf{x}_i - \mathbf{x}_0)/h]}$$

其中, $K(\cdot)$ 为k维核函数。

多元核回归估计量的性质与一元核回归相似。

但最优带宽为 $h^* = O(n^{-1/(k+4)})$ (大于一元情形下的最优带宽),而 $\hat{m}(x_0)$ 的收敛速度也更慢。

多元回归的解释变量越多,则收敛的速度越慢,对样本容量的 要求也就越大。

这种"维度的诅咒"(curse of dimensionality)限制了多元非参数回归的应用。

一种解决方法是,使用半参数估计降低模型中非参数部分的维度。

27.8 k 近邻回归

核回归估计是局部加权平均估计量(local weighted average estimator)的一个特例,使用一个特别的权重。

选择权重的另一方式是,对于最靠近 x_0 的k个 x_i 的观测值都给予相同的权重,而对其余观测值则给予权重 0。

记 $N_k(x_0)$ 为最靠近 x_0 的k个 x_i 观测值的集合(包括 x_0 自身),则k近邻估计量(k-nearest neighbor estimator)定义为:

$$\hat{m}_{KNN}(x_0) \equiv \frac{1}{k} \sum_{i=1}^{n} \mathbf{1} \{x_i \in N_k(x_0)\} \cdot y_i$$

此估计量可看成是使用"均匀核"(uniform kernel)的核估计,但带宽可变,且可以不对称(左边的带宽不等于右边的带宽)。

"对称化" (symmetrized)的k近邻估计量则对小于 x_0 的(k-1)/2观测值与大于 x_0 的(k-1)/2观测值进行简单算术平均。

k近邻估计量相当于移动平均(moving average)。

由于k近邻估计量使用的是简单算术平均,而不是核回归估计所使用的加权平均,故前者可能不如后者光滑(正如直方图不如核密度估计光滑)。

越靠近端点,可用于移动平均的样本点越少,估计量越不准确。 这种边界问题(boundary problem)可通过"局部线性回归"缓解。

27.9 局部线性回归

核回归估计量实际上是"局部常数估计"(local constant estimator),假定在 x_0 附近的某个邻域里,m(x)均等于一个常数。

局部线性回归假定m(x)在 x_0 附近的某个邻域里为线性函数,即在该邻域里, $m(x) = a_0 + b_0(x - x_0)$,然后使用加权最小二乘法(**WLS**)来估计此线性函数:

$$\min_{\{a_0, b_0\}} \sum_{i=1}^n K[(x_i - x_0)/h][y_i - a_0 - b_0(x_i - x_0)]^2$$

其中, $K(\cdot)$ 为核函数。离 x_0 越近,则权重越大(除非使用均匀核,则权重一样,等价于 OLS 回归)。

在 x_0 附近的小邻域里, $\hat{m}(x) = \hat{a}_0 + \hat{b}_0(x - x_0)$ 。

这种方法称为"局部线性回归"(local linear regression),由 Fan (1992)首倡,也称"范回归"(Fan regression)。

局部线性回归不仅能较好地解决"边界问题",而且比核回归更有效率且适用于更多数据类型。

如果带宽足够小,则在此小邻域内,一般的函数都可以很好地用线性函数来近似,故局部线性回归具有较好的性质。

更一般地,假定m(x)在 x_0 附近的某个邻域为p级多项式。"局部p级多项式估计量" (local polynomial estimator of degree p)最小化以下目标函数:

$$\min_{\{a_0,b_0\}} \sum_{i=1}^n K[(x-x_0)/h] \left[y_i - a_{0,0} - a_{0,1}(x_i - x_0) - \dots - \frac{a_{0,p}}{p!} (x_i - x_0)^p \right]^2$$

一个常用的局部回归估计量为 Cleveland(1979)所提出的"局部加权散点光滑估计量"(Locally weighted scatterplot smoothing,简记 Lowess),是局部多项式估计量的变种或升级版。

该估计量使用"三三核"(tricubic kernel),同时使用可变带宽 $h_{0,k}(\mathbf{h}x_0)$ 到其最近的 k 个观测值的距离所决定),以及对较大的残 差 $[y_i - \hat{m}(x_i)]$ 给予较小的权重。

Lowess 的优点是,使用了可变带宽(依数据的稠密程度而定),对于极端值更稳健,且缓解了在两端估计不准的边界问题。

27.10 非参数估计的 Stata 命令及实例

27.11 半参数估计

非参数回归假设对回归函数m(x)一无所知。

经济理论可能对m(x)的具体形式有所限制,比如需求函数要满足对称性与齐次性(homogeneity)。利用这些信息可提高估计效率。

当解释变量较多时,完全的非参数方法面临"维度的诅咒",要 求很大的样本容量。 可使用同时包含"参数部分" (a parametric component)与"非参数部分" (a nonparametric component)的"半参数模型" (semiparametric model)。

最常见的半参数模型为"部分线性模型"(Partially Linear model):

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + g(\mathbf{z}_i) + \varepsilon_i$$

其中,参数部分 $x_i'\beta$ 为线性函数,而非参数部分 $g(z_i)$ 为未知函数 (连函数形式也不知道)

假设扰动项 ε_i 均值独立于 x_i, z_i ,即 $E(\varepsilon_i | x_i, z_i) = 0$ 。

Robinson(1988)提出"罗宾逊差分估计量"(Robinson difference

estimator),以消去 $g(z_i)$ 。给定 z_i ,对方程两边取条件期望可得

$$E(y_i | z_i) = E(x_i | z_i)' \beta + g(z_i) + \underbrace{E(\varepsilon_i | z_i)}_{=0}$$

其中,根据迭代期望定律,

$$E(\varepsilon_i \mid z_i) = E_{x_i} E[(\varepsilon_i \mid z_i) \mid x_i] = E_{x_i} \underbrace{E(\varepsilon_i \mid x_i, z_i)}_{=0} = 0$$

将两个方程相减可得:

$$y_i - E(y_i | z_i) = [x_i - E(x_i | z_i)]' \beta + \varepsilon_i$$

在此"差分方程"中,未知函数 $g(z_i)$ 被消去,而条件期望 $E(y_i|z_i)$

与 $E(x_i|z_i)$ 可用非参数方法来估计(比如,核回归)。

假设Ê $(y_i|z_i)$ 与Ê $(x_i|z_i)$ 分别为对E $(y_i|z_i)$ 与E $(x_i|z_i)$ 的非参数估计,可对以下线性方程进行 OLS 估计:

$$y_i - \hat{\mathbf{E}}(y_i \mid \mathbf{z}_i) = \left[\mathbf{x}_i - \hat{\mathbf{E}}(\mathbf{x}_i \mid \mathbf{z}_i)\right]' \boldsymbol{\beta} + u_i$$

记此估计量为 $\hat{\boldsymbol{\beta}}_{PL}$ 。由于使用了条件期望的估计量来替代条件期望本身,故扰动项不再是 ε_i ,记新扰动项为 u_i 。

假设 ε_i 为 $iid(0, \sigma^2)$,可以证明:

$$\sqrt{n}(\hat{\boldsymbol{\beta}}_{PL} - \boldsymbol{\beta}) \xrightarrow{d} N \left(0, \sigma^2 \left(\underset{n \to \infty}{\text{plim}} \frac{1}{n} \sum_{i=1}^n \boldsymbol{w}_i \boldsymbol{w}_i' \right)^{-1} \right)$$

其中, $\mathbf{w}_i \equiv \mathbf{x}_i - \mathbf{E}(\mathbf{x}_i | \mathbf{z}_i)$ 。

用 $\hat{\mathbf{E}}(\mathbf{x}_i | \mathbf{z}_i)$ 替代 $\mathbf{E}(\mathbf{x}_i | \mathbf{z}_i)$ 即可估计 $\mathbf{Avar}(\hat{\boldsymbol{\beta}}_{PL})$ 。

如存在异方差,可使用夹心估计量得到稳健标准误。

最后,可得到对 $g(z_i)$ 的非参数估计:

$$\hat{g}(z_i) = \hat{E}(y_i | z_i) - \hat{E}(x_i | z_i)' \hat{\beta}_{PL}$$