# 第30章 久期分析

在实证研究中,有时被解释变量为某种活动持续的时间 (duration, spell, time to event)。

比如:病人存活的时间,灯泡报废的时间,失业持续的时间,婚姻持续的时间,罢工持续的时间,战争持续的时间,王朝的寿命,刑满释放犯再次犯罪的时间等。

这类数据称为"久期数据"(duration data),相应的分析方法称为"久期分析"(duration analysis)。

由于久期分析考察个体从某一状态转换到另一状态所花费的时间,故也称为"转换分析"(transition analysis)或"事件历史分析"(event history analysis)。

生物统计领域称其为"生存分析"(survival analysis), 运筹学领域称为"报废时间分析"(failure time analysis), 人口学领域称为"生命表分析"(life table analysis), 而保险领域称为"风险分析"(hazard analysis)。

久期分析的许多术语来自生物统计领域。

# 30.1 久期数据的处理方法

久期数据通常为横截面数据。

假设数据为 $\{T_i, x_i\}_{i=1}^n$ ,其中 $T_i$ 为被解释变量,即个体 i 的持续时间(寿命);而 $x_i$ 为解释变量。

考虑用 OLS 估计以下模型:

$$T_i = \mathbf{x}_i' \mathbf{\beta} + \varepsilon_i$$

由于持续时间 $T_i \geq 0$ ,而由上式得到的预测值 $\hat{T}_i = x_i'\hat{\beta}$ 有可能为负数,故这是不现实的模型。

较为现实的建模方法将 $\ln T_i$ 作为被解释变量(假设 $T_i > 0$ ):

$$ln T_i = \mathbf{x}_i' \mathbf{\beta} + \varepsilon_i$$

此对数线性模型的最大问题是,在我们抽样获得观测数据时,通常知道个体已经存活了一段时间。

而此方程却总是站在 $T_i = 0$ (即病情刚发作或确诊)的角度,无法纳入"个体已经存活了一段时间"这一信息。

我们常常更为关心给定个体已存活了一段时间的条件下,个体在下个时刻死亡的概率,即下文的风险函数。

比如,我们关心已经失业三个月的失业者明天找到工作的概率。

另外,如果久期数据存在右归并(参见 14.3 节),或者随时间而变的解释变量 $x_{ii}$ ,都很难通过 OLS 来处理。

久期分析常使用基于风险函数的一套特殊方法,形成自成体系的研究领域。

## 30.2 风险函数

记个体在某种状态中持续的时间(spell)或寿命为 $T \ge 0$ ,其一个特定取值记为 t。

假设 T 为连续型随机变量,并记其概率密度函数与累积分布函数分别为 f(t)与 F(t),其中 F(t)也被称为"失效函数"(failure function)。

考虑"病人"存活期超过t的概率,称为"生存函数"(survivor function):

$$S(t) \equiv P(T > t) = 1 - F(t), \quad t \ge 0$$

生存函数本质上相当于累积分布函数的"反函数"(reverse cumulative distribution function)。

由于累积分布函数F(t)单调递增,故生存函数S(t)单调递减。

假设病人已存活到时刻 t, 在[t,  $t + \Delta t$ )期间( $\Delta t > 0$ )死亡的概率为:

$$P(t \le T < t + \Delta t \mid T \ge t) = \frac{P(t \le T < t + \Delta t)}{P(T \ge t)} = \frac{F(t + \Delta t) - F(t)}{S(t)}$$

定义 "风险率" (hazard rate)或 "风险函数" (hazard function)为 病人在时刻t的瞬间死亡率:

$$\lambda(t) = \lim_{\Delta t \to 0^{+}} \frac{P(t \le T < t + \Delta t \mid T \ge t)}{\Delta t}$$

$$= \lim_{\Delta t \to 0^{+}} \frac{F(t + \Delta t) - F(t)}{\Delta t S(t)}$$

$$= \frac{1}{S(t)} \lim_{\Delta t \to 0^{+}} \frac{F(t + \Delta t) - F(t)}{\Delta t} = \frac{f(t)}{S(t)}$$

风险函数 $\lambda(t)$ 本质上是在给定存活至时刻t条件下的条件密度函数,故也称为"条件死亡率"(conditional failure rate);而f(t)为无条件密度函数。

如果 $f(t) = \phi(t)$ (标准正态密度),则 $\lambda(t)$ 是反米尔斯比率(IMR)。

风险率的可能取值介于 0(无死亡风险)与∞(必死无疑)之间。

在久期分析中,风险函数 $\lambda(t)$ 与生存函数S(t)比密度函数f(t)与累积分布函数F(t)更为方便与常用。

也可以从风险函数 $\lambda(t)$ 出发,反推出生存函数S(t)、累积分布函数F(t)以及密度函数f(t)。

首先, 从上式可知,

$$\lambda(t) = -\frac{d\ln S(t)}{dt}$$

故  $d \ln S(t) = -\lambda(t) dt$ , 两边从 0 到 t 作定积分可得:

$$\ln S(t) = -\int_0^t \lambda(u) \, du$$

其中,u为积分变量; S(0)=1(在初始时刻,所有个体都活着)。

$$F(t) = 1 - S(t) = 1 - \exp\left[-\int_0^t \lambda(u) du\right]$$

$$S(t) = \exp\left[-\int_0^t \lambda(u) \, du\right]$$

对方程两边求导可得,

$$f(t) = \lambda(t) \exp\left[-\int_0^t \lambda(u) \, du\right]$$

为度量截止时刻 t 的累积总风险,定义"累积风险函数" (cumulative hazard 或 integrated hazard)为:

$$\Lambda(t) = \int_0^t \lambda(u) \, du = -\ln S(t)$$

累积风险函数的好处在于,它比风险函数可以更准确地估计。

如果知道累积风险函数,很容易计算生存函数:

$$S(t) = \exp[-\Lambda(t)]$$

例 假设 T 服从指数分布 (exponential distribution),  $f(t) = \lambda e^{-\lambda t} (\lambda > 0)$ ,则

$$F(t) = \int_0^t \lambda e^{-\lambda s} ds = \int_0^t e^{-\lambda s} d(\lambda s) = -e^{-\lambda s} \Big|_0^t = 1 - e^{-\lambda t}$$

$$S(t) = e^{-\lambda t}, \quad \lambda(t) = \frac{f(t)}{S(t)} = \frac{\lambda e^{-\lambda t}}{e^{-\lambda t}} = \lambda, \quad \Lambda(t) = \lambda t$$

指数分布的风险函数为常数,称为"无记忆性"(memoryless)。它意味着,瞬间死亡的概率并不依赖于已存活了多久。

可以证明,个体在 $(0,t_2)$ 区间死亡的概率等于在已知个体存活至时刻 $t_1$ 的情况下,其在 $(t_1,t_1+t_2)$ 区间死亡的概率。

另一方面,如果风险函数为常数 $\lambda$ ,则其对应的密度函数为  $f(t) = \lambda \exp\left[-\int_0^t \lambda du\right] = \lambda e^{-\lambda t}$ ,一定服从指数分布。

指数分布的期望为 $E(T) = \frac{1}{\lambda}(风险率的倒数), 方差为Var(T) = \frac{1}{\lambda^2}$ 。

指数分布广泛应用于研究电子元器件的寿命问题。

指数分布只有一个参数,如果知道期望,则方差也确定(方差为期望的平方),缺乏灵活性。

指数分布的无记忆性有时也不现实。它意味着,一个 20 岁的青年与一个 80 岁的老年不仅瞬间死亡率一样,而且在未来 10 年内死亡的概率也相同。

将指数分布拓展至两个参数的威布尔分布(Weibull distribution)。

**定义** 如果随机变量 T 的累积分布函数为  $F(t) = 1 - \exp(-\gamma t^p)$ ,其中 $\gamma > 0$ ,p > 0,则称其服从威布尔分布。

威布尔分布的生存函数为 $S(t) = 1 - F(t) = \exp(-\gamma t^p)$ 。

威布尔分布的密度函数为 $f(t) = F'(t) = \gamma pt^{p-1} \exp(-\gamma t^p)$ 。

威布尔分布的风险函数为

$$\lambda(t) = \frac{f(t)}{S(t)} = \frac{\gamma p t^{p-1} \exp(-\gamma t^p)}{\exp(-\gamma t^p)} = \gamma p t^{p-1}$$

如果 p=1,则威布尔分布的 cdf 为  $F(t)=1-\exp(-\gamma t)$ ,就是指数分布的 cdf,故指数函数是威布尔分布的特例。

如果p>1,则风险函数 $\lambda(t)$ 单调递增,这意味着,活得越久则死亡概率越高(或许由于老年化过程),被称为"正向久期依赖" (positive duration dependence);

如果p < 1,则风险函数 $\lambda(t)$ 单调递减(或许新生儿死亡概率最高);被称为"负向久期依赖" (negative duration dependence)。

如果p=1(即指数分布的情形),则风险函数 $\lambda(t)$ 为常数(或许死亡由外在的随机因素所造成)。

参数 p 决定了风险函数  $\lambda(t)$  的形状,称为"形状参数"(shape parameter); 参数  $\gamma$  则 决定 其规模, 称为"规模参数"(scale parameter)。

## 30.3 久期数据的归并问题

久期数据常存在"右归并"(right censoring)。

当研究结束时,有些病人可能尚未死亡;或者有些失业者还未 找到工作。

观测到个体存活时间从0直至某归并时间(censoring time) $C^*$ 。

只知道个体的寿命属于区间( $C^*,\infty$ ),不知道其具体取值。

导致右归并的原因还包括,个体中途退出研究,或研究者与个体失去联系,无法继续跟踪调查。

在存在右归并的情形,记个体 i 的真实寿命为 $T_i^*$ (可能不可观测),而归并时间为 $C_i^*$ 。

实际观测到的 $T_i$ 或为个体寿命 $T_i^*$ ,或为归并时间 $C_i^*$ ,取决于二者哪个更小:

$$T_i = \min(T_i^*, C_i^*)$$

以虚拟变量 $d_i$ 来记录个体i的观测记录是否完整:

$$d_i = \mathbf{1}(T_i^* < C_i^*)$$

如果 $d_i = 1$ ,则有完整记录,无归并;如果 $d_i = 0$ ,存在右归并。

有时也会出现"左归并"(left censoring),即只知道个体的寿命属于区间 $(0, C^*)$ ,而不知道其具体取值。

另一种归并情形为"区间归并"(interval censoring),即只知道个体的寿命属于区间[ $C_a^*, C_b^*$ ),也不知道其具体取值。

区间归并常因为数据的离散性而发生,比如,研究者只知道失业者在某一周找到工作,而不知道其具体日期。

为保证久期分析的有效性,常假设"独立归并"(independent censoring)或"无信息归并"(noninformative censoring),即归并时间 $C_i^*$ 的分布不包含任何有关个体寿命 $T_i^*$ 分布的信息。

此时,可将表示归并的虚拟变量 $d_i$ 视为外生变量,不必在意归

并究竟如何发生,也无须为"归并机制"(censoring mechanism)建模。

在久期样本中,每一个体开始活动(比如,开始生病或失业)的 日历时间(calendar time)可以不同。

通常将"风险开始"(onset of risk)的时间标准化为0时刻。

以此度量的时间在 Stata 中称为"分析时间" (analysis time)。

久期分析的被解释变量T;正是以分析时间来计算的。

## 30.4 描述性分析

常希望进行一些粗略的描述性分析,比如根据样本数据来估计 生存函数、累积风险函数与风险函数,看它们的大致形状。

#### 1. 生存函数

生存函数S(t)为个体存活时间超过时刻t的概率。

如不存在归并,可定义S(t)的估计量为,样本中存活时间超过时刻t的个体数目r占样本容量n的比例,即 $\frac{r}{-}$ 。

但此法在归并的情况下并不适用。

此时,一般使用 Kaplan-Meier 估计量(Kaplan and Meier, 1958,简记 KM),它在独立归并(independent censoring)的情况下依然是S(t)的一致估计量。

记 $t_1 < t_2 < \cdots < t_j < \cdots < t_K$ 为样本中观测到的死亡时间。

记样本中在区间 $[t_{j-1},t_j)$ 仍存活而面临危险(at risk)的个体数为 $n_j$ 。

到了时间 $t_j$ ,这些 $n_j$ 个体的命运分为三种,即存活、死亡、归并(只知道其死亡时间大于 $t_i$ ,但不再有观测数据)。

记在时间 $t_i$ 死亡的人数为 $m_i$ 。

给定存活至 $t_{j-1}$ ,能进一步活至 $t_j$ 的概率(频率)为 $\frac{n_j-m_j}{n_i}$ 。

活至 $t_j$ 的无条件概率等于活过之前每一个区间的条件概率之乘积。Kaplan-Meier 估计量为

$$\hat{S}(t) \equiv \prod_{j|t_j \le t} \left( \frac{n_j - m_j}{n_j} \right)$$

故 Kaplan-Meier 估计量也称为"连乘估计量"(product limit estimator)。

如果不存在归并,则 $n_{j+1} = n_j - m_j$ ,方程中的连乘可以错项相约,故 $\hat{S}(t) = r/n$ 。

#### 2. 累积风险函数

累积风险函数 $\Lambda(t) = -\ln S(t)$ ,将 $\hat{S}(t)$ 的表达式代入,即可得 $\Lambda(t)$ 的估计量。

但此估计量的小样本性质不如 Nelson (1972)与 Aalen (1978)所提出的 Nelson-Aalen 估计量(简记 NA):

$$\hat{\Lambda}(t) \equiv \sum_{j|t_j \le t} \left( \frac{m_j}{n_j} \right)$$

其中,每项 $\frac{m_j}{n_j}$ 为局部风险率,而上式则为局部风险率的加总。

# 3. 风险函数

可以用 $\hat{\lambda}_j \equiv m_j/n_j$ 作为风险率的估计量。

但此估计量为不光滑的阶梯函数。

另一方法是对累积风险函数求导,但 $\hat{\Lambda}(t)$ 也是阶梯函数,并不处处可导。

实践中,一般先通过核密度方法将阶梯形的累积风险函数光滑化,然后再以此生成风险函数。

# 30.5 久期模型的最大似然估计

真实持续时间 $T^*$ 的概率分布可能依赖于某些解释变量x。

记 $T^*$ 的密度函数、累积分布函数、生存函数与风险函数为 $f(t|x,\theta)$ , $F(t|x,\theta)$ , $S(t|x,\theta)$ 与 $\lambda(t|x,\theta)$ ,其中x为不随时间而变的解释变量(time-invariant covariates), $\theta$ 为待估计的未知参数。

比如, $T^*$ 为失业持续的时间,x包括失业前的教育水平、工作经验、种族、婚姻状况、子女数目,以及政府发放的失业救济金额等;故T的分布依赖于x。

假设存在右归并,则其 MLE 估计类似于归并回归的 Tobit 模型。

对于未被归并的观测值,其对似然函数的贡献为 $f(t|\mathbf{x},\boldsymbol{\theta})$ 。

对于右归并的观测值,我们只知道其持续时间超过 t,故其对似然函数的贡献为 $P(T^* > t) = S(t \mid x, \theta)$ 。

个体i对似然函数的贡献可写为

$$f(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta})^{d_i} S(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta})^{1-d_i}$$

 $d_i$ 为右归并虚拟变量,即 $d_i$ =1表示无归并, $d_i$ =0表示右归并。

假设样本为 iid,将似然函数取对数,加总可得

$$\ln L(\boldsymbol{\theta}) = \sum_{i=1}^{n} \left[ d_i \ln f(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}) + (1 - d_i) \ln S(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}) \right]$$

由于 $f(t) = \lambda(t)S(t)$ , 故  $\ln f(t) = \ln \lambda(t) + \ln S(t)$ , 故

$$\ln L(\boldsymbol{\theta}) = \sum_{i=1}^{n} \left[ d_i \ln \lambda(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}) + \ln S(t_i \mid \boldsymbol{x}_i, \boldsymbol{\theta}) \right]$$

如果直接对风险函数 $\lambda(t|\mathbf{x},\boldsymbol{\theta})$ 建模,则此式更为方便。

如果似然函数正确,则 MLE 估计量一致、有效、渐近正态。

如果似然函数不正确,此 MLE 估计量通常不一致。

一个例外是 $T^*$ 服从指数分布且不存在归并,则只要条件期望函数(conditional mean function)正确即可保证MLE估计量的一致性。

如果存在归并,即使 $T^*$ 服从指数分布,MLE 估计量也不一致。

以上参数回归模型(parametric regression model)的最大缺点是缺乏稳健性,对概率分布的具体假设比较敏感。

如存在其他形式的归并,应对似然函数进行相应调整。

如果观测值存在左归并,只知道持续时间小于t,其对似然函数的贡献为

$$P(T^* < t) = F(t \mid x, \theta)$$

如果观测值存在区间归并,只知道持续时间属于区间[ $C_a^*, C_b^*$ ),故其对似然函数的贡献为

$$P(C_a \le T^* < C_b) = S(C_a \mid x, \theta) - S(C_b \mid x, \theta)$$

在经济应用中的久期数据常存在区间归并。比如,失业持续时间经常以周或月来计算,而指数分布、威布尔分布等都是连续型分布。此时,通常假设区间归并的影响甚微,作为连续数据处理。

## 30.6 比例风险模型

称风险函数 $\lambda(t; x)$ 为"比例风险"(Proportional Hazard, 简记 PH), 如果它可以分解为

$$\lambda(t; \mathbf{x}) = \lambda_0(t) h(\mathbf{x})$$

其中, $h(\cdot) > 0$ ,而 $\lambda_0(t)$ 被称为"基准风险"(baseline hazard),依赖于时间 t,但不依赖于x。

基准风险 $\lambda_0(t)$ 对于总体中的每一个体都相同,而个体的风险函数则依据h(x)与此基准风险 $\lambda_0(t)$ 成正比,故名"比例风险"。

$$\lambda(t; \mathbf{x}) = \lambda_0(t) e^{x'\beta}$$

其中, $e^{x'\beta}$ 被称为"相对风险"(relative hazard),故 $x'\beta$ 也称为"对数相对风险"(log-relative hazard)。

如所有解释变量都为0,风险函数 $\lambda(t; x)$ 就等于基准风险 $\lambda_0(t)$ 。

对方程两边取对数可得

$$\ln \lambda(t; \mathbf{x}) = \mathbf{x}'\boldsymbol{\beta} + \ln \lambda_0(t)$$

其中, $\beta$ 可方便地解释为半弹性。

另一解释是,如果 x 增加一单位,则风险率为 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{x'\boldsymbol{\beta}+\beta}$ ,正好是原来风险率 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{x'\boldsymbol{\beta}}$ 的 $e^{\beta}$ 倍。

Stata 称 $e^{\beta}$ 为"风险比率"(Hazard Ratio,简记 HR),即 x 增加一单位,将使新风险率变为原来风险率的 $e^{\beta}$ 倍。

如果令基准风险 $\lambda_0(t) = e^a$ ,其中 a 为待估参数(选择指数形式以保证 $e^a > 0$ ),则为"指数回归",因为指数分布的风险函数为常数。

也可从指数分布的密度函数出发,即  $f(t) = \lambda e^{-\lambda t}$  ( $\lambda > 0$ ),而令  $\lambda = e^a e^{x'\beta} = e^{a+x'\beta}$ ,其中x不包含常数项(如果有常数项 $e^{\beta_0}$ ,可与 $e^a$ 合并)。

将指数分布的风险函数 $\lambda$ 与生存函数 $S(t) = e^{-\lambda t}$ 代入可得:

$$\ln L(a, \boldsymbol{\beta}) = \sum_{i=1}^{n} \left[ d_i (a + \boldsymbol{x}_i' \boldsymbol{\beta}) - e^{a + \boldsymbol{x}_i' \boldsymbol{\beta}} t_i \right]$$

如果令基准风险 $\lambda_0(t) = pt^{p-1}e^a$ ,其中p > 0,a 为待估参数,则为"威布尔回归"(Weibull regression),因为威布尔分布的风险函数为 $\gamma pt^{p-1}$ (此处令 $\gamma = e^{a+x'\beta}$ )。

将指数分布的风险函数 $\gamma pt^{p-1}$ 与生存函数 $S(t) = \exp(-\gamma t^p)$ 代入可得:

$$\ln L(a, p, \beta) = \sum_{i=1}^{n} \left\{ d_i [a + x_i' \beta + \ln p + (p-1) \ln t_i] - e^{a + x_i' \beta} t_i^p \right\}$$

当p=1时,威布尔分布退化为指数分布。

故可通过检验 " $H_0$ : p=1" (或 $H_0$ :  $\ln p=0$ )来确定应使用威布尔回归还是指数回归。

如果令基准风险 $\lambda_0(t) = e^{a+\gamma t}$ ,其中 a, $\gamma$ 为待估参数,则为"冈珀茨回归"(Gompertz regression),在人口学与保险精算应用广泛。

与威布尔分布相比,冈珀茨分布的风险函数也是单调函数,即 当 $\gamma > 0$ 时单调递增,当 $\gamma < 0$ 时单调递减,而当 $\gamma = 0$ 时为常数(同样退化为指数分布);二者的不同点在于,冈珀茨分布风险函数的变化率为指数形式( $e^{rt}$ ),而威布尔分布风险函数的变化率为幂函数形式( $t^{p-1}$ )。

当 γ = 0 时, 冈珀茨分布退化为指数分布。

可检验" $H_0: \gamma = 0$ "来确定应使用冈珀茨回归还是指数回归。

威布尔分布与冈珀茨分布的风险函数都是单调函数,要么单调递增,要么单调递减,此性质有时也现实不符。

比如,对于人类的死亡率而言,婴儿与老人的死亡率较高,而中青年的死亡率较低,其风险函数并不具有单调性。

生物统计学家将人类死亡率的风险函数称为"浴缸风险" (bathtub hazard),因为它的形状就像一个浴缸。

在比例风险模型的框架下,一解决方法是不设定基准风险 $\lambda_0(t)$ 的函数形式,参见下文的 Cox 模型。

另一解决方法是假设基准风险  $\lambda_0(t)$  为阶梯函数,即  $\lambda_0(t)$  在每个小区间内都是待估计的常数(正如指数模型的风险率为常数),以更好地拟合实际的风险函数,称为"分段固定风险模型"(piecewise constant hazard model 或 piecewise constant exponential model)。

具体来说,分段固定风险模型的风险函数可写为

$$\lambda(t; \boldsymbol{x}) = \begin{cases} \lambda_1 e^{x'\boldsymbol{\beta}} & t \in [0, \tau_1) \\ \lambda_2 e^{x'\boldsymbol{\beta}} & t \in [\tau_1, \tau_2) \\ \vdots & \vdots \\ \lambda_M e^{x'\boldsymbol{\beta}} & t \in [\tau_{M-1}, \tau_M) \end{cases}$$

为便于估计,上式可写为

$$\lambda(t; \boldsymbol{x}) = \begin{cases} e^{\ln \lambda_1 + \boldsymbol{x}'\boldsymbol{\beta}} & t \in [0, \tau_1) \\ e^{\ln \lambda_2 + \boldsymbol{x}'\boldsymbol{\beta}} & t \in [\tau_1, \tau_2) \\ \vdots & \vdots \\ e^{\ln \lambda_M + \boldsymbol{x}'\boldsymbol{\beta}} & t \in [\tau_{M-1}, \tau_M) \end{cases}$$

分段固定风险模型等价于在每个时间段分别引入一个截距项。

对应于每个时间段,可定义M个虚拟变量,并将(M-1)个虚拟变量作为解释变量引入指数模型(假设模型中包括截距项)。

【例】Lalive et al (2006)在研究失业持续时间时,将风险函数每四周分为一段(大多数失业者在 60 周内找到工作)。分段固定风险模型的缺点是,需要估计较多参数,故要求样本容量比较大。

对于比例风险模型 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\boldsymbol{\beta}}$ ,无论其基准风险 $\lambda_0(t)$ 如何设定(指数、威布尔、冈珀茨或分段固定),对于参数 $\boldsymbol{\beta}$ 的经济含义解释都是一样的,即可将 $\boldsymbol{\beta}$ 解释为 $\mathbf{x}$  对于风险函数的半弹性,或将 $e^{\boldsymbol{\beta}}$ 解释为风险比率。

# 30.7 加速失效时间模型

对于比例风险模型,通常分析的重点是解释变量x对于风险函数  $\lambda(t;x)$ 的作用,不容易看出x对于平均寿命E(T)的影响。

考虑直接对lnT建模:

$$\ln T = x'\beta + u$$

其中, u 为扰动项。

由于 $\ln T$ 在 $(-\infty, \infty)$ 取值,故 u 服从取值于 $(-\infty, \infty)$ 的连续型分布。

由方程可得, $T = e^{x'\beta}v$ ,其中 $v = e^u$ 。

记 v 的密度函数、累积分布函数、生存函数与风险函数分别为  $f_{v}(v)$ ,  $F_{v}(v)$ ,  $S_{v}(v)$ 与 $\lambda_{v}(v)$ ;

记 T 的密度函数、累积分布函数、生存函数与风险函数分别为  $f_T(t)$ ,  $F_T(t)$ ,  $S_T(t)$ 与 $\lambda_T(t)$ ,则

$$S_T(t) = P(T > t) = P[e^{x'\beta}v > t] = P[v > e^{-x'\beta}t] = S_v(e^{-x'\beta}t)$$

因此,

$$f_{T}(t) = F_{T}'(t) = [1 - S_{T}(t)]' = -\frac{\partial S_{v}[e^{-x'\beta}t]}{\partial t} = f_{v}(e^{-x'\beta}t)e^{-x'\beta}$$

由此可知,

$$\lambda_{T}(t \mid \mathbf{x}) = \frac{f_{T}(t)}{S_{T}(t)} = \frac{f_{v}(e^{-x'\beta}t)e^{-x'\beta}}{S_{v}(e^{-x'\beta}t)} = \lambda_{v}(e^{-x'\beta}t)e^{-x'\beta}$$

如果 $e^{-x'\beta} > 1$ ,则意味着是对基准风险 $\lambda_{\nu}(t)$ 的加速;

如果 $e^{-x'\beta}$  < 1,则意味着是对基准风险 $\lambda_{\nu}(t)$ 的减速。

这类模型被称为"加速失效时间模型"(Accelerated Failure Time Model,简记 AFT),尽管 $e^{-x'\beta}$  <1意味着减速。

如果扰动项 $u \sim N(0, \sigma^2)$ ,称为"对数正态模型"(log-normal model)。

如果 *u* 服从逻辑分布(logistic distribution), 称为"对数逻辑模型" (log-logistic model)。

如果 u 服从广义伽马分布 (generalized gamma

distribution) $Gamma(\beta_0, \kappa, \sigma)$ ,称为"伽马模型"(gamma model)。

对数正态模型与对数逻辑模型的风险函数均为非单调函数 (non-monotonic),适用于风险率首先上升然后下降的情形。

包含三个参数的伽马模型,其风险函数形状更为灵活。

如果 $\kappa=1$ ,则伽马模型就是威布尔模型;

如果 $\kappa=1$ 而且 $\sigma=1$ ,则伽马模型就是指数模型;

如果 $\kappa=0$ ,则伽马模型就是对数正态模型。

对原假设 " $H_0$ :  $\kappa = 1$ " 或 " $H_0$ :  $\kappa = 0$ " 进行检验,有助于选择模型适用的分布函数。

指数模型与威布尔模型也可以写成 AFT 形式,故它们既属于 PH 模型,也属于 AFT 模型;其他模型,要么为 PH,要么为 AFT。

对于 AFT 模型,可进行 MLE 估计。

AFT 模型的参数 $\beta$ 与 PH 模型的参数 $\beta$ 的经济解释不同。

在 AFT 模型下, $\beta$ 可以解释为当x边际增加时,能使平均寿命增加的百分比(即半弹性)。

特别地,对于指数模型而言,在 PH 模型下,风险率为 $\lambda = e^{a+x'\beta}$ ,而 平 均 寿 命 为  $E(T) = \frac{1}{\lambda} = e^{-(a+x'\beta)}$  , 故 其 AFT 模 型 为  $\ln T = -(a+x'\beta) + u$  。

由此可见,PH模型下参数β与AFT模型下的参数正好符号相反,而绝对值相等。在 Stata 中进行指数回归时,默认为 PH 模型;但如果加选择项"time",则为 AFT 模型;二者的估计系数绝对值相等,但符号正好相反。

由于 PH 模型与 AFT 模型都对风险函数的形式作了具体假设,故属于"参数回归"(parametric regression)。

在进行参数回归时,可供选择的分布函数很多。如果进行抉择?

对于"嵌套模型"(nested models),可对相关参数进行 Wald 或似然比检验(比如,指数模型是威布尔模型与冈珀茨模型的特例; 威布尔模型与对数正态模型是伽马模型的特例)。 对于"非嵌套模型"(non-nested models),不存在这种嵌套关系,一个模型并不是另一模型的特例,可通过 AIC 信息准则比较模型 拟合优度。

AIC 准则的定义为

$$AIC = -2\ln L + 2(K+c)$$

其中, $\ln L$ 为对数似然函数,K 为解释变量x的维度,c 为概率分布的参数个数(比如,指数分布的 c=1; 威布尔分布的 c=2; 伽马分布的 c=3)。

### 30.8 Cox 模型

参数回归对风险函数的具体形式作了假设,如果模型设定正确,则 MLE 是最有效率的。

如果风险函数的设定错误,则 MLE 一般不一致。

我们对于风险函数的具体形式常常并无把握。

针对参数回归的缺点,在比例风险模型的框架下,Cox (1972, 1975)提出了以下"Cox 模型"或"Cox PH 模型"。

由于比例风险模型  $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\mathbf{\beta}}$  在形式上为乘法 (multiplicative),故个体i与个体j的风险函数之比可以写为

$$\frac{\lambda(t; \mathbf{x}_i)}{\lambda(t; \mathbf{x}_j)} = \frac{\lambda_0(t) e^{x_i' \beta}}{\lambda_0(t) e^{x_j' \beta}} = e^{(x_i - x_j)' \beta}$$

个体i与j的风险函数之比不随时间而变,只与 $(x_i - x_j)$ 有关。

故可不必假设基准风险 $\lambda_0(t)$ 的具体函数形式,而依然得到对 $\beta$ 的估计。

由于构成风险函数 $\lambda_0(t)e^{x'\beta}$ 的前半部分 $\lambda_0(t)$ 不需要估计参数,而后半部分 $e^{x'\beta}$ 需要估计参数,故为半参数回归。

### 1. 失效时间不重叠的情形(no tied failures)

首先考察失效时间均不相同的情形,即每一个体的"死亡"时间都不一样。

假设久期样本只包括以下四个观测值:

	subject	t	x
1.	1	2	4
2.	2	3	1
3.	3	6	3
4.	4	12	2

其中,*subject* 表示个体,t 表示失效时间(failure time),而 x 为解释变量。记第 j 位个体的失效时间为 $t_j$ ,则四位个体的失效时间分别为 $t_1$ = 2, $t_2$ = 3, $t_3$ = 6, $t_4$ =12,完全不重叠。

记在时间 $t_j$ 面临失效危险的所有个体所构成的集合为"风险集"(risk set) $R_j$ 。如果个体已失效或被归并,则不再面临失效危险。

当 t=2 时,风险集为 $R_1=\{1,2,3,4\}$ ,实际观测到第 1 位个体失效。

当 t=3 时,风险集为 $R_2=\{2,3,4\}$ ,实际观测到第 2 位个体失效。

当 t=6 时,风险集为 $R_3=\{3,4\}$ ,实际观测到第 3 位个体失效。

当 t = 12 时,风险集为 $R_4 = \{4\}$ ,实际观测到第 4 位个体失效。

在以上四个失效时间(2, 3, 6, 12),假设必然有一位个体会失效,然后计算在此条件下实际失效的那位个体失效的条件概率,分别记为 $P_1$ ,  $P_2$ ,  $P_3$ ,  $P_4$ 。

似然函数可写为

$$L(\beta) = P_1 P_2 P_3 P_4$$

下面分别来计算 $P_1, P_2, P_3, P_4$ 。

当 t = 12 时,风险集只包含第 4 位个体,故第 4 位个体失效的条件概率为 1,即  $P_4 = 1$ 。

当 t = 6 时,给定第 3、4 位个体必然有一位失效,在此条件下第 3 位个体失效的条件概率为

$$P_3 = \frac{\lambda(6 \mid x_3)}{\lambda(6 \mid x_3) + \lambda(6 \mid x_4)} = \frac{\lambda_0(6)e^{x_3\beta}}{\lambda_0(6)e^{x_3\beta} + \lambda_0(6)e^{x_4\beta}} = \frac{e^{x_3\beta}}{e^{x_3\beta} + e^{x_4\beta}}$$

其中, $\lambda(6|x_3)$ 表示 t=6, $x=x_3$ 时的风险率。在上式中,由于基准风险 $\lambda_0(6)$ 已被约去,故 $P_3$ 并不依赖于具体的失效时间 t=6。

当 t=3 时,给定第 2、3、4 位个体必然有一位失效,在此条件下第 2 位个体失效的条件概率为

$$P_2 = \frac{\lambda(3 \mid x_2)}{\lambda(3 \mid x_2) + \lambda(3 \mid x_3) + \lambda(3 \mid x_4)} = \frac{e^{x_2 \beta}}{e^{x_2 \beta} + e^{x_3 \beta} + e^{x_4 \beta}}$$

当 t=2 时,给定第 1、2、3、4 位个体必然有一位失效,在此条件下第 1 位个体失效的条件概率为

$$P_{1} = \frac{\lambda(2 \mid x_{2})}{\lambda(2 \mid x_{1}) + \lambda(2 \mid x_{2}) + \lambda(2 \mid x_{3}) + \lambda(2 \mid x_{4})} = \frac{e^{x_{1}\beta}}{e^{x_{1}\beta} + e^{x_{2}\beta} + e^{x_{3}\beta} + e^{x_{4}\beta}}$$

似然函数可写为

$$L(\beta) = \prod_{j=1}^{4} \left( \frac{e^{x_j \beta}}{\sum_{i \in R_j} e^{x_i \beta}} \right)$$

其中, $R_j$ 为对应于 $t_j$ (第j位个体失效时间)的风险集。

一般地,如果样本中有L个失效时间 $\{t_1, \dots, t_L\}$ 以及多个解释变量x,似然函数可写为

$$L(\boldsymbol{\beta}) = \prod_{j=1}^{L} \left( \frac{e^{x_{j}^{\prime} \boldsymbol{\beta}}}{\sum_{i \in R_{j}} e^{x_{i}^{\prime} \boldsymbol{\beta}}} \right)$$

上式称为"部分似然函数"(partial likelihood function),因为它并非完整的似然函数。

部分似然函数只依赖于样本中个体失效时间的排序,不依赖于 个体失效的具体时间。 由于同一个体多次出现于不同的风险集中,一般应使用 Lin and Wei (1989)提出的稳健标准误,在 Stata 中可由选择项"r"或"vce(robust)"来实现。

基于部分似然函数的 MLE 估计量一致且渐近正态,尽管其有效性不如基于完整似然函数的 MLE 估计量(前面的参数回归)。

但后者的一致性依赖于对风险函数形式的正确设定(我们对此一般无把握),而前者的效率损失通常不大。

由于 Cox 模型的稳健性,在实践中十分流行,是半参数估计的成功例子。

# 2. 失效时间有重叠的情形(tied failures)

如果样本中的失效时间有重叠,则部分似然函数的计算更为复杂。

延续上面的简单例子,但假设第 3 位与第 2 位个体同时在 t= 3 时失效,原始数据变为:

	subject	t	x
1.	1	2	4
2.	2	3	1
3.	3	3	3
4.	4	12	2

当 t = 3 时,风险集为 $R_2 = \{2,3,4\}$ ,而实际观测到第 2、3 位个体同时失效。应如何计算在给定风险集中两位个体会失效的条件下,第 2、3 位个体失效的条件概率?

通常有以下两种处理方法。

处理方法之一是假设第 2、3 位个体的失效时间其实并不完全相同,称为"精确边际计算法"(exact-marginal calculation)。

如果失效时间为连续变量,则第 2、3 位个体同时失效的概率为 0。之所以在样本中存在同时失效的个体,只是由于我们的观测时间不够细致(比如,以周或月为分析时间)。

共有两种可能情形。第一种情形是,第 2 位个体先失效,然后第 3 位个体失效,记此情形的条件概率为 $P_{23}$ ;

第二种情形是,第 3 位个体先失效,然后第 2 位个体失效, 记此情形的条件概率为 $P_{32}$ ; 而总的条件概率为 $(P_{23} + P_{32})$ 。 记 $r_i \equiv e^{x_i\beta}$ ,根据前面的推导逻辑可知:

$$P_{23} = \frac{r_2}{r_2 + r_3 + r_4} \cdot \frac{r_3}{r_3 + r_4}$$

$$P_{32} = \frac{r_3}{r_2 + r_3 + r_4} \cdot \frac{r_2}{r_2 + r_4}$$

如果多位个体同时失效,则精确边际法可能计算量过大。

比如,有10位个体同时失效,则共有10!=3,628,800种情形。

Breslow (1974)提出了以下近似计算方法,即在计算时,不调整每一项分母中的风险集(一直使用最初的风险集)。

根据 Breslow 的方法,

$$P_{23} \approx P_{32} \approx \frac{r_2 r_3}{(r_2 + r_3 + r_4)^2}$$

Efron (1977)提出了另一近似计算方法。

Efron 方法比 Breslow 更为精确,但计算费时更长。

当 t = 3 时,风险集为 $\{3,4\}$ 或 $\{2,4\}$ ,对应的条件概率之分母分别为 $(r_3 + r_4)$ 或 $(r_2 + r_4)$ 。如果使用二者的平均数作为分母,可得

$$P_{23} \approx P_{32} \approx \frac{r_2 r_3}{(r_2 + r_3 + r_4) \left(\frac{r_2 + r_3}{2} + r_4\right)}$$

Breslow 方法与 Efron 方法都是对精确边际法的近似。

处理方法之二是假设第 2、3 位个体确实同时失效, 称为"精确部分计算法"(exact-partial calculation)。

给定风险集{2,3,4}中有两位个体同时失效,则共有三种情形,即第2、3位个体同时失效,第2、4位个体同时失效,以及第3、4位个体同时失效。

因此, 第 2、3 位个体确实同时失效的条件概率为:

$$P_{23} = \frac{r_2 r_3}{r_2 r_3 + r_2 r_4 + r_3 r_4}$$

精确部分法与精确边际法的计算结果不相等,但一般差别不大。

究竟采取哪种方法,取决于将时间理解为连续型变量(精确边际法及其近似)还是离散型变量(精确部分法)。

在实践中,如果风险集较大或同时失效的个体较多,则精确法的计算时间可能很长,故 Stata 的默认方法为 Breslow 近似法。

#### 2. 估计基准风险函数

虽然 Cox 模型不设定基准风险 $\lambda_0(t)$ 的函数形式,但估计 $\beta$ 之后依然可得到对 $\lambda_0(t)$ 的估计。

根据 $S(t) = \exp[-\Lambda(t)]$ ,代入比例风险 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\boldsymbol{\beta}}$ 可得:

$$S(t) = \exp[-\Lambda(t)] = \exp\left[-\int_0^t \lambda(u; \mathbf{x}) du\right] = \exp\left[-\int_0^t \lambda_0(u) e^{\mathbf{x}'\boldsymbol{\beta}} du\right]$$
$$= \exp\left[\left(-\int_0^t \lambda_0(u) du\right) \left(e^{\mathbf{x}'\boldsymbol{\beta}}\right)\right] = \left[\exp\left(-\int_0^t \lambda_0(u) du\right)\right]^{e^{\mathbf{x}'\boldsymbol{\beta}}} \equiv S_0(t)^{e^{\mathbf{x}'\boldsymbol{\beta}}}$$

其中, $S_0(t) \equiv \exp\left(-\int_0^t \lambda_0(u) du\right)$ 为对应于基准风险  $\lambda_0(t)$  的基准生存函数。根据 Cox 模型,已知 $\boldsymbol{\beta}$  的估计量  $\hat{\boldsymbol{\beta}}$  ; 根据 KM 估计量,已知 $\boldsymbol{S}(t)$  的估计量  $\hat{\boldsymbol{S}}(t)$  ; 故可得基准生存函数  $S_0(t)$  的估计量  $\hat{\boldsymbol{S}}_0(t)$  。

累积风险函数可写为:

$$\Lambda(t) = \int_0^t \lambda(u) \, du = \int_0^t \lambda_0(u) \, e^{x'\beta} \, du = e^{x'\beta} \int_0^t \lambda_0(u) \, du \equiv e^{x'\beta} \Lambda_0(t)$$

其中, $\Lambda_0(t) \equiv \int_0^t \lambda_0(u) du$  为对应于基准风险  $\lambda_0(t)$  的基准累积风险 函数。从 KM 估计量  $\hat{S}(t)$  出发,根据  $\Lambda(t) = -\ln S(t)$ ,可得到  $\Lambda(t)$  的估计量  $\hat{\Lambda}(t)$ 。故根据上述方程可得到  $\hat{\Lambda}_0(t)$ 。

根据关系式 $\Lambda_0(t) \equiv \int_0^t \lambda_0(u) du$ ,可计算每个失效时间对于 $\hat{\Lambda}_0(t)$ 的边际贡献,即 $\hat{\lambda}_0(t)$ 。

使用核密度方法将此边际贡献光滑化,即得到对 $\lambda_0(t)$ 的估计。

根据对基准风险的估计 $\hat{\lambda}_0(t)$ 以及参数估计 $\hat{\beta}$ ,可计算在 $\mathbf{x} = \mathbf{x}^*$ 处的风险函数:

$$\hat{\lambda}(t; \mathbf{x}^*) = \hat{\lambda}_0(t) e^{\mathbf{x}^{*'}\hat{\boldsymbol{\beta}}}$$

通常,  $\Diamond x^* = \bar{x}$ , 即计算在解释变量平均值处的风险函数;

也可选择感兴趣的其他解释变量取值(特别当 x 为二值变量或离散变量时)。

### 30.9 比例风险模型的设定检验

比例风险模型(包括 Cox 模型)的重要假设是 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\boldsymbol{\beta}}$ 。

如果此假设不成立,则比例风险模型不能成立。

需对比例风险模型进行设定检验, Stata 称为"PH-assumption tests"。

# 1. 对数**-**对数图(log-log plot)

根据比例风险假定 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\boldsymbol{\beta}}$ ,可将累积风险函数写为

$$\Lambda(t) = \int_0^t \lambda(u; \mathbf{x}) du = \int_0^t \lambda_0(u) e^{\mathbf{x}'\boldsymbol{\beta}} du = e^{\mathbf{x}'\boldsymbol{\beta}} \int_0^t \lambda_0(u) du \equiv e^{\mathbf{x}'\boldsymbol{\beta}} \Lambda_0(t)$$

其中, $\Lambda_0(t)$ 为对应于 $\lambda_0(t)$ 的累积风险函数。由上式可知,

$$\ln \Lambda(t) = \mathbf{x}'\boldsymbol{\beta} + \ln \Lambda_0(t)$$

代入 $\Lambda(t) = -\ln S(t)$ ,且方程两边同乘(-1)可得:

$$-\ln\left[-\ln S(t)\right] = -x'\beta - \ln\left[-\ln S_0(t)\right]$$

其中, $S_0(t)$ 为对应于 $\lambda_0(t)$ 的生存函数。由于0 < S(t) < 1,故  $\ln S(t) < 0$ , $-\ln S(t) > 0$ 。

函数 $-\ln[-\ln S(t)]$ 的斜率并不依赖于x。

当x取不同值时(比如,x为虚拟变量或离散变量),函数  $-\ln[-\ln S(t)]$ 应为相互平行的曲线,只是截距项 $(-x'\beta)$ 不同。

据此画出的图被称为"对数-对数图"(log-log plot)。

如果对数-对数图中的曲线相互平行,则支持比例风险假设;如果不同曲线的斜率相差甚远,则意味着比例风险假设不成立。

对数-对数图的缺点是,如何确定曲线是否平行带有主观性。

### 2. 观测-预测图(observed versus expected plot)

检验比例风险假设的另一图示法为"观测-预测图"。针对每一解释变量 x,分别画图。

假设 x 为离散变量,首先根据 x 的不同取值水平画其 Kaplan-Meier (KM)生存函数图,即观测图(observed plots)。

其次,估计 Cox 模型,以此计算基准生存函数  $S_0(t)$ ,然后代入 x 的不同取值水平,得到相应的生存函数图,即预测图(expected plot)。

最后,给定x的一个取值水平,比较其观测图与预测图是否足够接近。如果很接近,则表明变量x满足比例风险假设;反之,则比例风险假设不成立。观测-预测图的缺点同样是它的主观性。

## 3. 基于残差的检验(residual-based tests)

对于像久期分析这样的非线性模型,有多种残差的定义。

对于检验比例风险假设最有用的是"舍恩菲尔德残差"(Schoenfeld residuals)。

对于个体 j与解释变量 $x_k$ ( $k=1,\dots,K$ ,假设共有K个解释变量),可计算其对应的舍恩菲尔德残差如下:

$$r_{kj} = x_{kj} - \sum_{i \in R_j} \left( x_{ki} \cdot \frac{e^{x_i' \beta}}{\sum_{i \in R_j} e^{x_i' \beta}} \right)$$

其中, $R_i$ 为当个体j失效时的风险集。

舍恩菲尔德残差 $r_{kj}$ 为失效个体的解释变量观测值 $x_{kj}$ 减去仍处于风险集中个体的解释变量之加权平均,而权重为"相对风险" (relative hazard) $e^{x_i \beta}$ 。

如果比例风险假设成立,舍恩菲尔德残差不应随时间呈现出规律性的变化。

针对每个解释变量 $x_k$ ,都可以将其舍恩菲尔德残差与时间画图,并考察其斜率是否为0。

进一步,可以把舍恩菲尔德残差对时间回归,然后检验时间的系数是否为0。

### 30.10 分层 Cox 模型

如果比例风险假设不满足,处理方法之一为"分层 Cox 模型" (stratified Cox model)。

不失一般性,假设变量 sex(性别)不满足比例风险假设,则可将样本中个体分为两组,第一组为男性,第二组为女性。

假设男性与女性的基准风险函数不同,但参数 $\beta$ 都相同(此假设也可以检验),个体的风险函数可写为

$$\lambda(t; \mathbf{x}_{j}) = \begin{cases} \lambda_{01}(t)e^{x'_{j}\boldsymbol{\beta}}, & j \text{ 为男性} \\ \lambda_{02}(t)e^{x'_{j}\boldsymbol{\beta}}, & j \text{ 为女性} \end{cases}$$

其中, $\lambda_{01}(t)$ 为男性组的基准风险, $\lambda_{02}(t)$ 为女性组的基准风险。

根据男性组的风险函数 $\lambda_{01}(t)e^{x'_{j}\theta}$ ,可计算男性组的部分似然函数 $L_{1}$ ;类似地,可计算女性组的部分似然函数 $L_{2}$ 。

整个样本的部分似然函数为 $L = L_1 \cdot L_2$ 。

由于变量 sex 不直接出现在似然函数中(sex 不满足比例风险假设,无法直接引入 Cox 模型),故无法估计其效应;这是分层分析的代价。

进一步,如果某分层变量有k个取值水平,则可将样本中个体分为k层或k组,然后进行分层估计。

更一般地,如果有多个分层变量,则应考虑它们的交叉情形。

比如,变量 x 有 3 种可能取值,变量 z 有 2 种可能取值,二者都不满足比例风险假设,故同为分层变量;此时,应将样本分为 6 组,使得每组内的 x, z 取值都相同。

分层 Cox 模型的一个重要假定为,不同组的参数 $\beta$ 都相同。

为检验此假定,可以引入分层变量与留在 Cox 模型中变量的 互动项进行分层分析,然后检验所有这些互动项的联合显著性。

如果都不显著,则支持"不同组参数 $\beta$ 都相同"的原假设。

## 30.11 随时间而变的解释变量

如果比例风险假设不满足,处理方法之二为引入随时间而变的解释变量(Time-Varying Covariates,简记 TVC)。

比如,在持续失业的过程中,宏观经济状况可能发生变化,从而影响就业概率。

引入 TVC 后,可能导致内生性。

不由个体控制的变量(比如宏观经济)是外生的;而个体可以影响的变量则可能为内生的。

例如,考察婚姻持续时间时,如果使用孩子的数量作为TVC,可能导致内生性问题。由于稳定的婚姻会增加孩子的数量,故根据数据得出的"孩子越多,婚姻越持久"结论并不可靠。

下面,假设 TVC 为外生。

引入 TVC 后,可将风险函数写为

$$\lambda(t; \mathbf{x}(t)) = \lambda_0(t) e^{\mathbf{x}'(t)\boldsymbol{\beta}}$$

其中,解释变量x(t)可随时间而变,其系数 $\beta$ 仍为固定。

一旦解释变量x(t)的取值变化,其风险函数也立即发生变化。

如要考虑滞后效应,可引入x(t-1)作为解释变量。

个体 i 与个体 j 的风险函数之比可写为:

$$\frac{\lambda(t; \mathbf{x}_i(t))}{\lambda(t; \mathbf{x}_j(t))} = \frac{\lambda_0(t) e^{\mathbf{x}_i'(t)\boldsymbol{\beta}}}{\lambda_0(t) e^{\mathbf{x}_j'(t)\boldsymbol{\beta}}} = e^{[\mathbf{x}_i(t) - \mathbf{x}_j(t)]'\boldsymbol{\beta}}$$

此风险函数之比是时间 t 的函数,不再满足比例风险假设,称为"扩展 Cox 模型" (extended Cox model)。

这对于基于似然函数(参数回归)或部分似然函数(Cox 模型)的估计并无实质影响。

这是因为,现实数据总是离散的(譬如年度数据、月度数据、日度数据),故可将每位个体的单一记录分为几条记录,对应于几个时间段,使得在每个时间段内 TVC 变为常数,然后沿用解释变量不随时间而变的方法进行估计。

假设个体 1 从时间 0 至 T 一直处于失业状态,并在时间 T 找到工作。假设  $0 < t_1 < t_2 < T$ 。

共有两个解释变量,其中 $x_1$ 不随时间而变(假设为虚拟变量,比如性别);而 $x_2(t)$ 可以随时间而变,在区间[ $0,t_1$ ),[ $t_1,t_2$ ),[ $t_2,T$ )的取值分别为 $x_2(t_1)$ , $x_2(t_2)$ 与 $x_2(T)$ ,故为阶梯函数。则个体 1 的信息由三条记录构成,参见表 14.1。

表 14.1 个体 1 的相关记录

个体 ID	持续时间	$x_1$	$x_2(t)$	归并虚拟变量 d
1	$t_1$	1	$x_2(t_1)$	0
1	$t_2$	1	$x_2(t_2)$	0
1	T	1	$x_2(T)$	1

个体 1 的完整信息被分为三个部分,对应于三条记录。在第 1、 2 条记录,个体 1 均未失效,而以归并结束,故归并虚拟变量为 0; 在第 3 条记录,个体 1 在时间 T 失效,故归并虚拟变量为 1。

扩展Cox模型的用途之一是用来检验比例风险假设。

回到解释变量不随时间而变的情形,可将比例风险假设解释为风险函数 $\lambda(t; \mathbf{x}) = \lambda_0(t)e^{\mathbf{x}'\boldsymbol{\beta}}$ 的参数 $\boldsymbol{\beta}$ 不随时间而变。

考虑一维情形。假设 $\beta$ 随时间而变,并将其写为 $\beta + \gamma g(t)$ ,其中g(t)为时间的函数(比如,t或 $\ln t$ ),则风险函数可写为

$$\lambda(t; x) = \lambda_0(t) e^{x[\beta + \gamma g(t)]} = \lambda_0(t) e^{x\beta + \gamma x g(t)}$$

这相当于是在原模型中引入了一个 TVC,即 $x \cdot g(t)$ ,由不随时间而变的解释变量 x 与时间的函数 g(t) 的乘积构成,是经人为定义而生成的 TVC。

如果 $\gamma = 0$ ,则简化为标准 Cox 模型的风险函数。

可通过检验原假设" $H_0: \gamma = 0$ "来检验比例风险假设。

通常选择g(t)为t或 $\ln t$ 。

在多维情形下,则引入所有解释变量x与g(t)的乘积,然后检验所有这些乘积项的系数联合显著性。

在作此检验时,由于引入了原模型中所没有的 TVC,故需要调整数据格式,将个体的信息根据需要分为多条记录。

## 30.12 不可观测的异质性

在进行久期分析时,样本中的个体可能具有"不可观测的异质性"(unobserved heterogeneity),也称为"弱质"(frailty)。

比如,在研究病人的存活时间时,病人的体质或弱质并不能完全观察,但却影响病人的死亡风险。

在线性模型中,忽略不可观测的异质性相当于遗漏变量;如果遗漏变量与解释变量不相关,则不影响估计量的一致性。

在久期分析的非线性模型中,即使不可观测的异质性与解释变量不相关,仍会导致不一致。

【例】对于失业持续时间的研究。经验数据表明,失业时间越长,则找到工作的概率越低,即风险率随着时间而下降。

如果样本中的每位个体完全一样,则意味着负向久期依赖 (negative duration dependence)。但事实可能并非如此。

假设失业人口可以分为两类,即 F 类(fast, 其风险函数恒等于 0.4)与 S 类(slow, 其风险函数恒等于 0.1),这两类各占一半。

由于F类的风险率高于S类,故F类平均地比S类更快找到工作而退出样本,导致样本中F类占比随时间而下降,引起整体的风险率下降。

假设样本中有 200 人,其中 100 人为 F 类,另 100 人为 S 类。

在 100 位 *F* 类人中,第 1 期将有 40 人找到工作,第 2 期将有 24 人找到工作,而第 3 期将有 14.4 人找到工作。

在 100 位 *S* 类人中,第 1 期将有 10 人找到工作,第 2 期将有 9 人找到工作,而第 3 期将有 8.1 人找到工作。

就整个样本而言,第 1 期的风险率为(40+10)/200 = 0.25,第 2 期的风险率为(24+9)/150 = 0.22,第 3 期的风险率为(14.4+8.1)/117 = 0.192,呈逐渐下降的趋势。

整体风险率的逐渐下降,只是由于 *F* 类与 *S* 类的结构变化而造成,而个体的风险函数始终为常数。

此效应被称为"弱质效应"(frailty effect)。

对于威布尔模型,风险函数为 $\lambda(t) = \gamma p t^{p-1}$ ,其中参数 p 决定风险函数的斜率,表示久期依赖的方向与程度。

如果存在不可观测的异质性而被忽略,则久期依赖参数p将被系统地低估,得不到一致估计。

解决方法是直接将不可观测的异质性引入模型中。

假设个体 j 的风险函数为

$$\lambda(t; \mathbf{x}_j, v_j) = \lambda_0(t) e^{x_j' \beta} v_j, \ v_j > 0$$

其中,不可观测的异质性 $v_j > 0$ 以乘积的形式进入风险函数。 $v_j$  越大,则个体j 越弱质,失效的风险越高。

 $\lambda(t; \mathbf{x}_j, v_j)$ 称为"条件风险函数" (conditional hazard function),因为它是给定 $v_i$ 条件下的风险函数。

生存函数为:

$$S(t; \mathbf{x}_{j}, v_{j}) = e^{-\Lambda(t)} = \exp\left[-\int_{0}^{t} \lambda_{0}(u) e^{\mathbf{x}_{j}^{\prime} \boldsymbol{\beta}} v_{j} du\right] = \left[\exp\left(-\int_{0}^{t} \lambda_{0}(u) e^{\mathbf{x}_{j}^{\prime} \boldsymbol{\beta}} du\right)\right]^{v_{j}} = S(t; \mathbf{x}_{j})^{v_{j}}$$

其中, $S(t; x_i)$ 为不含异质性的生存函数。

由于 $v_j$ 不可观测,故需要假设其概率分布,然后将 $v_j$ 积分掉,得到无条件的风险函数与生存函数。

假设 $v_j$ 的概率密度函数为 $g(v_j)$ ,则无条件风险函数与生存函数分别为

$$\lambda(t; \mathbf{x}_j) = \int_0^\infty \lambda(t; \mathbf{x}_j, v_j) g(v_j) dv_j$$

$$S(t; \mathbf{x}_j) = \int_0^\infty S(t; \mathbf{x}_j, v_j) g(v_j) dv_j$$

为使方程有解析解,常假设原模型为威布尔模型(指数模型为其特例),而 $v_j$ 服从 $Gamma(\delta, \delta)$ 分布或"逆正态分布"(Inverse Gaussian,简记 IG);这类模型称为"混合模型"(mixture model)。

将 $v_j$ 的期望值标准化为 1(故 $v_j$ =1代表平均弱质, average frailty),并记其方差为 $\theta$ 。

如果 $\theta=0$ ,则 $v_i$ 退化为常数,不存在异质性;

可通过检验 " $H_0$ :  $\theta=0$ " 来判断是否存在异质性。

由于不可观测的异质性不再出现在无条件风险函数与生存函数,故可对其进行 MLE 估计。

还可考虑依某变量的取值将个体分组,然后假设组内个体为同质,而不同组的个体具有异质性,这被称为"共享异质性"(shared frailty),即该异质性为同组内成员所共有。

上文的个体异质性则被称为"非共享异质性"(unshared frailty)。